PANDUAN PENGGUNAAN STATIFY

Pengantar

DAFTAR ISI

MODUL UJI STATISTIK PARAMETRIK DAN NONPARAMETRIK LANJUTAN....3
A. Proses Input Data....3
B. Kasus 1....3
C. Kasus 2....3
MODUL ANALISIS FAKTOR....4
A. Deskripsi Singkat....4
B. Tujuan Demonstrasi....4
C. Material Demonstrasi....4
D. Kegiatan Demonstrasi....4
MODUL GLM MULTIVARIATE & REPEATED MEASURES....10
A. Deskripsi Singkat....10
B. Tujuan Demonstrasi....10
C. Material Demonstrasi....10
D. Kegiatan Demonstrasi....10
MODUL TIME SERIES....22
Pengantar....22
Proses Input Data....22
Heteroscadascity Models....24
2. Tahapan Menggunakan Menu Heteroscedasticity Models....24
MODUL REGRESI LOGISTIK BINER....61
A. Deskripsi Singkat....61
B. Tujuan Demonstrasi....61
C. Material Demonstrasi....61
D. Kegiatan Demonstrasi....61
Demonstrasi Metode Enter....62
Demonstrasi Metode Forward....67
Demonstrasi Metode Backward....68
MODUL REGRESI ORDINAL....70
A. Deskripsi Singkat....70
B. Tujuan Demonstrasi....70
C. Material Demonstrasi....70
D. Kegiatan Demonstrasi....70
MODUL REGRESI MULTINOMIAL....75
A. Deskripsi Singkat....75

B. Tujuan Demonstrasi....75
C. Material Demonstrasi....75
D. Analisis menggunakan data mentah atau raw data....75
Analisis menggunakan data dengan bobot....84
a. Tahapan input data....84
b. Tahapan analisis Regresi Multinomial....86
MODUL ANALISIS DISKRIMINAN....89
E. Deskripsi Singkat....89
F. Tujuan Demonstrasi....89
G. Material Demonstrasi....89
H. Kegiatan Demonstrasi....89
Skenario 1: Metode Enter Independents Together....91
Skenario 2: Metode Use Stepwise Method....95
MODUL NEAREST NEIGHBOR....97
1. Deskripsi Singkat....97
2. Tujuan Demonstrasi....97
3. Material Demonstrasi....97
4. Kegiatan Demonstrasi....97
a. Skenario 1: Konfigurasi Default....98
b. Skenario 2: Konfigurasi pada Tab Neighbor....100
c. Skenario 3: Konfigurasi pada Tab Features....102
d. Skenario 4: Konfigurasi pada Tab Partition....104
e. Save Variable dan Output....105
f. Skenario 5: Target berupa Numerik....107
MODUL K-MEDOIDS....108
MODUL TEXT PREPROCESSING, VECTOR TRANSFORMATION, TEXT CLASSIFICATION, WORDCLOUD....109

MODUL UJI STATISTIK PARAMETRIK DAN NONPARAMETRIK LANJUTAN

A. Proses Input Data

1. Unduh data berikut:
2.
3. Buka situs web Statify

B. Kasus 1

C. Kegiatan Demonstrasi

Kolmogorov Smirnov

1. Masukkan data ke dalam Statify dan beri nama variabelnya.
2. Langkah selanjutnya yaitu melakukan uji normalitas dengan cara klik **Analyze > Descriptive Statistics > Explore**
3. Masukkan variabel yang dilakukan pengujian normalitas pada jendela Explore dengan memasukkan variabel pengujian 97

   Catatan: Anda dapat memasukkan beberapa variabel sekaligus di Dependent List untuk menguji normalitas masing-masing variabel, misalnya uji normalitas 2 variabel atau 3 variabel.
4. Klik button Plots dan centang '**Normality plots with tests**' kemudian Continue dan klik OK.
5. Hasil pengujian ditampilkan pada jendela output. Untuk membaca hasil dari Kolmogorov-Smirnov terdapat pada tabel dengan judul 'Tests of Normality' 98 Sehingga, berdasarkan tabel output di atas dapat diambil kesimpulan bahwa nilai p-value untuk Kolmogorov Smirnov adalah 0.200 (p-value > 0.05) yang artinya terima dan dapat disimpulkan bahwa data berat ginjal 36 kelinci yang digunakan berasal dari populasi berdistribusi normal.

Shapiro Wilks

1. Masukkan data ke dalam Statify dan beri nama variabelnya.
2. Langkah selanjutnya yaitu melakukan uji normalitas dengan cara klik
3.

Uji Bartlett

4. Masukkan data ke dalam Statify dan beri nama variabelnya.
5. Langkah selanjutnya yaitu melakukan uji normalitas dengan cara klik
6.

Uji Proporsi Binomial dan Multinomial

1. Masukkan data ke dalam Statify dan beri nama variabelnya.
2. Tentukan hipotesis H0 dan H1.
3. Tentukan variabel yang menjadi baris (merupakan kejadian/kategori yang akan dihitung proporsinya) dan variabel yang menjadi kolom (variabel kategori/kelompok).
4. Tentukan tingkat signifikansi () dan hitung/temukan adalah jumlah baris dan c adalah jumlah kolom.
5. Klik Analyze–>Descriptive Statistics–>Crosstabs
6. Masukkan variabel ke bidang baris. Misalnya dalam contoh gambar di bawah ini, klik variabel statusruta dan selanjutnya klik tombol panah di samping bidang Row(s) atau klik dan tahan variabel statusruta dan geser ke bidang Row(s)
7. Masukkan variabel kategori/kelompok ke dalam bidang Column(s). Misalkan dalam contoh di bawah ini, klik variabel desa lalu klik tombol panah di samping bidang Column(s) atau klik dan tahan variabel desa dan geser ke bidang Column(s).
8. Klik tombol Statistics sehingga menampilkan gambar di bawah ini. Selanjutnya klik Chi-square sehingga tercentang, kemudian klik tombol Continue
9. Klik tombol Cells sehingga menampilkan gambar di bawah ini. Pilih Observed dan Expected di bagian Counts . Selanjutnya klik tombol Continue.
10. Klik tombol OK.

Uji Kebebasan Chi-Square

11. Masukkan data ke dalam Statify dan beri nama variabelnya.
12. Sebelum melakukan pengolahan maka kita perlu melakukan pengkodean pada setiap kategori.
13. Tentukan variabel yang menjadi baris (merupakan kejadian/kategori yang akan dihitung proporsinya) dan variabel yang menjadi kolom (variabel kategori/kelompok).
14. Tentukan tingkat signifikansi () dan hitung/temukan adalah jumlah baris dan c adalah jumlah kolom.
15. Klik Analyze–>Descriptive Statistics–>Crosstabs
16. Masukkan variabel ke bidang baris. Misalnya dalam contoh gambar di bawah ini, klik variabel statusruta dan selanjutnya klik tombol panah di samping bidang Row(s) atau klik dan tahan variabel statusruta dan geser ke bidang Row(s)
17. Masukkan variabel kategori/kelompok ke dalam bidang Column(s). Misalkan dalam contoh di bawah ini, klik variabel desa lalu klik tombol panah di samping bidang Column(s) atau klik dan tahan variabel desa dan geser ke bidang Column(s).
18. Klik tombol Statistics sehingga menampilkan gambar di bawah ini. Selanjutnya klik Chi-square sehingga tercentang, kemudian klik tombol Continue

19. Klik tombol Cells sehingga menampilkan gambar di bawah ini. Pilih Observed dan Expected di bagian Counts . Selanjutnya klik tombol Continue.
20. Klik tombol OK.

MODUL ANALISIS FAKTOR

A. Deskripsi Singkat

Analisis Faktor dilakukan untuk mengidentifikasi struktur hubungan antarvariabel dan mereduksi sejumlah variabel yang saling berkorelasi menjadi beberapa faktor yang lebih sederhana. Sistem akan menganalisis pola korelasi antarvariabel, menentukan jumlah faktor yang terbentuk, serta menghitung nilai *loading factor* untuk menunjukkan kontribusi masing-masing variabel terhadap faktor. Selain pembentukan faktor, pengguna juga akan diperlihatkan hasil pengujian kelayakan data dan interpretasi faktor yang terbentuk sebagai dasar dalam memahami struktur data.

B. Tujuan Demonstrasi

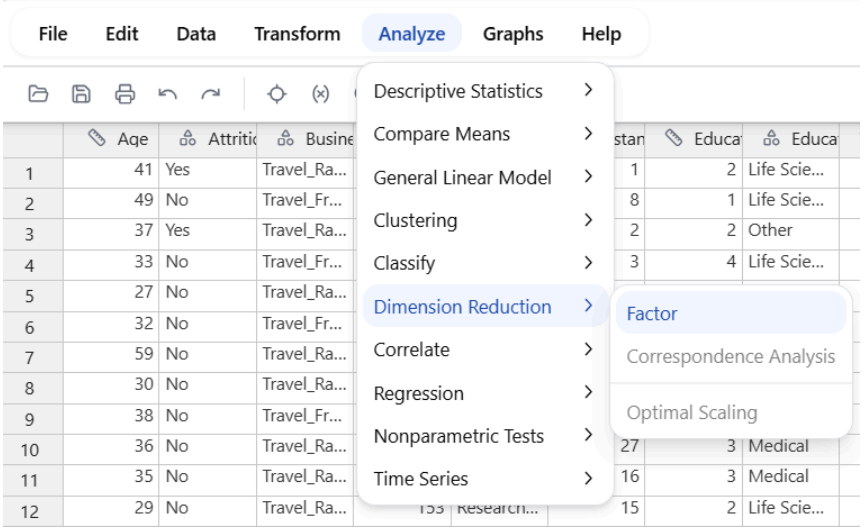
Demonstrasi modul Analisis Faktor ditujukan untuk memberikan pemahaman praktis mengenai tahapan pelaksanaan analisis faktor menggunakan perangkat lunak Statify. Kegiatan demonstrasi mencakup pengaturan variabel dan parameter analisis, proses pembentukan faktor, serta pembacaan hasil yang diperoleh untuk mengetahui hubungan variabel dengan faktor yang terbentuk. Dengan demikian, pengguna dapat memahami penerapan analisis faktor sekaligus menginterpretasikan hasilnya sesuai dengan karakteristik data yang dianalisis.

C. Material Demonstrasi

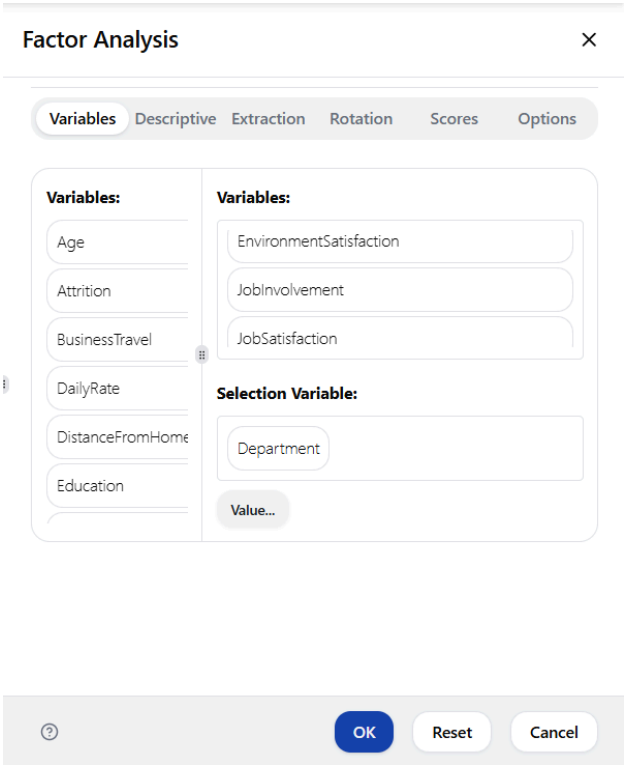
1. Dataset yang dapat diakses pada https://s.stis.ac.id/dataset_demoStatify64
2. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/
3. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64

D. Kegiatan Demonstrasi

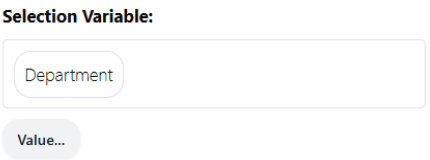
1. Tahap persiapan dilakukan dengan mengimpor dataset ke lembar kerja Statify. Pilih menu **File > Import Data > CSV Data**. Jika tampilan/preview dataset berhasil muncul, lalu tekan Impor.
2. Pilih menu **Analyze > Dimension Reduction> Factor**.



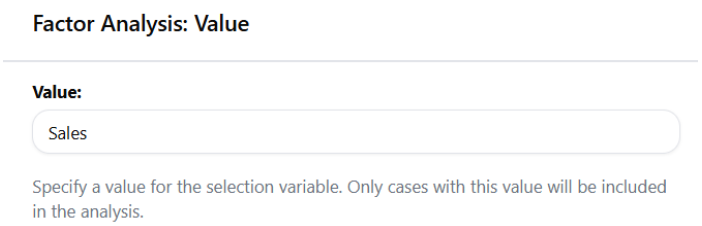
3. Klik tab **Variables**. Pada tahap ini, kita akan memilih variabel terkait kepuasan dan keterlibatan kerja untuk melihat apakah variabel-variabel tersebut dapat diringkas menjadi faktor utama.
    - Pindahkan variabel EnvironmentSatisfaction, JobInvolvement, JobSatisfaction, RelationshipSatisfaction, dan WorkLifeBalance ke dalam kotak Variables dengan cara *drag-and-drop*.



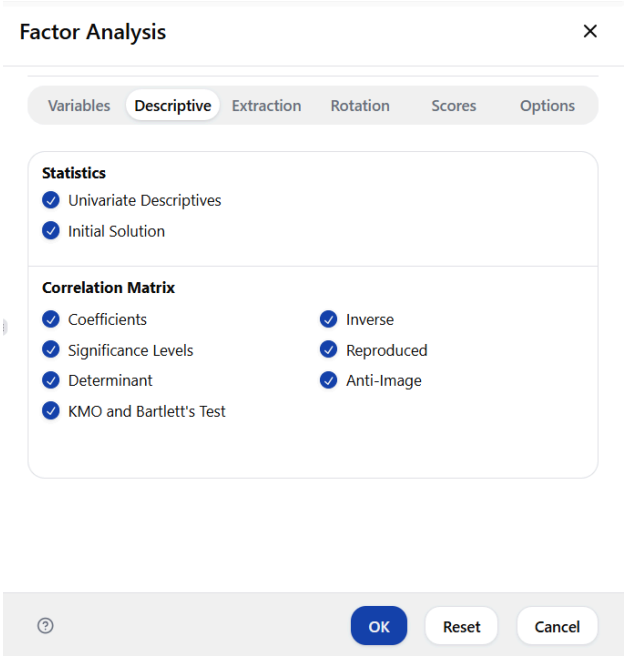
    - Pindahkan variabel Department ke dalam kotak Selection Variable.



    - Klik tombol Value. Ketikkan “Sales” pada text input, lalu klik button Continue. Konfigurasi ini akan menginstruksikan sistem untuk mengekstrak faktor kepuasan khusus pada karyawan divisi Sales saja.

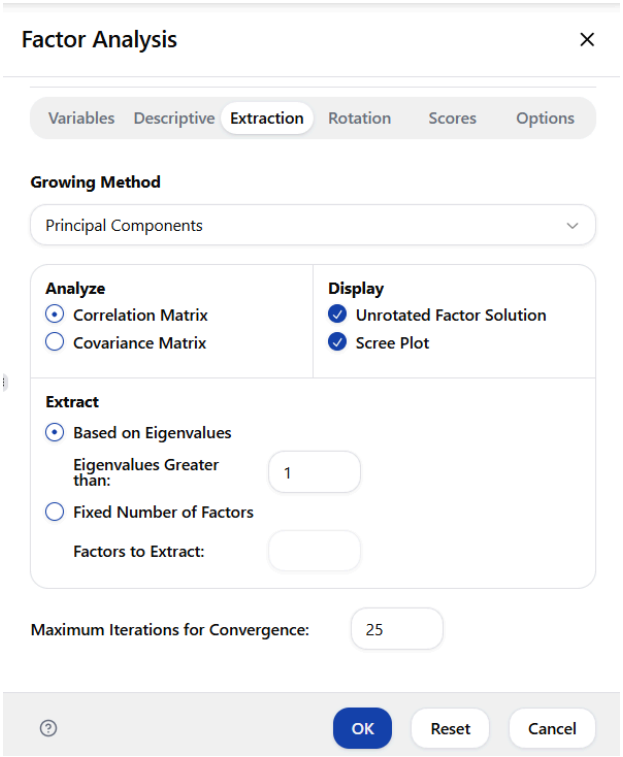


4. Klik tab **Descriptive**. Sebelum faktor dibentuk, kita wajib menguji kelayakan matriks data. Tab ini berisikan serangkaian uji asumsi yang harus dipenuhi.



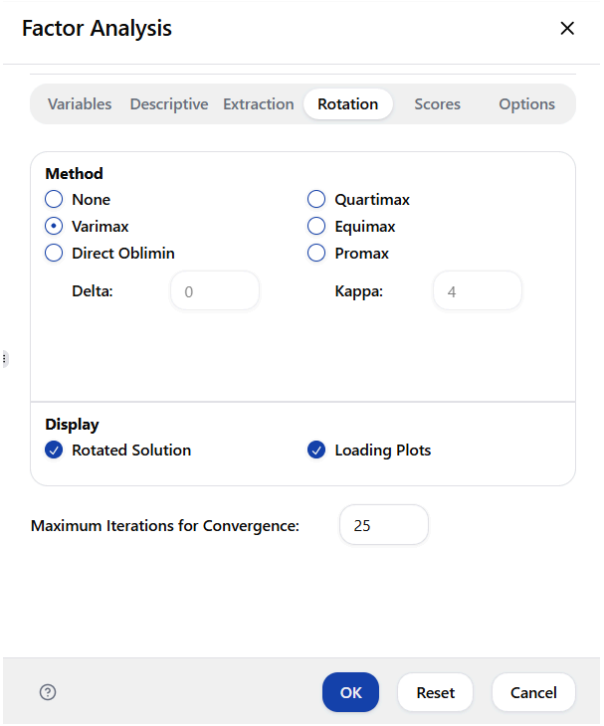
- Pada kolom Statistics, centang **Univariate Descriptives** untuk melihat ringkasan statistik dasar dari kelima variabel kepuasan kerja yang akan dianalisis, dan **Initial Solution** untuk menampilkan nilai komunalitas awal sebelum ekstraksi.
- Pada kolom Correlation Matrix, centang **Coefficients** dan **Significance Levels** untuk menampilkan matriks korelasi antarvariabel kepuasan. Pastikan Anda juga mencentang **KMO and Bartlett's Test** sebagai syarat wajib pengujian kecukupan sampel, beserta **Inverse**, **Reproduced**, dan **Anti-Image** untuk mengevaluasi *Measure of Sampling Adequacy* (MSA) dari masing-masing variabel pembentuk.

5. Klik tab **Extraction**. Tab ini digunakan untuk menentukan bagaimana faktor diekstraksi dari data mentah.



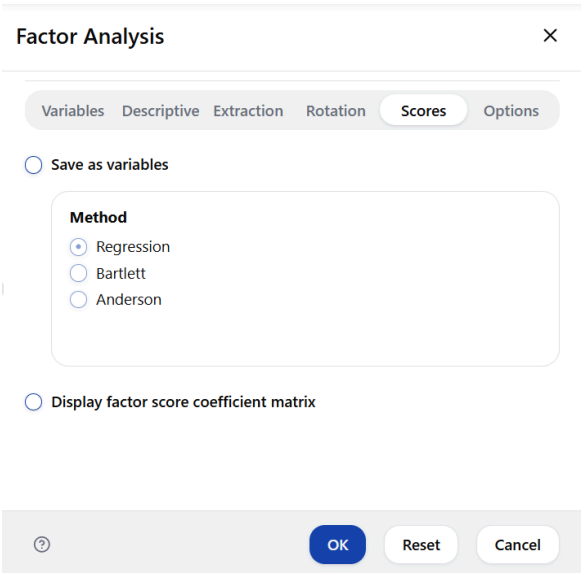
- Klik Principal Components sebagai metode ekstraksi untuk mereduksi dimensi data dengan mempertahankan sebanyak mungkin varians asli dari variabel-variabel kepuasan tersebut.
- Pada kolom Analyze, Pilih **Correlation Matrix** agar matriks korelasi yang telah dievaluasi pada tahap sebelumnya digunakan sebagai dasar pengekstraksian faktor.
- Centang opsi **Unrotated Factor Solution** untuk menampilkan matriks faktor sebelum dirotasi pada halaman *output*, dan centang **Scree Plot** untuk memunculkan visualisasi grafik garis yang akan sangat membantu kita dalam mengevaluasi jumlah faktor optimal secara visual.
- Pilih opsi **Based on Eigenvalues** dan pastikan nilainya diatur pada angka **1** (*Eigenvalues Greater than: 1*). Dengan pengaturan ini, sistem secara otomatis hanya akan membentuk faktor yang memiliki nilai Eigen di atas angka 1.

6. Klik tab **Rotation**. Rotasi diperlukan agar muatan variabel pada setiap faktor menjadi lebih ekstrem (mendekati 0 atau 1), sehingga penamaan dan interpretasi faktor lebih mudah dilakukan.

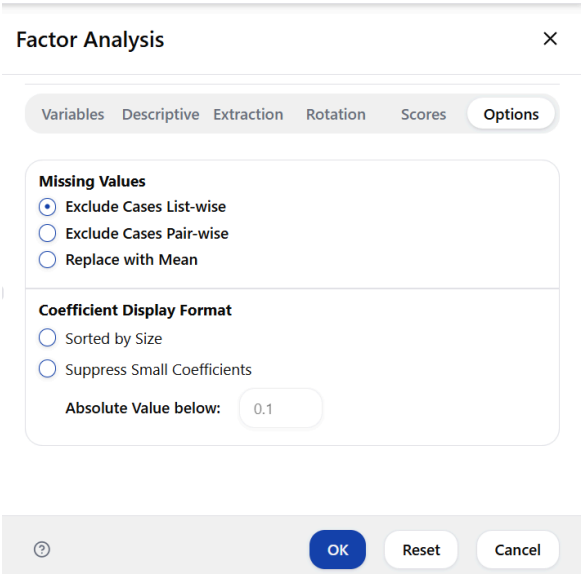


- Pada demonstrasi ini, pilih **Varimax** sebagai metode rotasi untuk meminimalkan jumlah variabel dengan muatan tinggi pada satu faktor.
- Centang **Rotated Solution** agar sistem menampilkan matriks komponen yang telah dirotasi, dan centang juga **Loading Plots** untuk membantu Anda melihat pengelompokan variabel secara visual.

7. Jika ingin menyimpan hasil ekstraksi ini sebagai data baru untuk analisis lanjutan dan menampilkan tabel matriks pengali yang digunakan model saat menghitung skor faktor, Anda bisa mengaktifkan fitur Save as variables dan fitur Display factor score coefficient matrix pada tab **Scores**.



8. Jika ingin memastikan ketepatan penanganan data yang kosong dan kebersihan tabel hasil, Anda bisa menyetel konfigurasinya pada tab **Options**.



9. Terakhir, klik **OK** untuk memproses analisis.

MODUL GLM MULTIVARIATE & REPEATED MEASURES

A. Deskripsi Singkat

Analisis GLM Multivariate dan Repeated Measures digunakan untuk menguji perbedaan rata-rata pada lebih dari satu variabel dependen (peubah ganda) secara simultan, baik pada satu populasi, dua populasi independen, dua populasi berpasangan, beberapa populasi (satu atau dua faktor), maupun pada pengukuran berulang terhadap subjek yang sama. Sistem akan menghitung statistik uji T^2 Hotelling atau statistik multivariat (Pillai's Trace, Wilks' Lambda, Hotelling's Trace, Roy's Largest Root) sesuai desain analisis yang dipilih, beserta pemeriksaan asumsi kesamaan matriks kovarians (Box's M) dan sphericity (Mauchly's Test) bila relevan.

Modul ini mencakup enam skenario analisis: Hotelling T^2 Satu Populasi, Hotelling T^2 Dua Populasi Independen, Hotelling T^2 Berpasangan, One-Way MANOVA, Two-Way MANOVA, dan Repeated Measures MANOVA.

B. Tujuan Demonstrasi

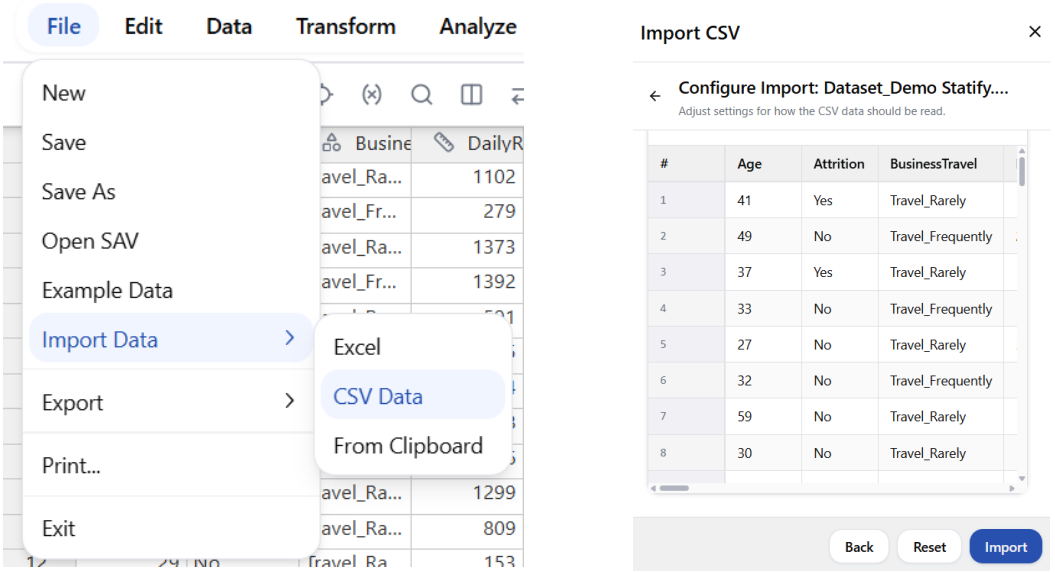
Panduan ini disusun sebagai panduan praktis untuk menggunakan perangkat lunak Statify dalam menjalankan keenam skenario GLM Multivariate dan Repeated Measures di atas. Melalui demonstrasi ini, pengguna diharapkan mampu memahami cara memilih menu yang sesuai dengan desain data yang dimiliki (satu populasi, dua populasi, berpasangan, atau lebih dari dua kelompok), memasukkan variabel dependen dan faktor pada dialog yang tepat, serta membaca dan menginterpretasikan tabel Multivariate Tests yang dihasilkan.

C. Material Demonstrasi

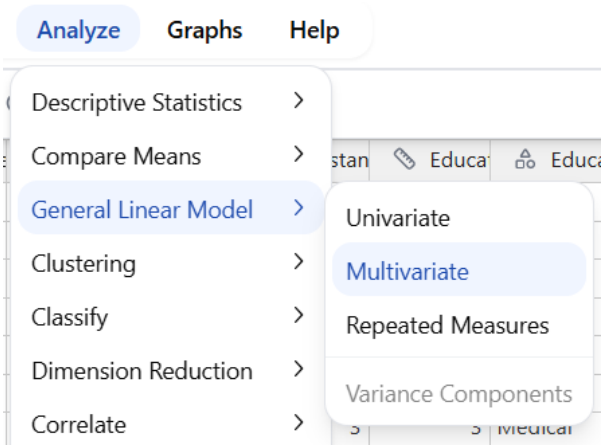
1. Dataset yang dapat diakses pada https://s.stis.ac.id/dataset_demoStatify64
2. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/
3. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64

D. Kegiatan Demonstrasi

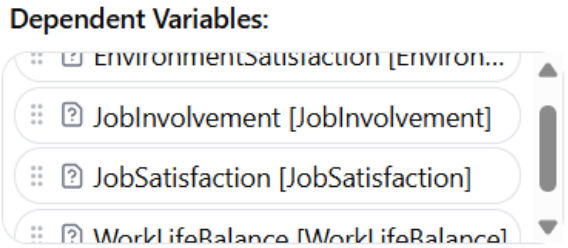
- **Hotelling T^2 Satu Populasi**
  1. Impor dataset. Pilih **File > Import Data > CSV Data**. Jika tampilan/preview dataset berhasil muncul, tekan Impor.



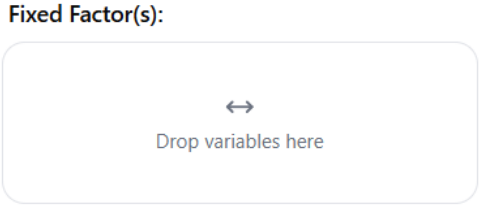
2. Pilih menu **Analyze > General Linear Model > Multivariate**.



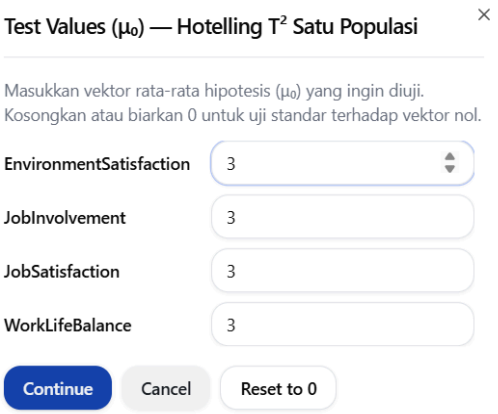
3. Pindahkan variabel **EnvironmentSatisfaction**, **JobInvolvement**, **JobSatisfaction**, dan **WorkLifeBalance** ke kotak **Dependent Variables**.



4. Biarkan kotak **Fixed Factor(s)** kosong.



5. Klik tombol **Test Values**. Isi nilai μ_0 untuk tiap variabel sesuai urutan: 3, 3, 3, 3. Klik **Continue**.



6. Klik **OK**.
7. Baca hasil pada tabel **Multivariate Tests**, baris efek **Hotelling T^2 (vs μ_0)**.

Multivariate Tests

Type TypeIII sum of squares

Multivariate Tests

Copy SVG

Multivariate Tests

Effect		T^2	Value	F	Hypothesis df	Error df	Sig.	Partial Eta Squared	Noncent. Parameter	Observed Power
Hotelling T^2 (vs μ_0)	Pillai's Trace		0.2822	144.0623	4	1466	<.001	0.2822	576.249	0.9993
	Wilks' Lambda		0.7178	144.0623	4	1466	<.001	0.2822	576.249	0.9993
	Hotelling's Trace	577.4282	0.3931	144.0623	4	1466	<.001	0.2822	576.249	0.9993
	Roy's Largest Root		0.3931	144.0623	4	1466	<.001	0.2822	576.249	0.9993

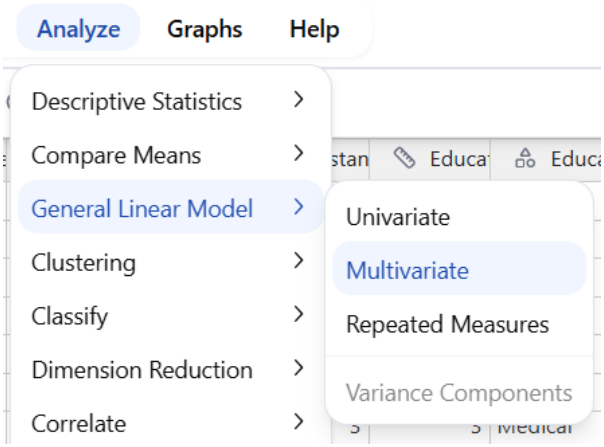
Description Edit

One-Sample Hotelling's T^2 tests H_0: $\mu = \mu_0$. For the intercept-only model (no between-subjects factors), $T^2 = (n - 1) \times$ Hotelling's Trace, and $F = ((n - p) / (p(n - 1))) \cdot T^2 \sim F(p, n - p)$. Reject H_0 when Sig. < α.

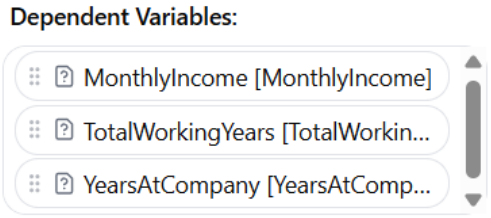
Dengan nilai Sig. < 0,001 (lebih kecil dari $\alpha = 0{,}05$), keputusannya adalah tolak H_0, yang berarti rata-rata keempat variabel kepuasan dan keterlibatan kerja karyawan berbeda secara signifikan dari nilai target $\mu_0 = (3, 3, 3, 3)$.

- **Hotelling T^2 Dua Populasi Independen**

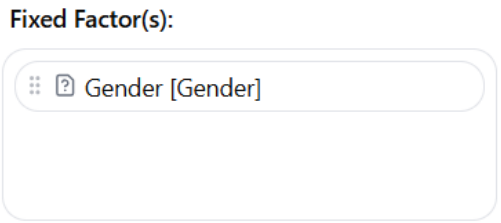
1. Pilih menu **Analyze > General Linear Model > Multivariate**.



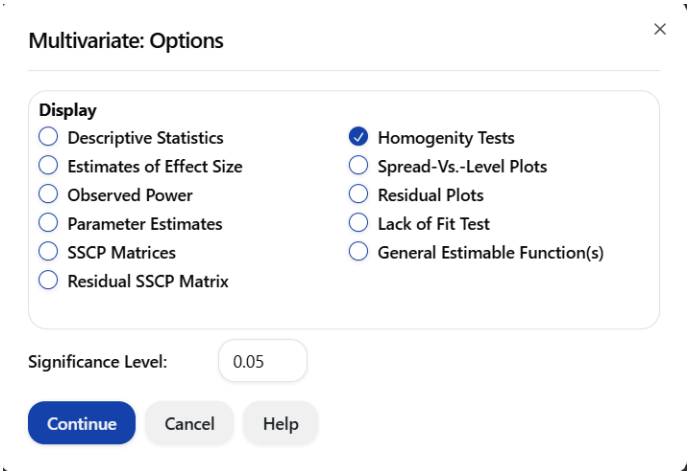
2. Pindahkan variabel **MonthlyIncome**, **TotalWorkingYears**, **YearsAtCompany**, dan **DistanceFromHome** ke kotak **Dependent Variables**.



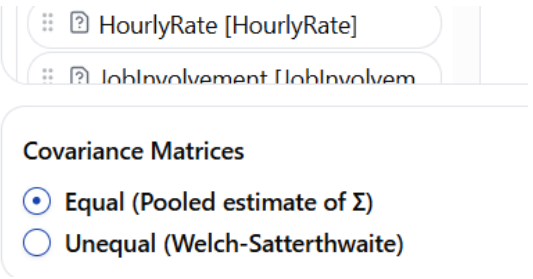
3. Pindahkan variabel **Gender** ke kotak **Fixed Factor(s)**.



4. (Opsional) Klik **Options**, centang **Homogeneity tests** untuk menampilkan Box's M Test.



5. Scroll ke bawah sedikit, pilih mode **Covariance Matrices**: **Equal (Pooled estimate of Σ)** jika Box's M tidak signifikan, atau **Unequal (Welch-Satterthwaite)** jika signifikan.



6. Klik **OK**.
7. Baca hasil pada tabel **Multivariate Tests**, baris efek **Gender** (bukan Intercept).

Box's Test of Equality of Covariance Matrices	
Box's M	8.5168
F	1.4162
df1	6
df2	10692276.9345
Sig.	0.2039

Multivariate Tests

Type TypeIII sum of squares

Multivariate Tests

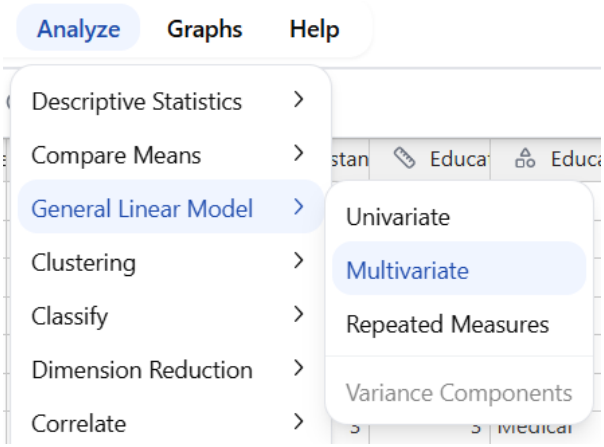
Copy SVG

Multivariate Tests										
Effect		T^2	Value	F	Hypothesis df	Error df	Sig.	Partial Eta Squared	Noncent. Parameter	Observed Power
Hotelling T^2 (vs μ_0)	Pillai's Trace		0.6955	1116.3154	3	1466	<.001	0.6955	3348.9461	0.9999
	Wilks' Lambda		0.3045	1116.3154	3	1466	<.001	0.6955	3348.9461	0.9999
	Hotelling's Trace	3353.5149	2.2844	1116.3154	3	1466	<.001	0.6955	3348.9461	0.9999
	Roy's Largest Root		2.2844	1116.3154	3	1466	<.001	0.6955	3348.9461	0.9999
Gender	Pillai's Trace		0.0022	1.1	3	1466	0.348	0.0022	3.3	0.9091
	Wilks' Lambda		0.9978	1.1	3	1466	0.348	0.0022	3.3	0.9091
	Hotelling's Trace		0.0023	1.1	3	1466	0.348	0.0022	3.3	0.9091
	Roy's Largest Root		0.0023	1.1	3	1466	0.348	0.0022	3.3	0.9091

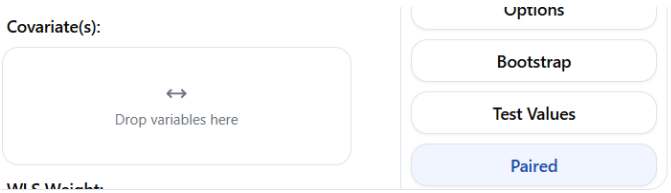
Dengan nilai Sig. = 0,348 (lebih besar dari α = 0,05), keputusannya adalah gagal tolak H_0, yang berarti tidak terdapat perbedaan signifikan pada rata-rata pendapatan, masa kerja, dan jarak rumah antara karyawan laki-laki dan perempuan.

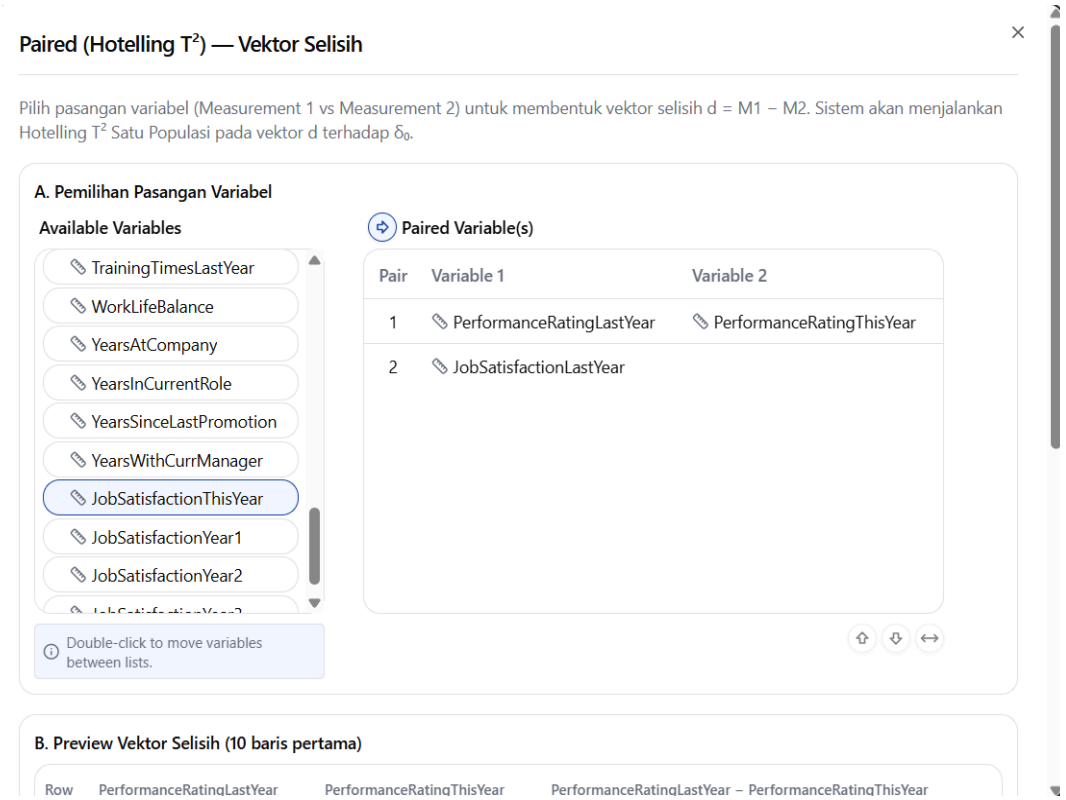
- **Hotelling T^2 Berpasangan**

1. Pilih menu **Analyze > General Linear Model > Multivariate**.

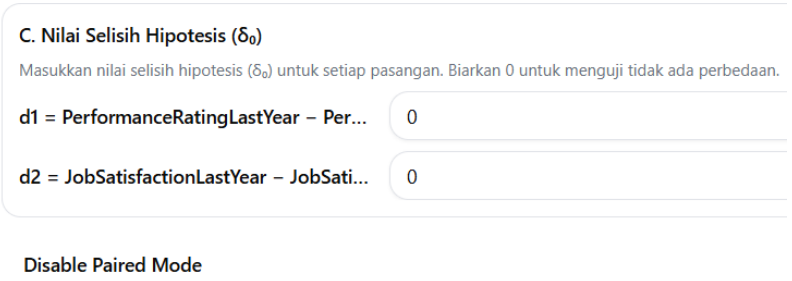


2. Klik tombol **Paired**. Tentukan pasangan variabel: **PerformanceRatingLastYear** dengan **PerformanceRatingThisYear**, dan **JobSatisfactionLastYear** dengan **JobSatisfactionThisYear**.

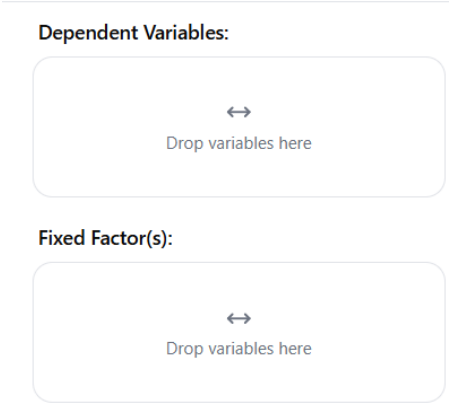




3. Biarkan nilai default $\delta_0 = [0, 0]$. Klik **Continue**.



4. Tidak perlu lagi memindahkan variabel ke kotak Dependent Variables maupun Fixed Factor(s).



5. Klik **OK**.
6. Baca hasil pada tabel **Multivariate Tests — Hotelling T² Berpasangan**.

Multivariate Tests — Hotelling T² Berpasangan

Analisis dilakukan pada vektor selisih d1 = PerformanceRatingLastYear − PerformanceRatingThisYear; d2 = JobSatisfactionLastYear − JobSatisfactionThisYear. δ0 = [0, 0].

Multivariate Tests — Hotelling T² Berpasangan

Copy SVG

Multivariate Tests — Hotelling T² Berpasangan										
Effect		T²	Value	F	Hypothesis df	Error df	Sig.	Partial Eta Squared	Noncent. Parameter	Observed Power
Hotelling T² Berpasangan	Pillai's Trace		0.0366	27.863	2	1468	<.001	0.0366	55.7259	0.9964
	Wilks' Lambda		0.9634	27.863	2	1468	<.001	0.0366	55.7259	0.9964
	Hotelling's Trace	55.7639	0.038	27.863	2	1468	<.001	0.0366	55.7259	0.9964
	Roy's Largest Root		0.038	27.863	2	1468	<.001	0.0366	55.7259	0.9964

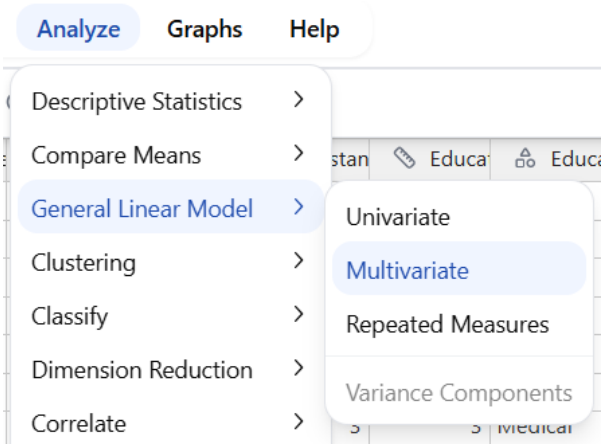
Description Edit

Paired Hotelling's T^2 tests H_0: $\delta = \delta_0$ on the difference vector d = M1 − M2. $T^2 = n \cdot (\bar{d} - \delta_0)^T S_d^{-1} (\bar{d} - \delta_0)$, and $F = ((n - p) / (p(n - 1))) \cdot T^2 \sim F(p, n - p)$. Reject H_0 when Sig. < α.

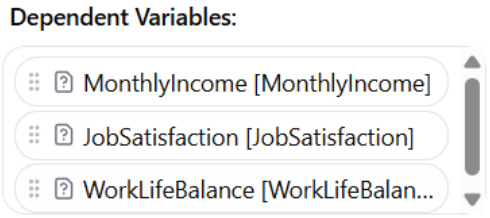
Dengan nilai Sig. < 0,001 (lebih kecil dari α = 0,05), keputusannya adalah tolak H_0, yang berarti terdapat perbedaan signifikan pada skor penilaian kinerja dan kepuasan kerja karyawan antara tahun lalu dan tahun ini.

- **One-Way MANOVA**

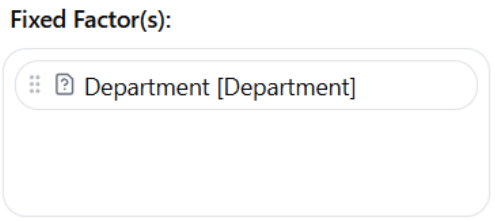
1. Pilih menu **Analyze > General Linear Model > Multivariate**.



2. Pindahkan variabel **MonthlyIncome**, **JobSatisfaction**, dan **WorkLifeBalance** ke kotak **Dependent Variables**.



3. Pindahkan variabel **Department** ke kotak **Fixed Factor(s)**.



4. Klik **OK**.
5. Baca hasil pada tabel **Multivariate Tests**, baris efek **Department**.

Multivariate Tests

Type TypeIII sum of squares

Multivariate Tests

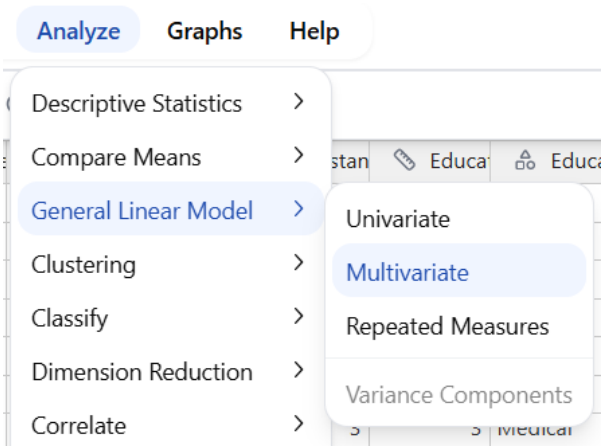
Copy SVG

Multivariate Tests										
Effect		T^2	Value	F	Hypothesis df	Error df	Sig.	Partial Eta Squared	Noncent. Parameter	Observed Power
Hotelling T^2 (vs μ_0)	Pillai's Trace		0.8853	3769.1582	3	1465	<.001	0.8853	11307.4746	1
	Wilks' Lambda		0.1147	3769.1582	3	1465	<.001	0.8853	11307.4746	1
	Hotelling's Trace	11322.9115	7.7184	3769.1582	3	1465	<.001	0.8853	11307.4746	1
	Roy's Largest Root		7.7184	3769.1582	3	1465	<.001	0.8853	11307.4746	1
Department	Pillai's Trace		0.0105	2.5751	6	2932	0.0172	0.0052	15.4505	0.9612
	Wilks' Lambda		0.9895	2.5768	6	2930	0.0172	0.0052	15.4608	0.9612
	Hotelling's Trace		0.0106	2.5785	6	2928	0.0171	0.0105	15.471	0.9612
	Roy's Largest Root		0.0091	4.4275	3	1466	0.0042	0.009	13.2824	0.9774

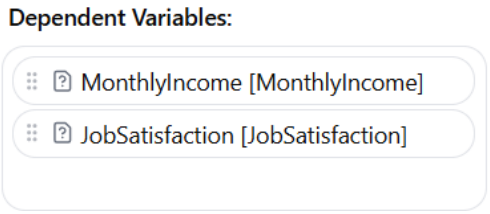
Dengan nilai Sig. = 0,017 (lebih kecil dari α = 0,05), keputusannya adalah tolak H_0, yang berarti terdapat perbedaan signifikan pada rata-rata pendapatan, kepuasan kerja, dan keseimbangan kerja-hidup antara karyawan di ketiga departemen.

- **Two-Way MANOVA**

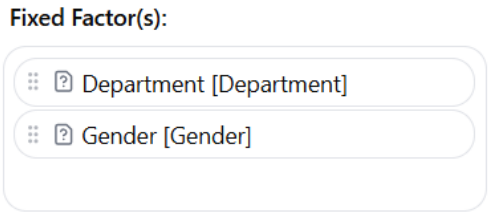
1. Pilih menu **Analyze > General Linear Model > Multivariate**.



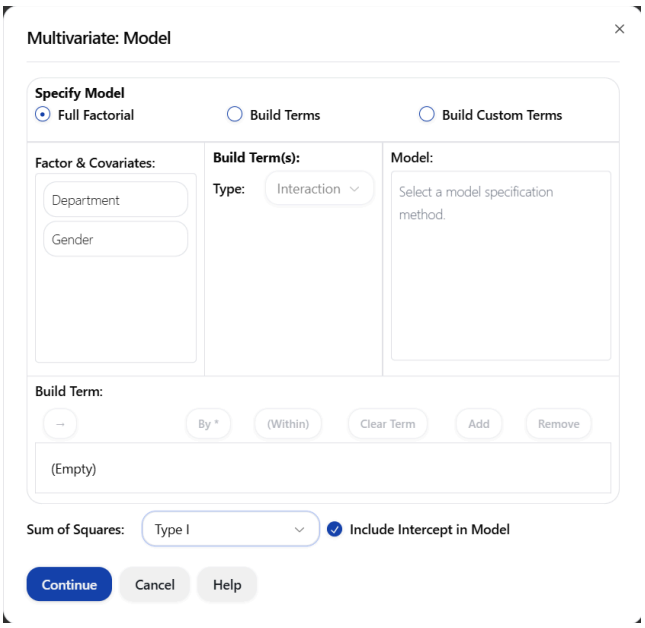
2. Pindahkan variabel **MonthlyIncome** dan **JobSatisfaction** ke kotak **Dependent Variables**.



3. Pindahkan variabel **Gender** dan **Department** (keduanya) ke kotak **Fixed Factor(s)**.



4. Klik tab **Model**, pilih **Full Factorial** dan **Type I** Sum of Squares. Klik **Continue**.



5. Klik **OK**.
6. Baca hasil pada tabel **Multivariate Tests**, baris efek **Gender**, **Department**, dan **Gender*Department**.

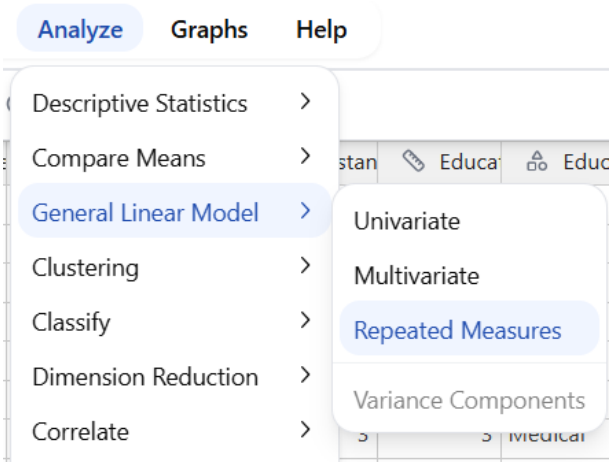
Multivariate Tests

Effect		T^2	Value	F	Hypothesis df	Error df	Sig.	Partial Eta Squared	Noncent. Parameter	Observed Power
Hotelling T^2 (vs μ_0)	Pillai's Trace		0.6961	1675.2409	2	1463	<.001	0.6961	3350.4818	0.9999
	Wilks' Lambda		0.3039	1675.2409	2	1463	<.001	0.6961	3350.4818	0.9999
	Hotelling's Trace	3352.7719	2.2901	1675.2409	2	1463	<.001	0.6961	3350.4818	0.9999
	Roy's Largest Root		2.2901	1675.2409	2	1463	<.001	0.6961	3350.4818	0.9999
Department	Pillai's Trace		0.005	1.851	4	2928	0.1163	0.0025	7.404	0.946
	Wilks' Lambda		0.995	1.8511	4	2926	0.1163	0.0025	7.4043	0.946
	Hotelling's Trace		0.0051	1.8511	4	2924	0.1163	0.005	7.4046	0.946
	Roy's Largest Root		0.0044	3.2559	2	1464	0.0388	0.0044	6.5119	0.9693
Gender	Pillai's Trace		0.0021	1.5492	2	1463	0.2128	0.0021	3.0984	0.9355
	Wilks' Lambda		0.9979	1.5492	2	1463	0.2128	0.0021	3.0984	0.9355
	Hotelling's Trace		0.0021	1.5492	2	1463	0.2128	0.0021	3.0984	0.9355
	Roy's Largest Root		0.0021	1.5492	2	1463	0.2128	0.0021	3.0984	0.9355
Department*Gender	Pillai's Trace		0.0028	1.0253	4	2928	0.3927	0.0014	4.1011	0.9025
	Wilks' Lambda		0.9972	1.0249	4	2926	0.3929	0.0014	4.0997	0.9024
	Hotelling's Trace		0.0028	1.0246	4	2924	0.393	0.0028	4.0984	0.9024
	Roy's Largest Root		0.0024	1.7665	2	1464	0.1713	0.0024	3.533	0.9434

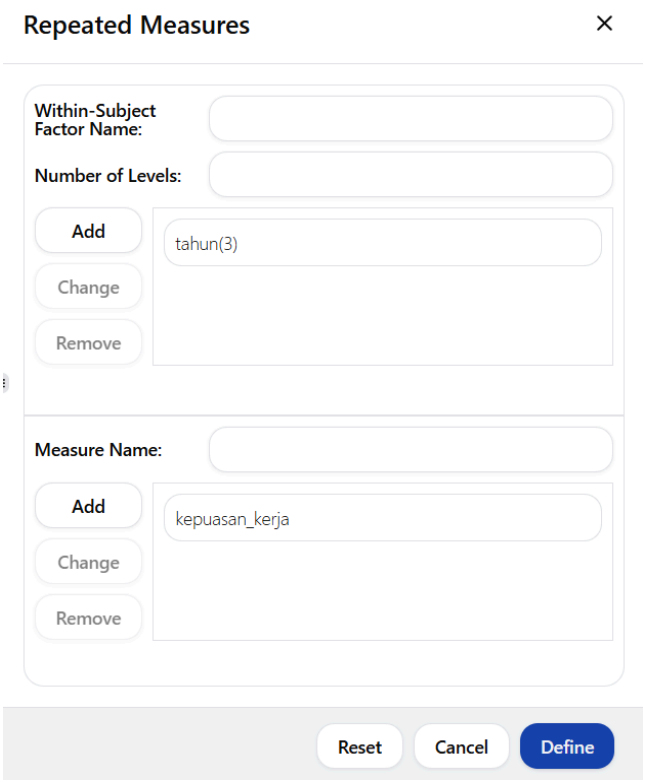
Dengan nilai Sig. masing-masing sebesar 0,213 (Gender), 0,116 (Department), dan 0,393 (Gender*Department), seluruhnya lebih besar dari $\alpha = 0{,}05$, keputusannya adalah gagal tolak H_0 untuk ketiga efek, yang berarti baik jenis kelamin, departemen, maupun interaksi keduanya tidak berpengaruh signifikan terhadap pendapatan dan kepuasan kerja.

- **Repeated Measures MANOVA**

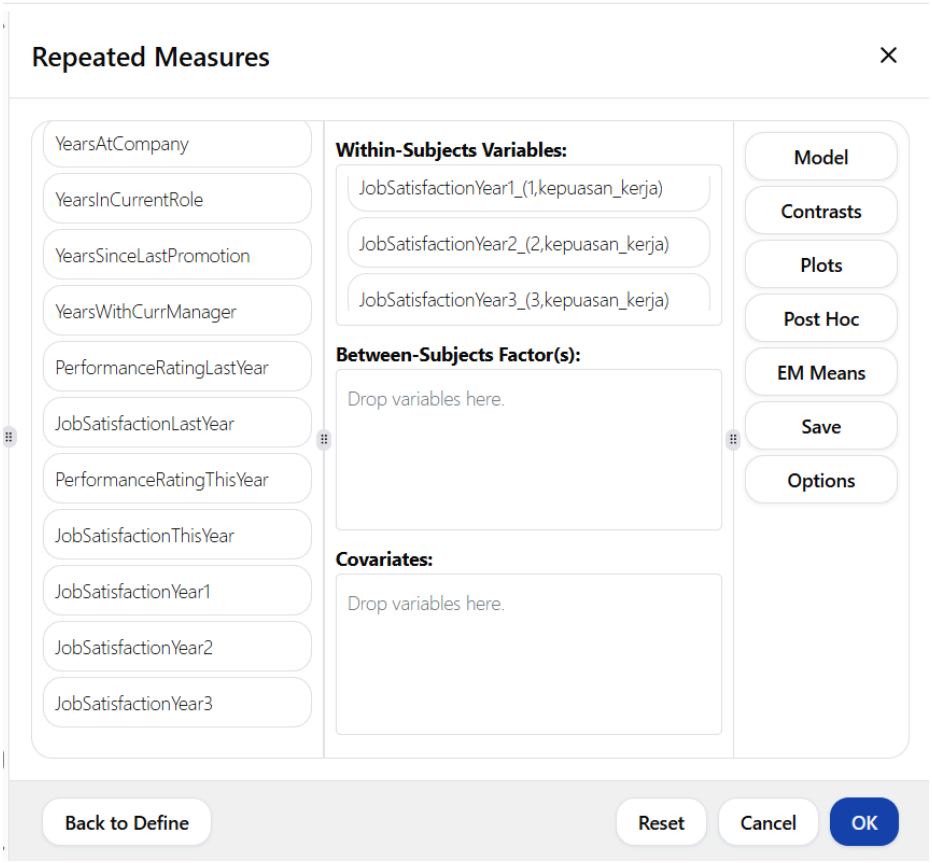
1. Pilih menu **Analyze > General Linear Model > Repeated Measures**.



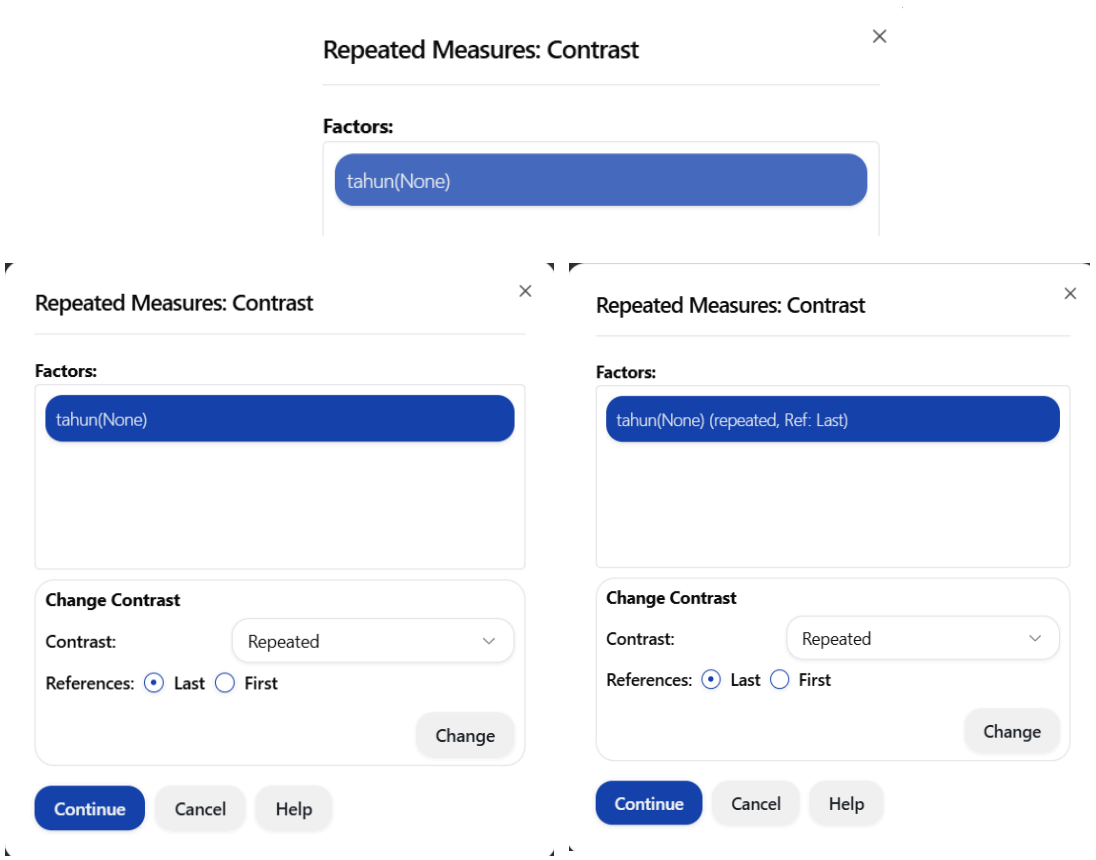
2. Pada **Within-Subject Factor Name**, ketik **tahun**. Pada **Number of Levels**, isi **3**. Klik **Add**. Pada **Measure Name**, isi **kepuasan_kerja**, kemudian **Add**. Klik **Define**.



3. *Drag & drop* satu per satu variabel **JobSatisfactionYear1**, **JobSatisfactionYear2**, **JobSatisfactionYear3** sesuai urutan level.



4. Klik tab **Contrasts**, klik sekali factors yang akan digunakan (tahun), kemudian ubah jenis kontras menjadi **Repeated**, klik **Change**, lalu **Continue**.



5. Klik **OK**.
6. Baca hasil pada tabel **Multivariate Tests**, baris efek **tahun**, serta tabel **Mauchly's Test of Sphericity**.

Multivariate Tests

Design: Intercept; Within Subjects Design: Type TypeIII sum of squares

Multivariate Tests

Copy SVG

Multivariate Tests									
		Value	F	Hypothesis df	Error df	Sig.	Partial Eta Squared	Noncent. Parameter	Observed Power
tahun	Pillai's Trace	0.174	155.044	2.000	1468.000	<.001	0.174	310.087	0.999
	Wilks' Lambda	0.826	155.044	2.000	1468.000	<.001	0.174	310.087	0.999
	Hotelling's Trace	0.211	155.044	2.000	1468.000	<.001	0.174	310.087	0.999
	Roy's Largest Root	0.211	155.044	2.000	1468.000	<.001	0.174	310.087	0.999

Description Edit

Multivariate tests of within-subjects effects. Wilks' Lambda is commonly reported; a significant result indicates that repeated measures differ across levels.

Mauchly's Test of Sphericity

Tests the null hypothesis that the error covariance matrix of the orthonormalized transformed dependent variables is proportional to an identity matrix. Design: Intercept; Within Subjects Design: tahun

Mauchly's Test of Sphericity

Copy SVG

Mauchly's Test of Sphericity								
Measure	Within Subjects Effect	Mauchly's W	Approx. Chi-Square	df	Sig.	Greenhouse-Geisser	Huynh-Feldt	Lower-bound
kepuasan_kerja	tahun	0.828	276.258	2	<.001	0.854	0.854	0.500

Description Edit

If significant (Sig. < .05), sphericity is violated and corrected degrees of freedom should be used.

Dengan nilai Sig. < 0,001 (lebih kecil dari $\alpha = 0{,}05$), keputusannya adalah tolak H_0, yang berarti skor kepuasan kerja karyawan berubah secara signifikan selama tiga tahun pengukuran berturut-turut.

MODUL TIME SERIES

Pengantar

Panduan ini dibuat sebagai dokumentasi penggunaan aplikasi Statify modul analisis time series yang terbagi atas beberapa menu antara lain, menu Homoscadascity Test, Heteroscadascity Model, menu Error Correection Model (ECM), dan menu Autoreggresive Lag Distributed (ARDL). Adapun pada bagian selanjutnya akan dijelaskan mengenai rincian panduan penggunaan dari masing-masing menu analisis time series lanjutan.

Proses Input Data

1. Tahapan Input Data

Ikuti langkah-langkah berikut.

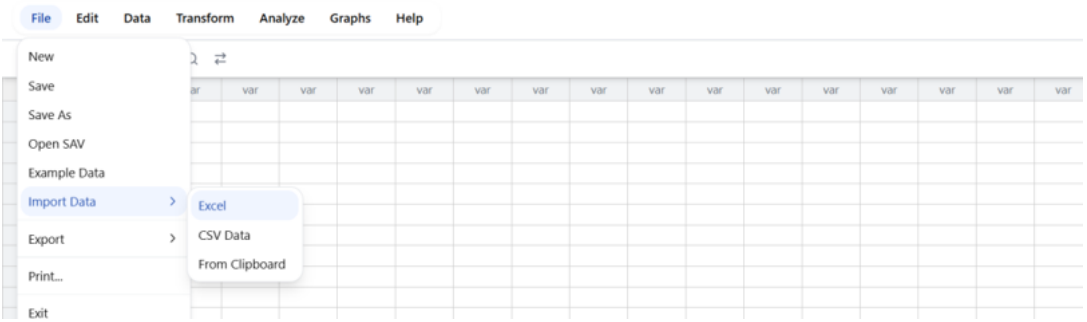
1. Unduh data berikut

   Data Penumpang.xlsx.

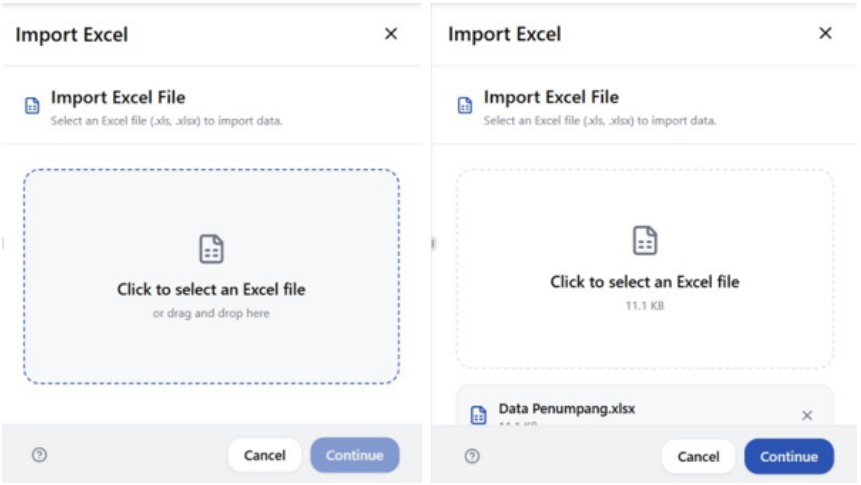
2. Buka situs web Statify

   https://statify-dev.student.stis.ac.id/dashboard/data.

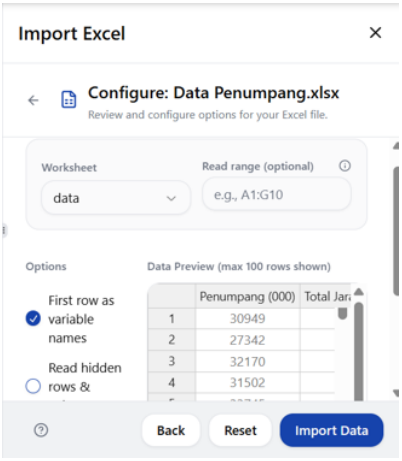
3. Klik File → Import Data → Excel pada navbar Statify



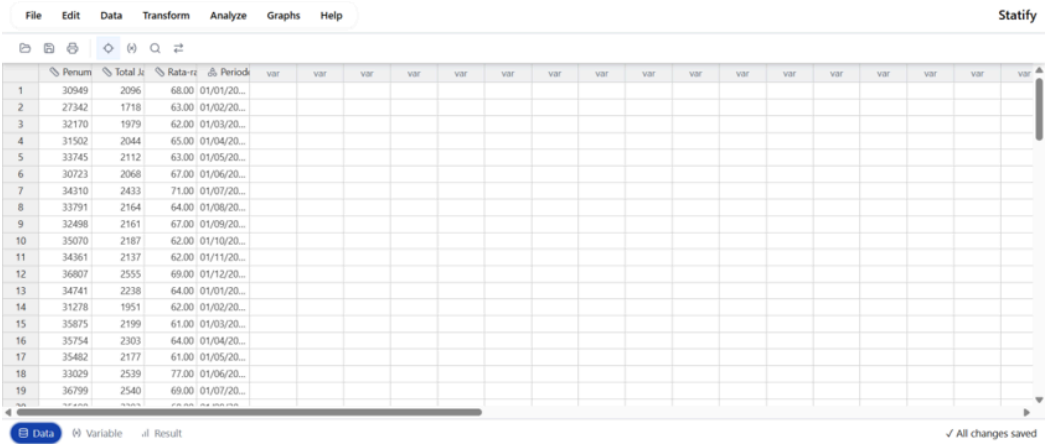
4. Klik untuk memilih file excel yang hendak diimpor



5. Klik continue untuk melanjutkan.



6. Gunakan konfigurasi *default*-nya saja lalu klik Import Data.



7. Pastikan data yang masuk sudah diimpor dengan benar.

8. Data sudah siap digunakan untuk melakukan analisis *time series* pada tahapan-tahapan berikutnya.

Keterangan Data

Data yang digunakan adalah data penumpang kereta api nasional bulanan periode Januari 2017 hingga Desember 2024 dengan jumlah sembilan puluh enam observasi yang terdiri atas empat variabel sebagai berikut.

1. Penumpang (000) : Total penumpang kereta api nasional dalam satuan ribu.
2. TJTP (000.000 km) : Total jarak tempuh penumpang dalam satuan ratusan ribu kilometer.
3. RJP (km) : Rata-rata jarak perjalanan per penumpang dalam satuan kilometer.
4. Periode : Periode data per bulan.

Data bersumber dari *website* resmi Badan Pusat Statistik (BPS) dari *link* berikut :

https://www.bps.go.id/id/statistics-table/2/MjM1MyMy/penumpang-angkutan-kereta-api-nasional-bulanan-.html

Heteroscadascity Models

2. Tahapan Menggunakan Menu Heteroscedasticity Models

Menu Heteroscedasticity Models digunakan untuk mengestimasi model volatilitas bersyarat (conditional volatility) pada suatu seri data. Menu ini mendukung lima spesifikasi model: GARCH (Standard), EGARCH (Exponential), TGARCH (Threshold/GJR), ARCH (Autoregressive Conditional Heteroscedasticity), dan IGARCH (Integrated GARCH).

Skenario analisis:

Untuk mendemonstrasikan model ARCH/GARCH, kita akan menggunakan variabel Penumpang (000) sebagai seri yang akan dianalisis volatilitasnya terutama untuk melihat clustering volatilitas yang terjadi akibat dampak pandemi COVID-19.

Catatan penting:

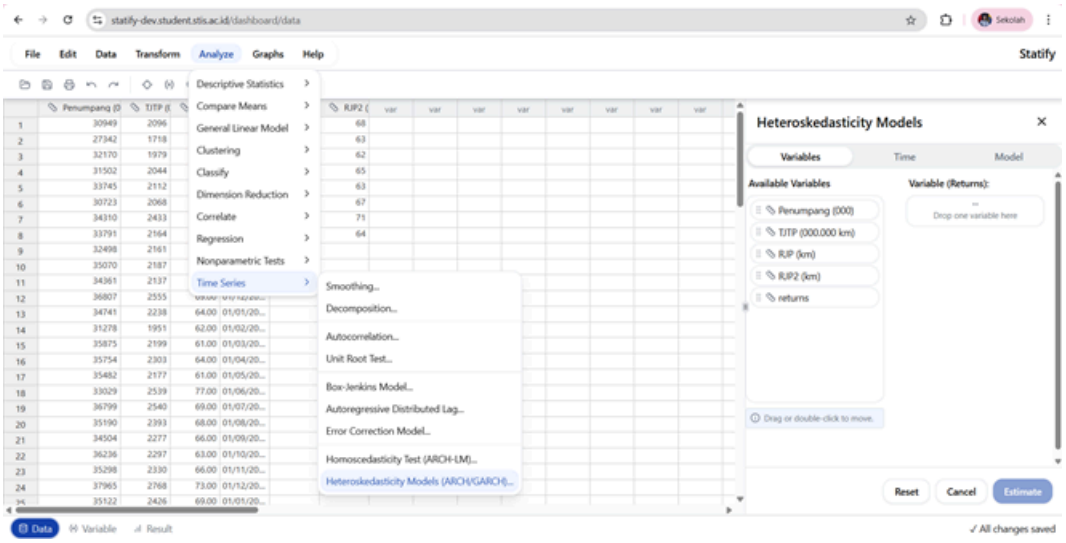
Menu ini menerima **satu variabel** saja sebagai input. Konstanta pada mean equation (C/μ) sudah disertakan secara otomatis oleh sistem, setara dengan spesifikasi variabel c pada software EViews.

2.1. GARCH (Standard)

Model GARCH(p,q) standar mengestimasi varians bersyarat menggunakan lag dari squared residual (efek ARCH) dan lag dari conditional variance (efek GARCH).

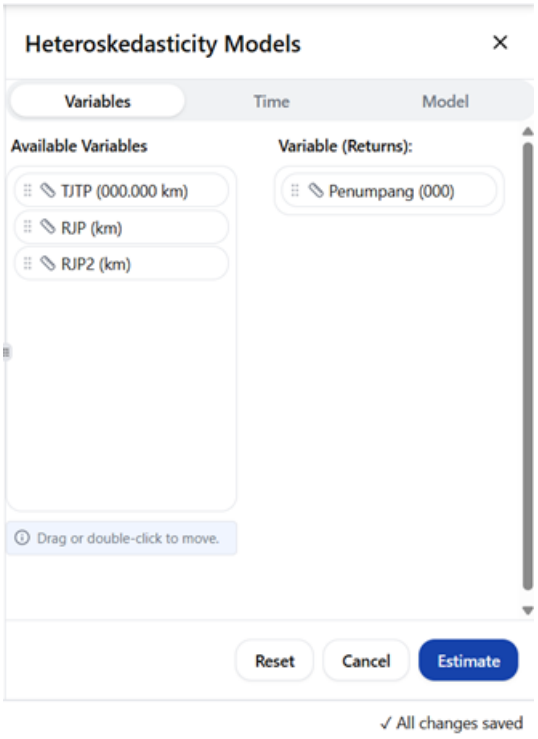
Ikuti langkah-langkah berikut.

1. Klik Analyze → Time Series → Heteroscedasticity Models untuk masuk ke menu.

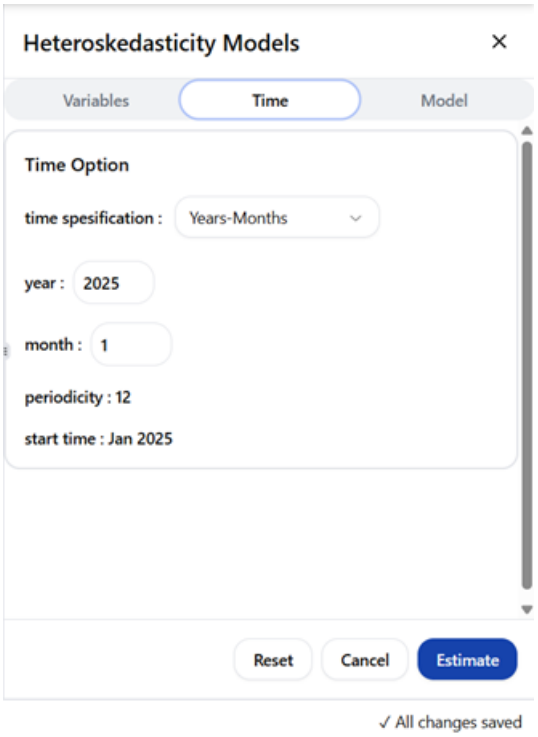


2. Pada tab Variables, pilih variabel yang akan digunakan:

Pindahkan variabel Penumpang (000) ke kolom Selected Variable.



3. Pilih tab Time untuk menyesuaikan periode waktu.

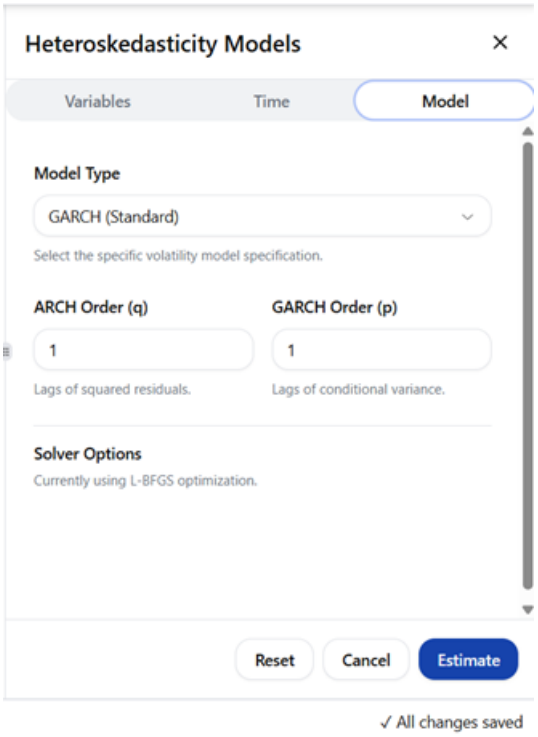


4. Pilih tab Model untuk mengatur spesifikasi model:

Model Type: GARCH (Standard)

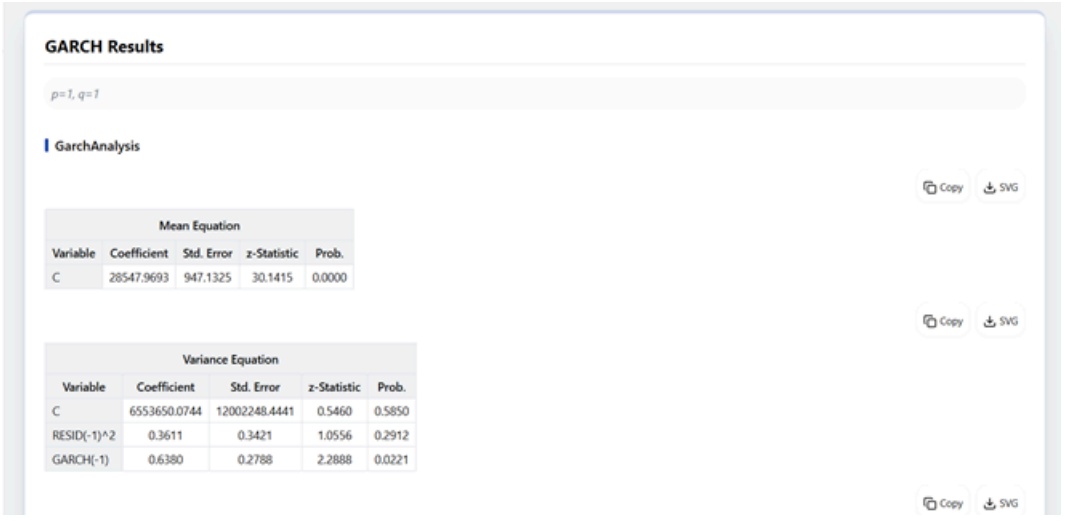
ARCH Order (q): 1 — jumlah lag squared residuals

GARCH Order (p): 1 — jumlah lag conditional variance



5. Setelah itu klik Estimate.

Selanjutnya Anda akan dipindahkan ke halaman Result dan Anda dapat melihat output GARCH(1,1) yang terdiri atas beberapa tabel berikut. Mean equation GARCH menggunakan z-Statistic (bukan t-Statistic) karena estimasi menggunakan metode Maximum Likelihood (MLE).



Diagnostics	
Statistic	**Value**
R-squared	-0.0000
Adjusted R-squared	-0.0000
S.E. of regression	10651.4430
Sum squared resid	10778057536.9063
Log likelihood	-996.6165
Durbin-Watson stat	0.0926
Mean dependent var	28547.9688
S.D. dependent var	10651.4430
Akaike info criterion	20.8462
Schwarz criterion	20.9530
Hannan-Quinn criter.	20.8894

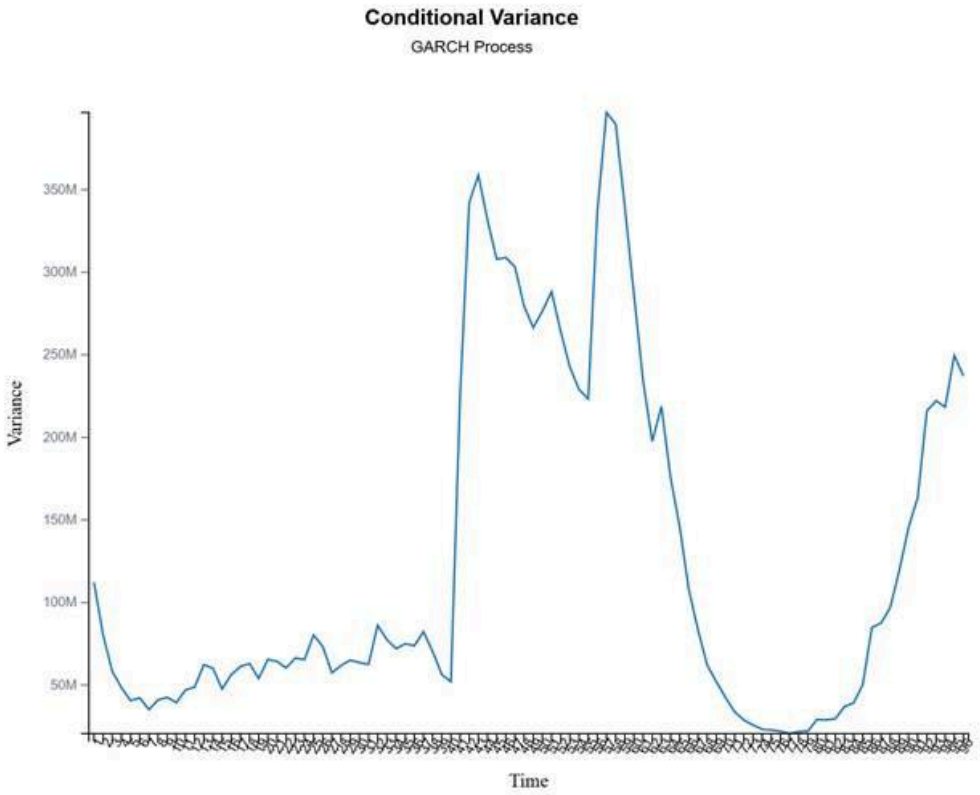
Interpretasi:

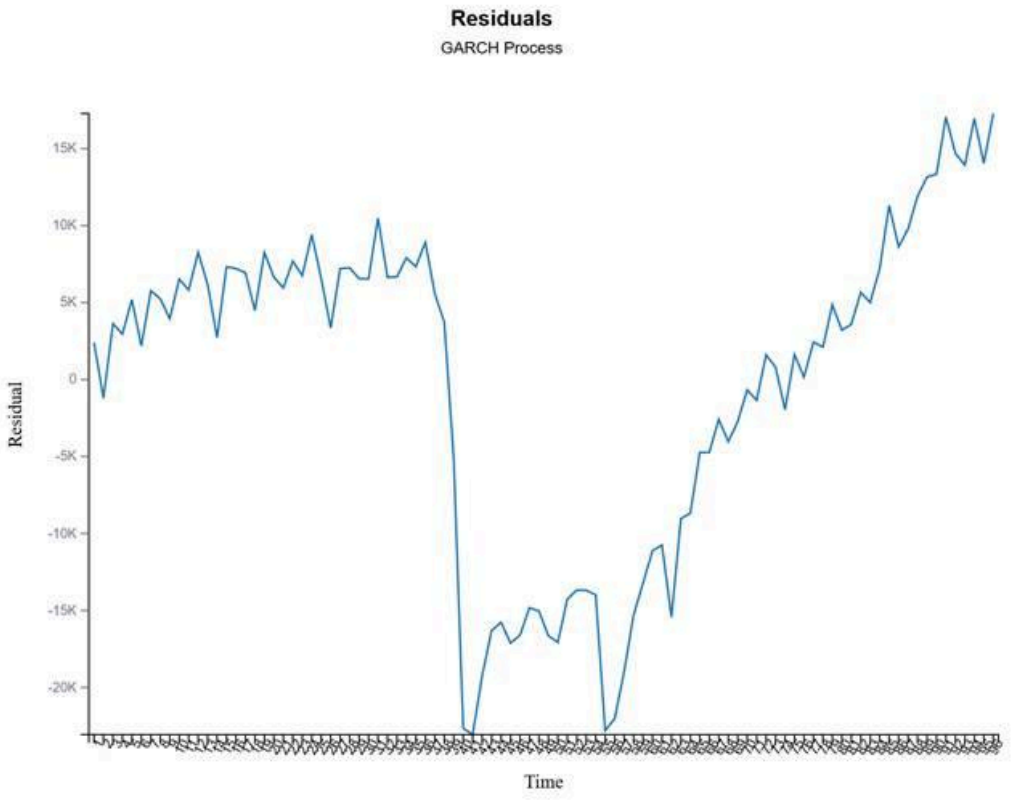
α adalah RESID(-1)^2 dan β adalah GARCH(-1). Nilai α + β menunjukkan persistensi volatilitas. Apabila α + β mendekati 1, maka volatilitas memiliki persistensi yang sangat tinggi (mendekati IGARCH). Untuk data penumpang yang dipengaruhi pandemi, nilai ini cenderung tinggi karena shock pandemi bersifat persisten.

Grafik yang dihasilkan:

Conditional Variance : menampilkan estimasi varians bersyarat dari waktu ke waktu.

Residuals : menampilkan residual dari mean equation.

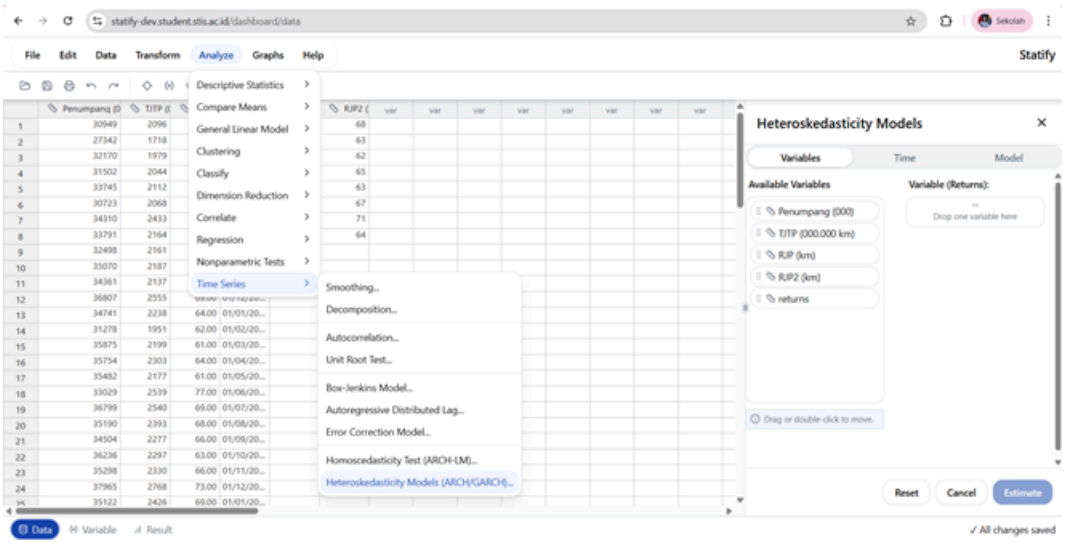




2.2. ARCH

Model ARCH murni (tanpa komponen GARCH) mengestimasi varians bersyarat hanya menggunakan lag dari squared residual. Model ini cocok untuk volatilitas dengan memori pendek. Ikuti langkah-langkah berikut.

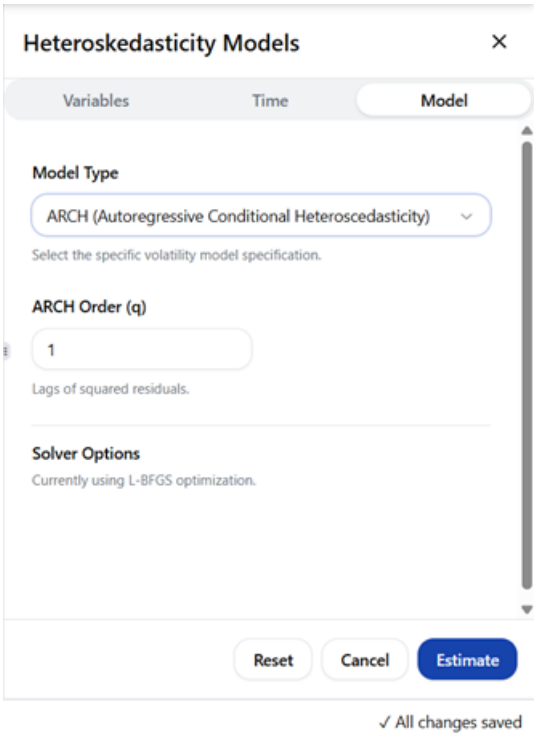
1. Klik Analyze → Time Series → Heteroscedasticity Models untuk masuk ke menu.



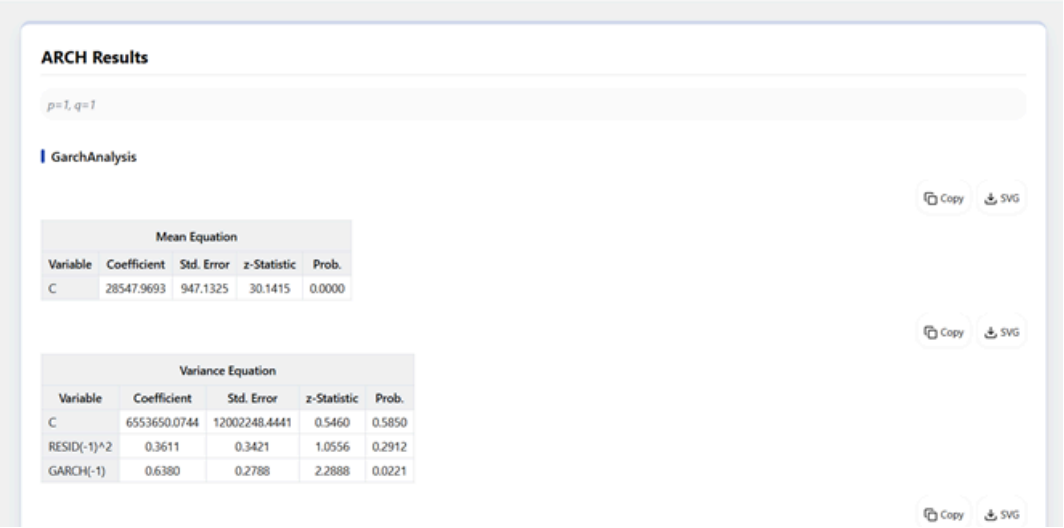
2. Konfigurasi variabel tidak perlu dilakukan.
3. Pilih tab Model:

Model Type: ARCH (Autoregressive Conditional Heteroscedasticity)

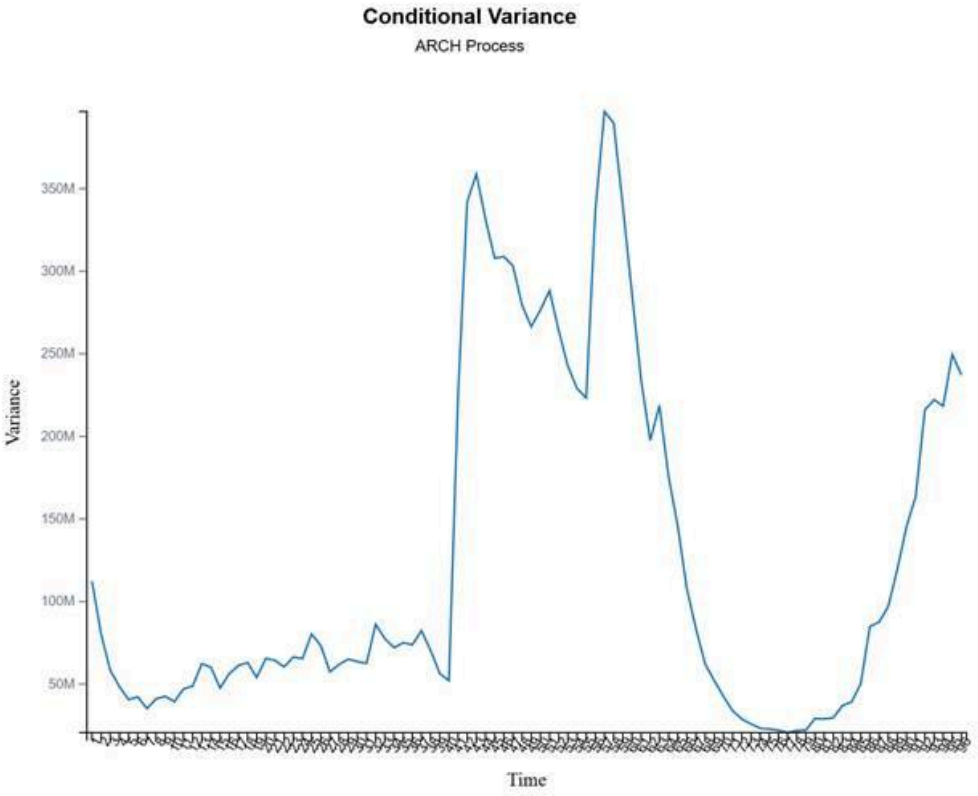
ARCH Order (q): 1 (GARCH Order tidak diperlukan untuk model ARCH murni)

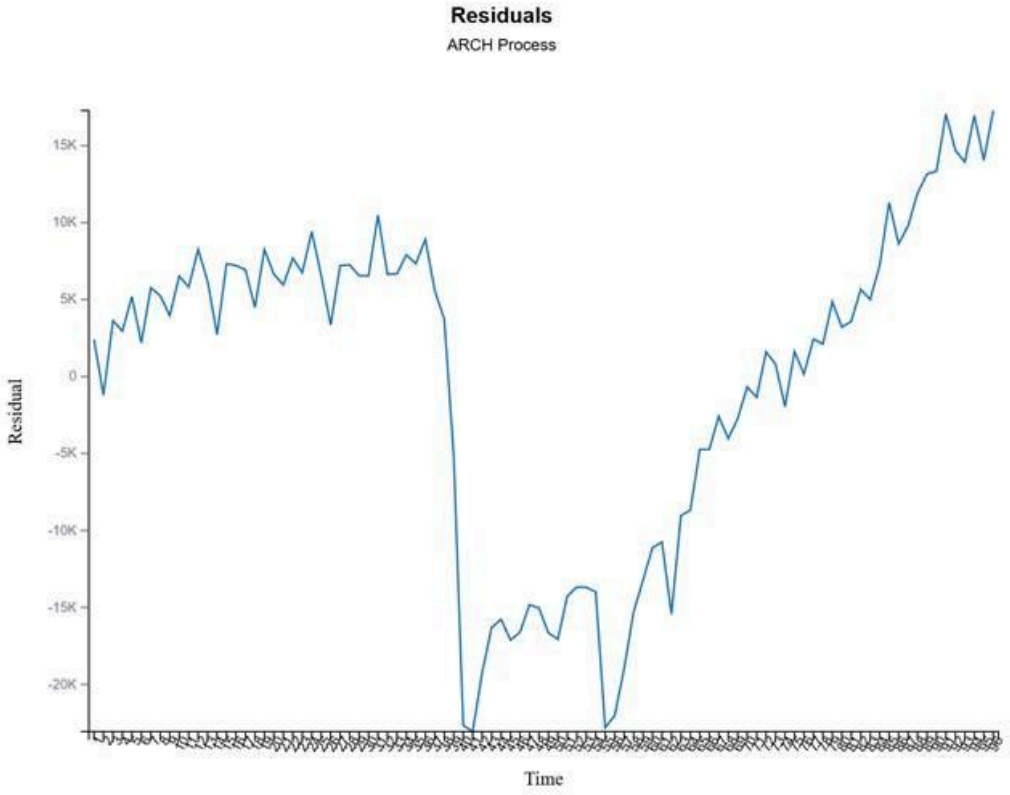


4. Setelah itu klik Estimate.
5. Output ARCH(0,1) terdiri atas beberapa tabel berikut.





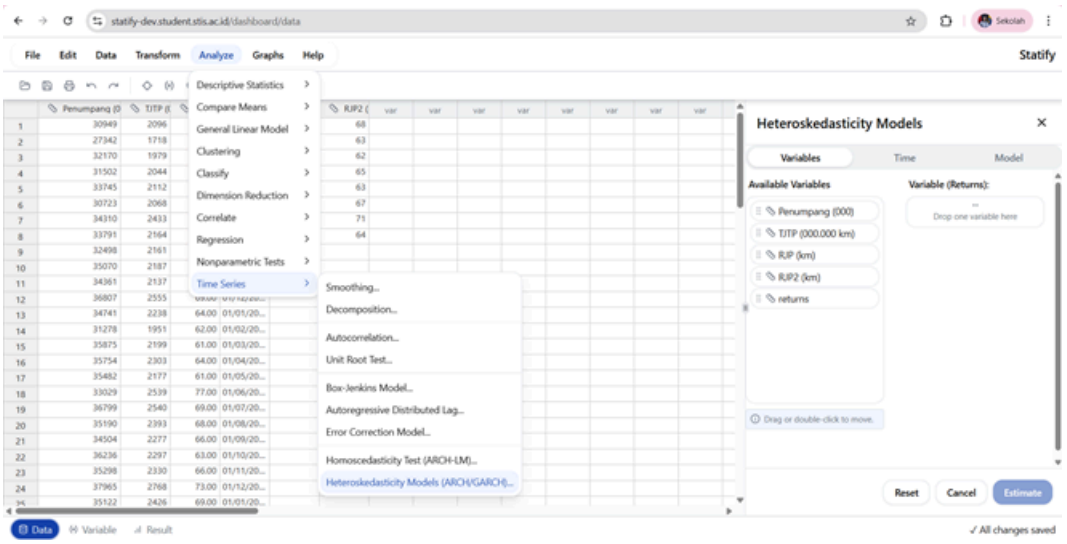




2.3. EGARCH (Exponential)

Model EGARCH menangkap efek asimetri volatilitas (leverage effect), di mana berita buruk menghasilkan volatilitas lebih besar daripada berita baik dengan magnitude yang sama. Model EGARCH bekerja pada log dari conditional variance, sehingga selalu menghasilkan varians positif. Ikuti langkah-langkah berikut.

1. Klik Analyze → Time Series → Heteroscedasticity Models untuk masuk ke menu.

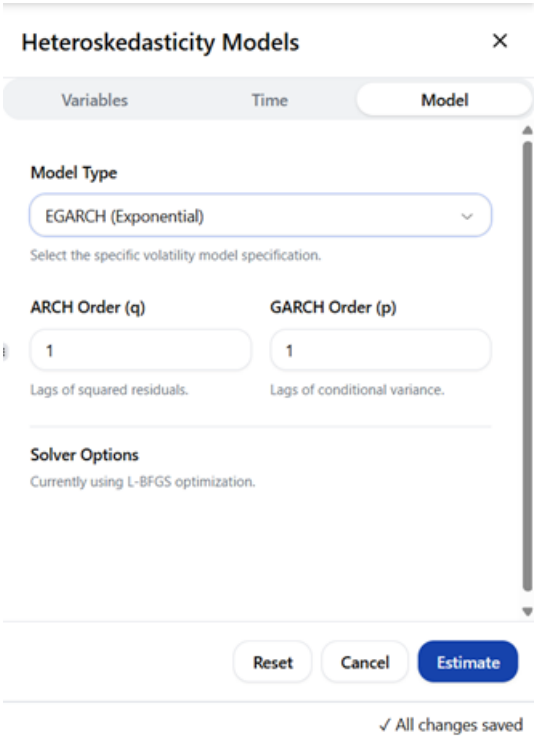


2. Konfigurasi variabel tidak perlu dilakukan karena aplikasi menyimpan hasil konfigurasi sebelumnya.
3. Pilih tab Model untuk mengubah spesifikasi model:

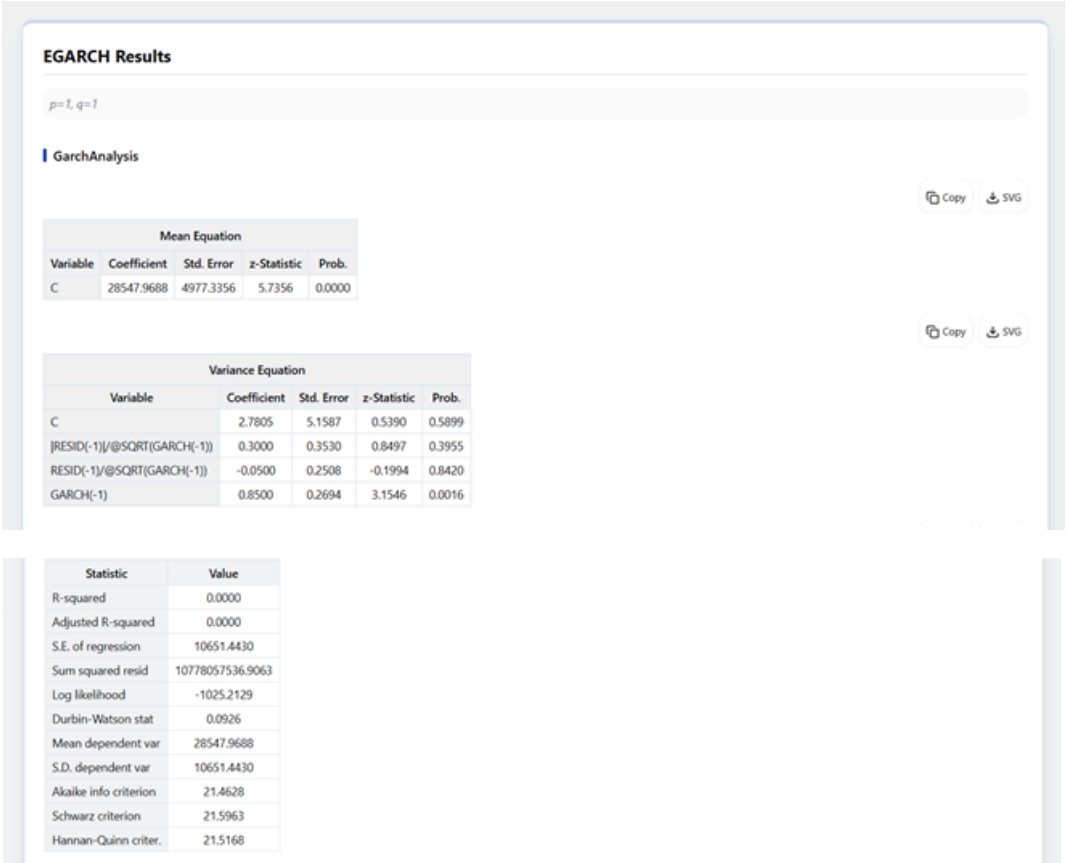
Model Type: EGARCH (Exponential)

ARCH Order (q): 1

GARCH Order (p): 1



4. Setelah itu klik Estimate.
5. Output EGARCH(1,1) terdiri atas beberapa tabel berikut.



EGARCH Results

p=1, q=1

GarchAnalysis

Copy SVG

Mean Equation

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	28547.9688	4977.3356	5.7356	0.0000

Copy SVG

Variance Equation

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	2.7805	5.1587	0.5390	0.5899
|RESID(-1)|/@SQRT(GARCH(-1))	0.3000	0.3530	0.8497	0.3955
RESID(-1)/@SQRT(GARCH(-1))	-0.0500	0.2508	-0.1994	0.8420
GARCH(-1)	0.8500	0.2694	3.1546	0.0016

Statistic	Value
R-squared	0.0000
Adjusted R-squared	0.0000
S.E. of regression	10651.4430
Sum squared resid	10778057536.9063
Log likelihood	-1025.2129
Durbin-Watson stat	0.0926
Mean dependent var	28547.9688
S.D. dependent var	10651.4430
Akaike info criterion	21.4628
Schwarz criterion	21.5963
Hannan-Quinn criter.	21.5168

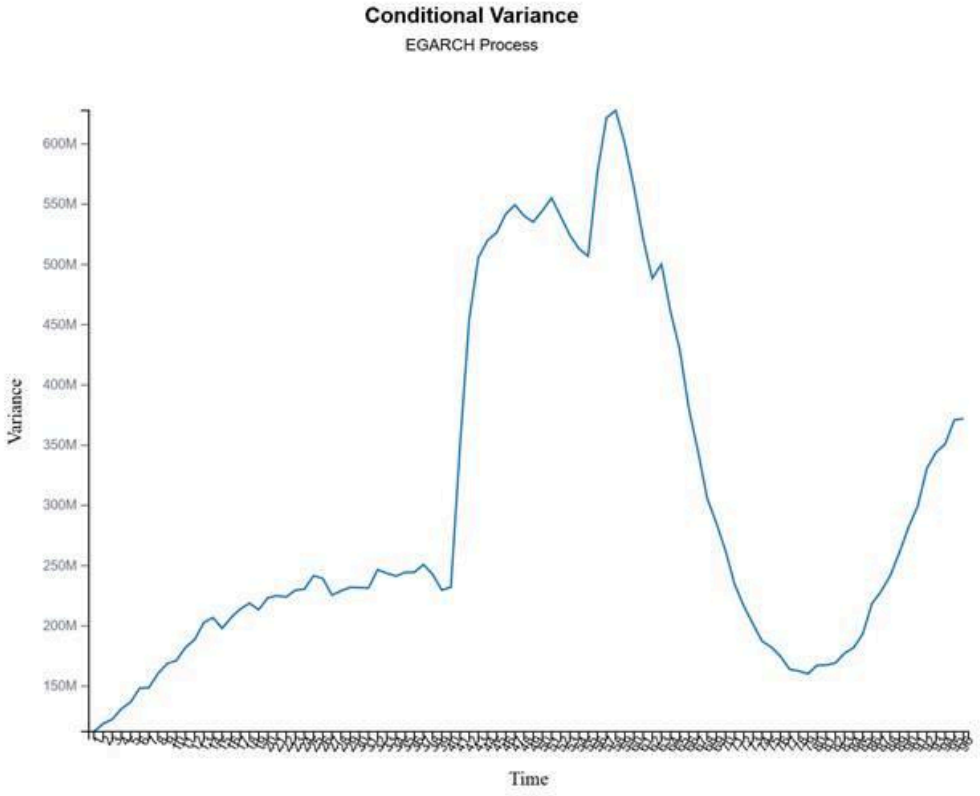
|RESID(-1)|/@SQRT(GARCH(-1)) adalah α

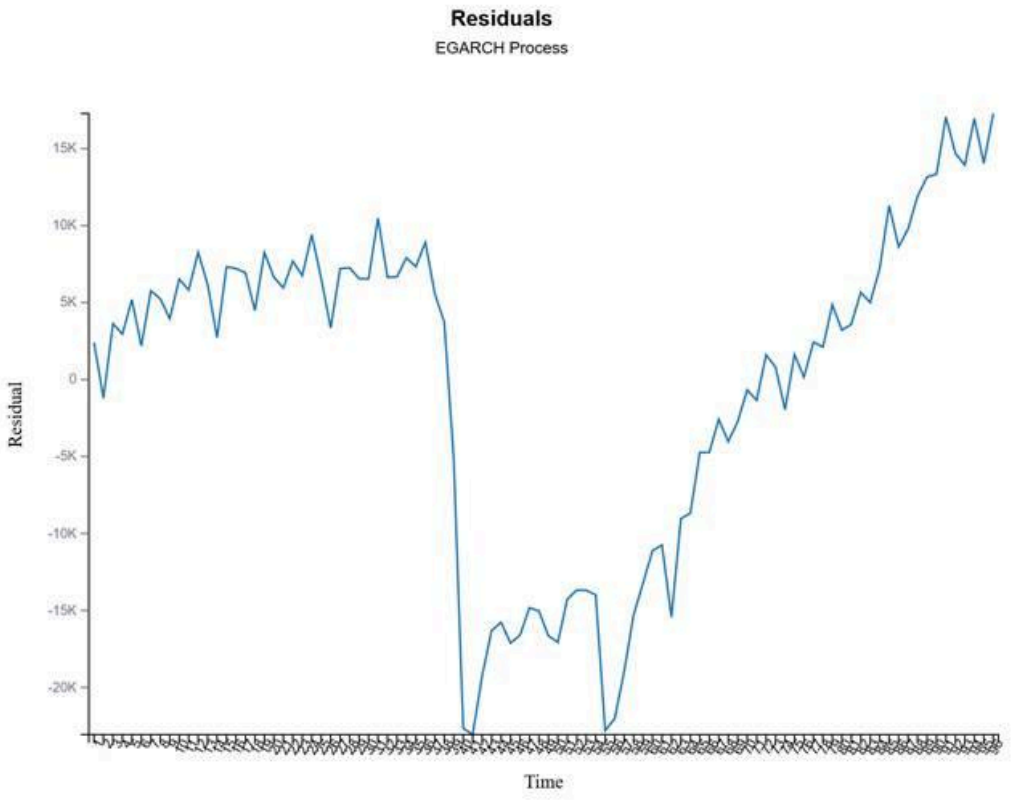
RESID(-1)/@SQRT(GARCH(-1)) adalah γ

EGARCH(-1) adalah β

Interpretasi:

Apabila γ signifikan dan negatif, maka terdapat leverage effect yang menghasilkan volatilitas lebih tinggi. Untuk data penumpang, gamma negatif bermakna penurunan penumpang mengakibatkan ketidakpastian yang lebih besar.



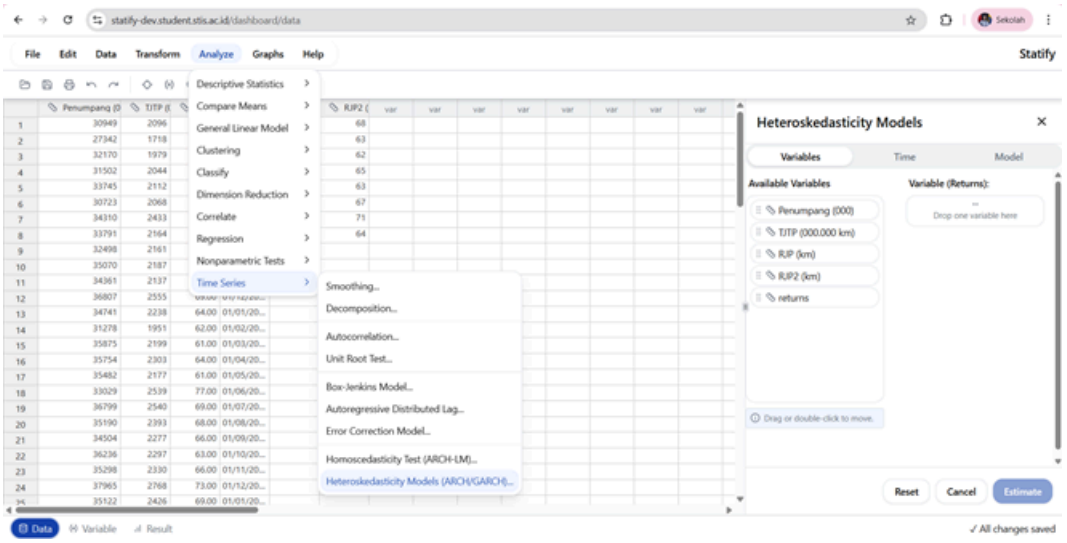


2.4. TGARCH (Threshold/GJR)

Model TGARCH (juga dikenal sebagai GJR-GARCH) menambahkan threshold variable yang aktif hanya ketika residual bernilai negatif, sehingga memungkinkan asimetri dalam dampak shock positif dan negatif terhadap volatilitas.

Ikuti langkah-langkah berikut.

1. Klik Analyze → Time Series → Heteroscedasticity Models untuk masuk ke menu.

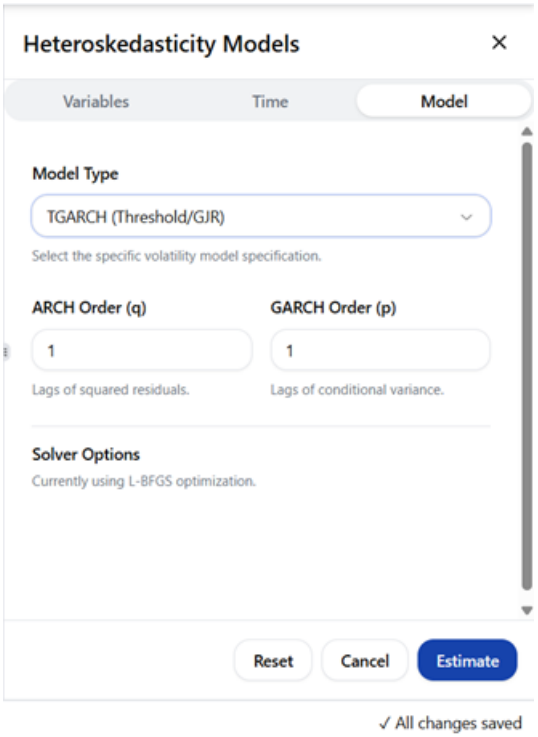


2. Konfigurasi variabel tidak perlu dilakukan.
3. Pilih tab Model:

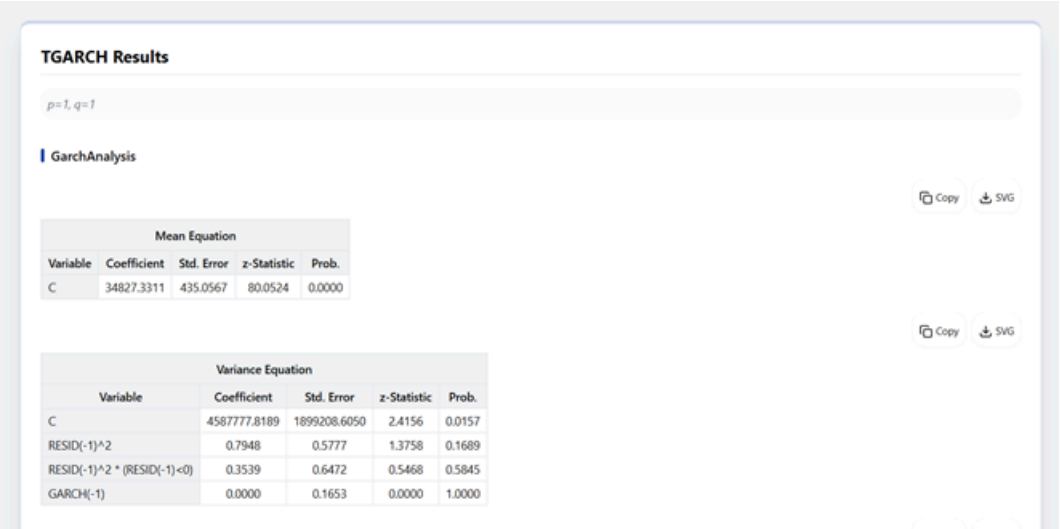
Model Type: TGARCH (Threshold/GJR)

ARCH Order (q): 1

GARCH Order (p): 1



4. Setelah itu klik Estimate.
5. Output TGARCH(1,1) terdiri atas beberapa tabel berikut.



Diagnostics	
Statistic	**Value**
R-squared	-0.3512
Adjusted R-squared	-0.3512
S.E. of regression	12381.3847
Sum squared resid	14563375165.8442
Log likelihood	-966.3308
Durbin-Watson stat	0.0685
Mean dependent var	28547.9688
S.D. dependent var	10651.4430
Akaike info criterion	20.2361
Schwarz criterion	20.3696
Hannan-Quinn criter.	20.2900

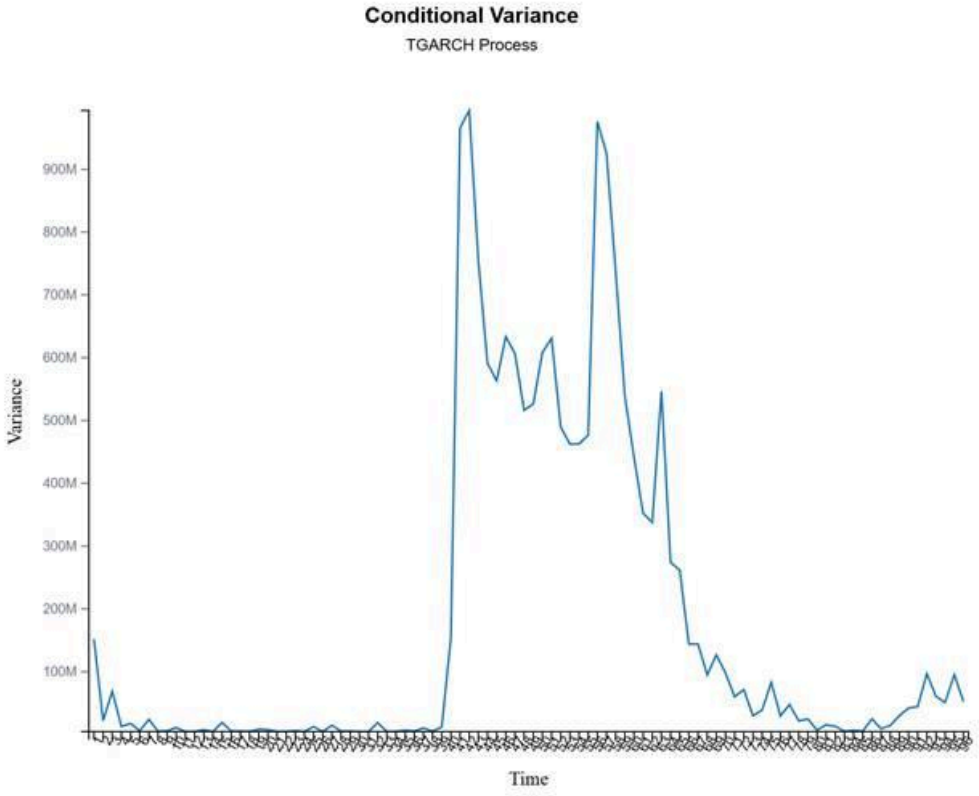
RESID(-1)^2 adalah α

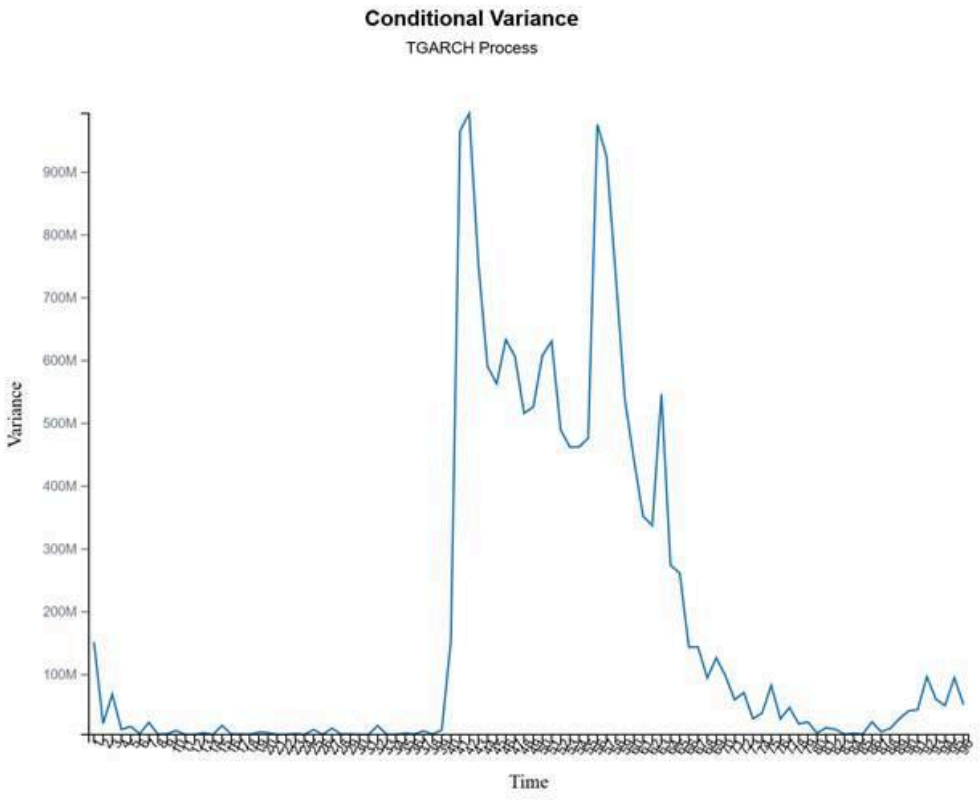
RESID(-1)^2 * (RESID(-1)<0) adalah γ

GARCH(-1) adalah β

Interpretasi:

Apabila γ signifikan dan positif, terdapat leverage effect yaitu shock negatif menghasilkan efek ARCH sebesar (α + γ), sedangkan shock positif hanya sebesar α.



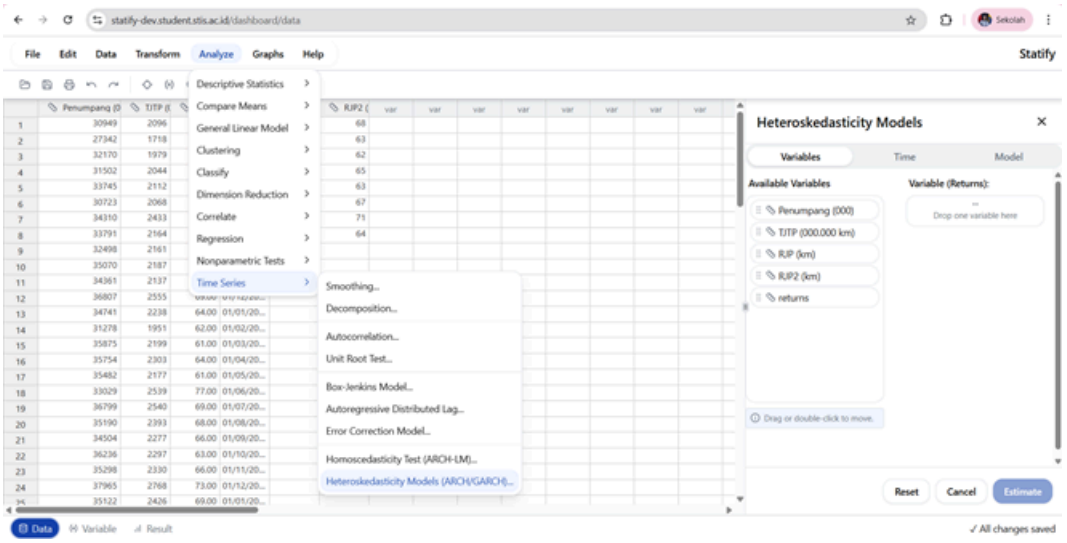


2.5. IGARCH (Integrated GARCH)

Model IGARCH adalah kasus khusus GARCH dengan constraint $\alpha + \beta = 1$, yang berarti volatilitas memiliki persistensi tak terbatas (unit root dalam variance). Model ini sering sesuai untuk seri finansial atau data dengan structural break seperti dampak pandemi.

Ikuti langkah-langkah berikut.

1. Klik Analyze → Time Series → Heteroscedasticity Models untuk masuk ke menu.

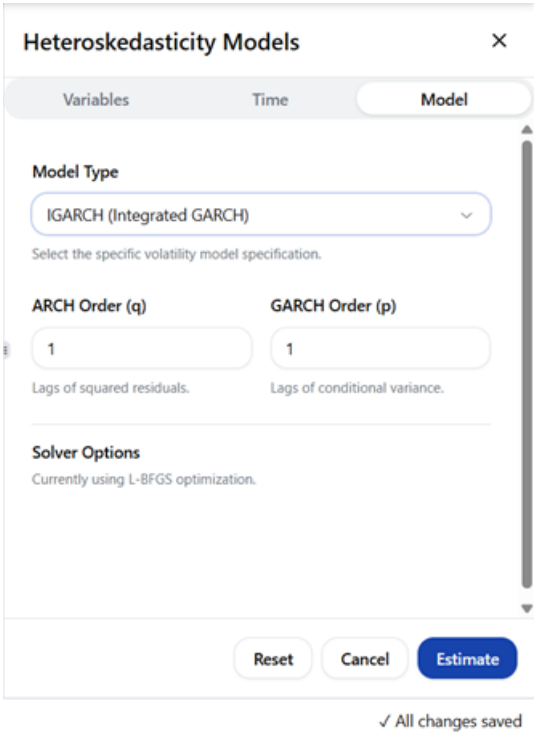


2. Konfigurasi variabel tidak perlu dilakukan.
3. Pilih tab Model:

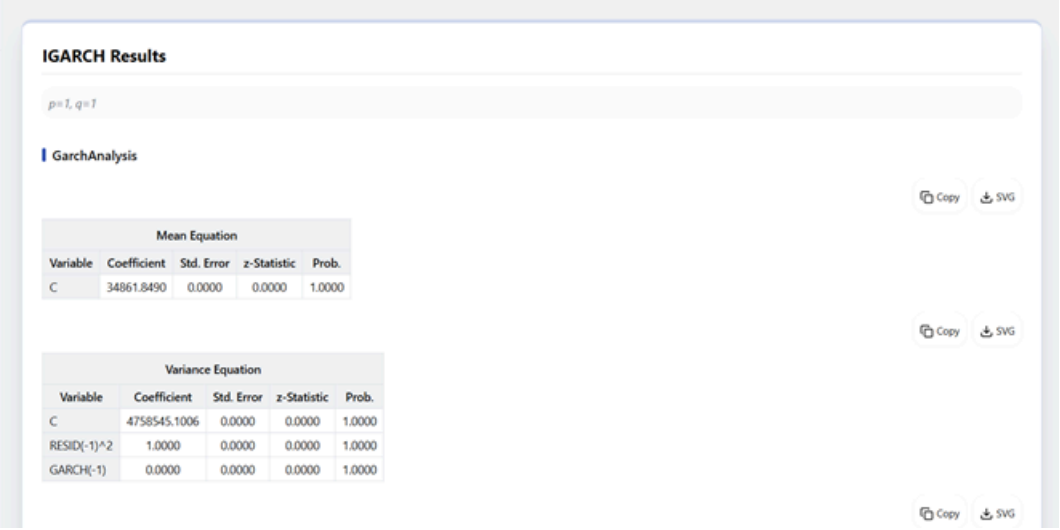
Model Type: IGARCH (Integrated GARCH)

ARCH Order (q): 1

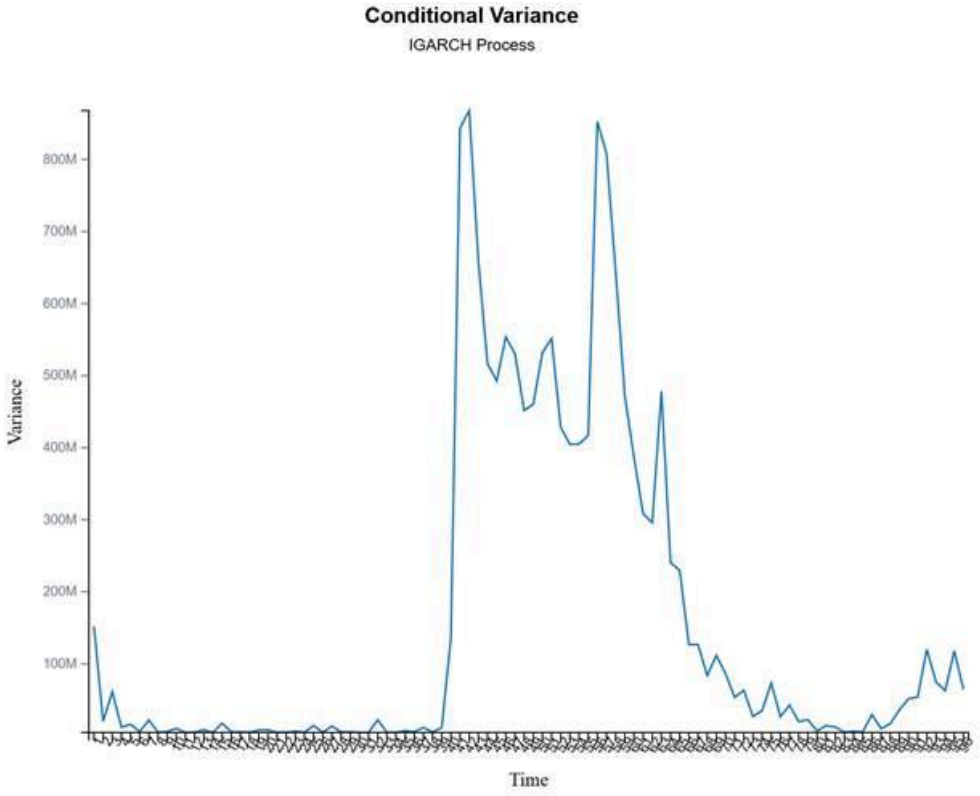
GARCH Order (p): 1

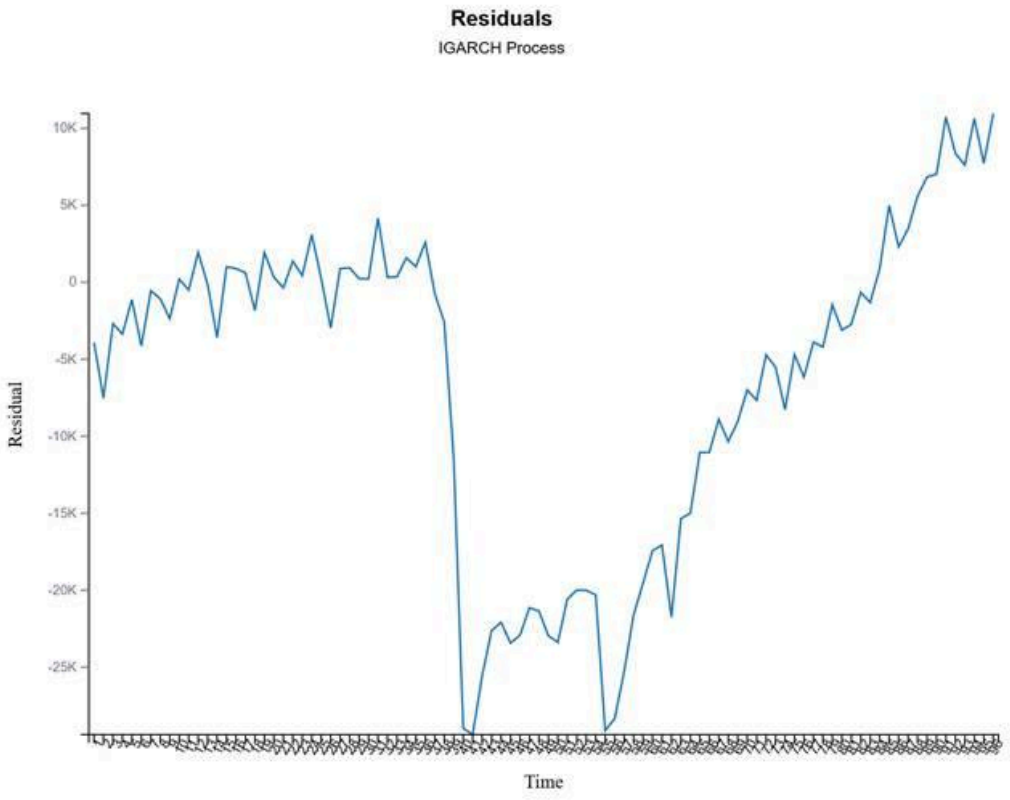


4. Setelah itu klik Estimate.
5. Output TGARCH(1,1) terdiri atas beberapa tabel berikut.



Diagnostics	
Statistic	**Value**
R-squared	-0.3551
Adjusted R-squared	-0.3551
S.E. of regression	12399.1110
Sum squared resid	14605105585.7013
Log likelihood	-966.4775
Durbin-Watson stat	0.0683
Mean dependent var	28547.9688
S.D. dependent var	10651.4430
Akaike info criterion	20.1974
Schwarz criterion	20.2776
Hannan-Quinn criter.	20.2298





3. Validasi Menu

Berikut beberapa validasi dari konfigurasi menu Heteroscedasticity Models.

1. Peringatan belum memilih variabel

   Apabila pengguna menekan tombol Estimate tanpa memilih variabel, maka akan muncul notifikasi:

   "Please select at least one variable"

2. Peringatan data tidak mencukupi

   Apabila jumlah data yang valid kurang dari 10 observasi, maka akan muncul notifikasi:

   "Insufficient data points (minimum 10 required)"

3. Peringatan estimasi gagal konvergen

   Apabila algoritma L-BFGS tidak berhasil menemukan solusi optimal (misalnya karena data terlalu singkat atau spesifikasi model tidak sesuai), maka akan muncul notifikasi error dari worker. Coba kurangi orde p dan q, atau gunakan model yang lebih sederhana

ARDL (Autoregressive Distributed Lag)

4. Tahapan Menggunakan Menu ARDL

   4.1. Tahapan

Menu ARDL digunakan untuk mengestimasi hubungan jangka panjang dan jangka pendek antara variabel dependen dengan satu atau lebih variabel independen menggunakan pendekatan Engle-Granger dua tahap. Menu ini menghasilkan persamaan ARDL tak terbatas (*unrestricted*),

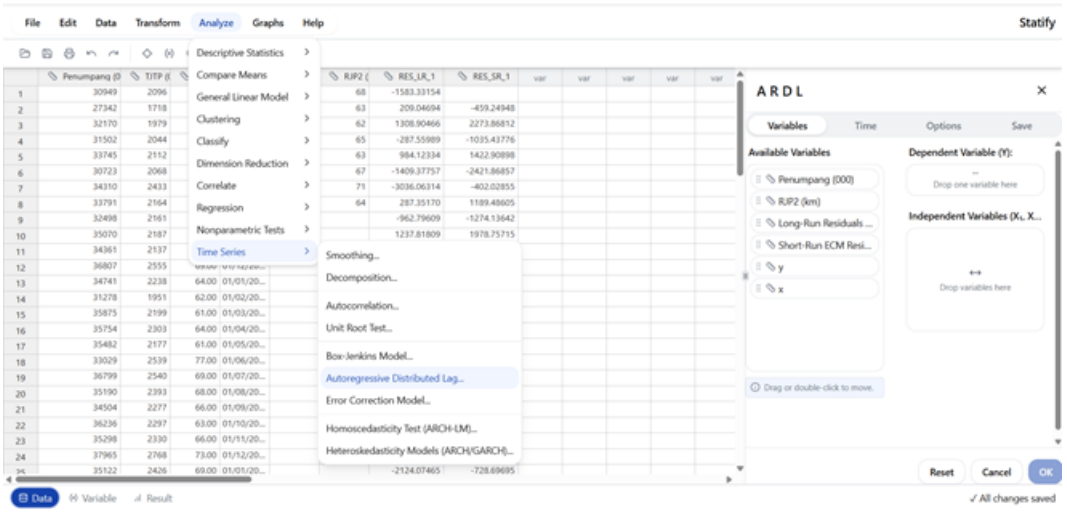
persamaan jangka panjang, uji kointegrasi, persamaan jangka pendek (ARDL-ECM), correlogram residual, uji asumsi klasik, dan interpretasi otomatis.

Skenario analisis:

Pada panduan ini, kita akan menganalisis pengaruh Total Jarak Tempuh Penumpang (TJTP) dan Rata-rata Jarak Perjalanan (RJP) terhadap jumlah Penumpang kereta api nasional dengan menggunakan model ARDL.

Ikuti langkah-langkah berikut.

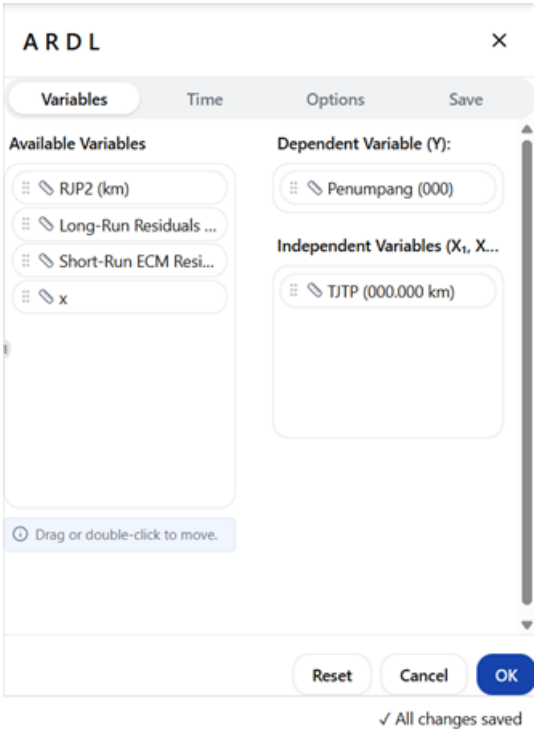
1. Klik Analyze → Time Series → ARDL untuk masuk ke menu ARDL.



2. Pada tab Variables, pilih variabel yang akan digunakan:

Pindahkan variabel Penumpang (000) ke kolom Dependent Variable (variabel dependen/Y).

Pindahkan variabel TJTP (000.000 km) dan RJP (km) ke kolom Independent Variables (variabel independen/X).



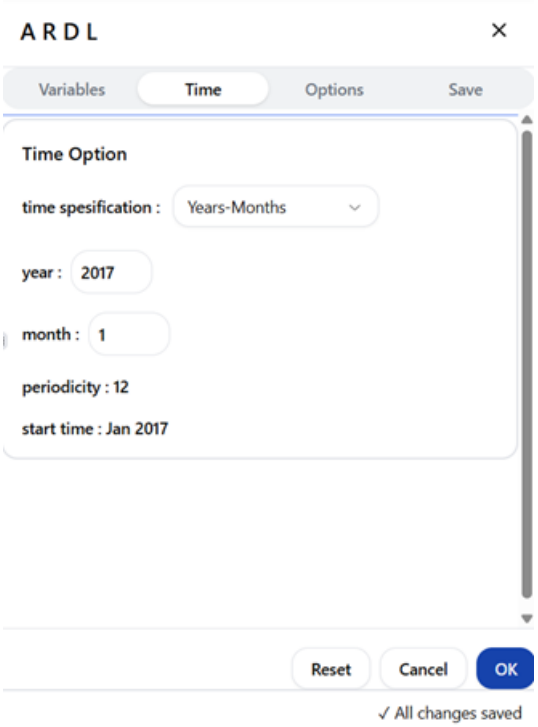
Selain *drag and drop*, anad juga bisa klik nama variabel di daftar kiri, lalu klik tombol panah (→) untuk memindahkannya ke kotak yang sesuai.

3. Pilih tab Time untuk menyesuaikan periode waktu. Atur konfigurasi sebagai berikut:

Frequency: Monthly (Bulanan)

Start Period: Januari 2017

End Period: Desember 2024



Sebagai catatan: konfigurasi waktu untuk menu time series cukup dilakukan sekali saja karena sudah terintegrasi untuk setiap menu time series.

4. Pilih tab Options untuk mengatur orde lag model ARDL.

Tab Options kini memiliki dua mode pemilihan lag:

Mode A — Automatic Lag Selection (Direkomendasikan)

Centang kotak Automatic Lag Selection (Recommended like EViews) untuk mengaktifkan pemilihan lag otomatis. Pada mode ini, Statify akan mengevaluasi semua kombinasi model ARDL dari orde 1 hingga batas maksimum yang ditentukan, kemudian memilih model terbaik berdasarkan kriteria informasi yang dipilih.

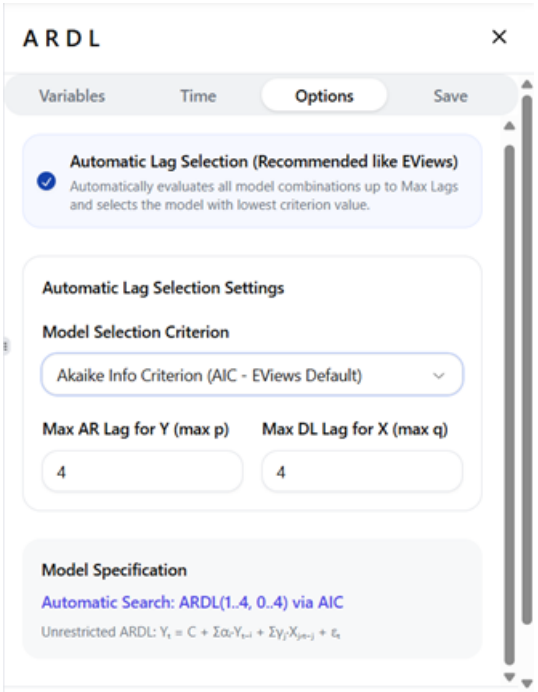
Atur parameter berikut:

Model Selection Criterion: Akaike Info Criterion (AIC - EViews Default) *(atau BIC/HQ)*

Max AR Lag for Y (max p): 4 — batas atas lag variabel dependen yang dievaluasi

Max DL Lag for X (max q): 4 — batas atas lag variabel independen yang dievaluasi

Pada mode ini, Statify akan menampilkan notifikasi model terpilih, misalnya: ARDL(2, 1, 0) via AIC — artinya model dengan p=2 untuk Y, q_1=1 untuk TJTP, q_2=0 untuk RJP.



Mode B — Manual Fixed Lag Orders

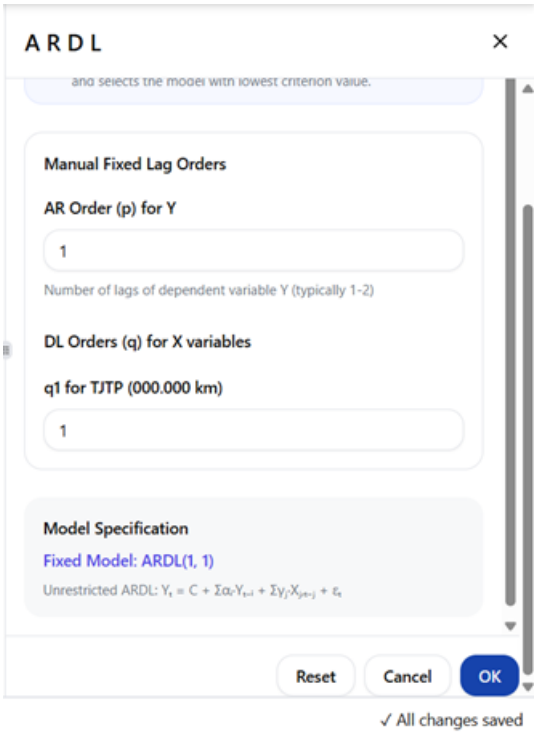
Jika kotak Auto Select tidak dicentang, Anda dapat menentukan orde lag secara manual:

AR Order (p) for Y: 1 — jumlah lag dari variabel dependen

q1 for TJTP (000.000 km): 1 — jumlah lag dari TJTP

q2 for RJP (km): 1 — jumlah lag dari RJP

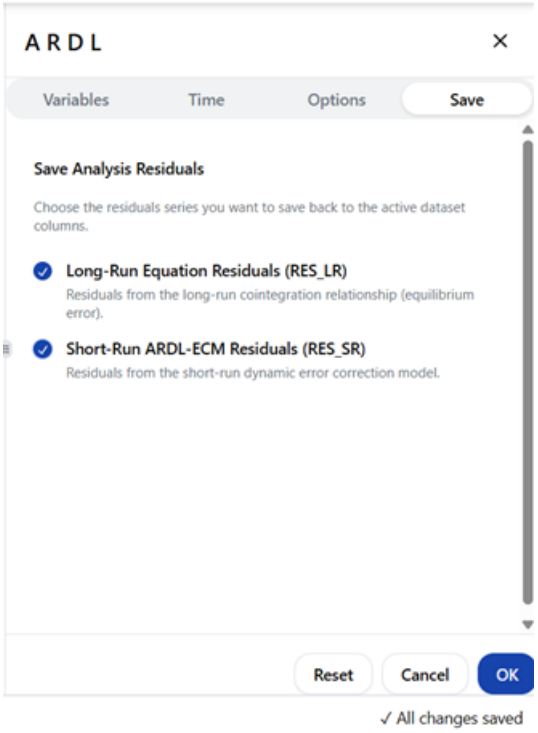
Di bagian bawah tab Options, terdapat kotak Model Specification yang menampilkan pratinjau spesifikasi model, misalnya: Fixed Model: ARDL(1, 1, 1) atau Automatic Search: ARDL(1..4, 0..4) via AIC.



5. Pilih tab Save jika ingin menyimpan residual ke dataset:

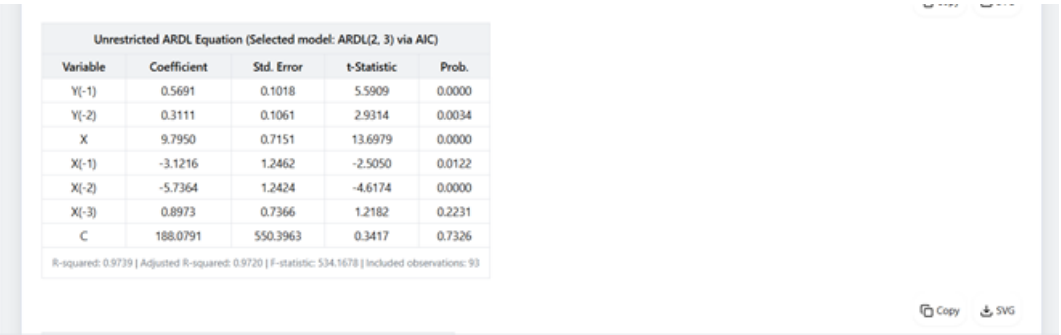
Long-Run Equation Residuals (RES_LR): centang untuk menyimpan residual jangka panjang (equilibrium error).

Short-Run ARDL-ECM Residuals (RES_SR): centang untuk menyimpan residual jangka pendek.



Menyimpan residual berguna untuk analisis lanjutan, seperti uji ARCH-LM pada menu Homoscedasticity Test.

6. Setelah itu klik OK.
7. Selanjutnya Anda akan dipindahkan ke halaman Result dan Anda dapat melihat output ARDL yang terdiri atas sembilan tabel dan tiga grafik berikut.



Unrestricted ARDL Equation (Selected model: ARDL(2, 3) via AIC)

Variable	Coefficient	Std. Error	t-Statistic	Prob.
Y(-1)	0.5691	0.1018	5.5909	0.0000
Y(-2)	0.3111	0.1061	2.9314	0.0034
X	9.7950	0.7151	13.6979	0.0000
X(-1)	-3.1216	1.2462	-2.5050	0.0122
X(-2)	-5.7364	1.2424	-4.6174	0.0000
X(-3)	0.8973	0.7366	1.2182	0.2231
C	188.0791	550.3963	0.3417	0.7326

R-squared: 0.9739 | Adjusted R-squared: 0.9720 | F-statistic: 534.1678 | Included observations: 93

Copy SVG

Tabel diatas menampilkan persamaan ARDL tak terbatas (*baseline model*) yang menjadi dasar estimasi jangka panjang dan jangka pendek. Apabila Auto Select aktif, judul tabel akan mencantumkan nama model terpilih dan kriteria yang digunakan, misalnya: Unrestricted ARDL Equation (Selected model: ARDL(2,1,0) via AIC). Variabel dan jumlah barisnya bergantung pada orde model yang dipilih. Footer tabel mencantumkan R-squared, Adjusted R-squared, F-statistic, dan jumlah observasi efektif (*Included observations*).

Unrestricted ARDL Fit & Diagnostics			
Statistic	**Value**	**Statistic**	**Value**
R-squared	0.9739	Mean dependent var	28496.1720
Adjusted R-squared	0.9720	S.D. dependent var	10813.3722
S.E. of regression	1807.9677	Akaike info criterion	17.9101
Sum squared resid	281112255.4257	Schwarz criterion	18.1007
Log likelihood	-825.8187	Hannan-Quinn criter.	17.9870
F-statistic	534.1678	Durbin-Watson stat	1.9402
Prob(F-statistic)	0.0000	Evaluated Models	20

Baris Evaluated Models menunjukkan jumlah kombinasi model ARDL yang dievaluasi saat mode Auto Select digunakan. Misalnya nilai 25 berarti 25 kombinasi ARDL telah dibandingkan sebelum model terbaik dipilih.

Long Run Equation: Penumpang (000) ~ C + TJTP (000.000 km)				
Variable	**Coefficient**	**Std. Error**	**t-Statistic**	**Prob.**
C (Intercept)	2592.9207	807.3917	3.2115	0.0018
TJTP (000.000 km)	14.2841	0.4135	34.5408	0.0000
R-squared: 0.9270 | Adjusted R-squared: 0.9262 | F-statistic: 1193.0642				

Tabel diatas menampilkan hasil estimasi OLS hubungan jangka panjang antara variabel dependen dengan variabel independen dalam bentuk level. Koefisien pada tabel ini menunjukkan dampak jangka panjang perubahan satu satuan TJTP dan RJP terhadap jumlah penumpang.

Long Run Fit & Diagnostics			
Statistic	**Value**	**Statistic**	**Value**
R-squared	0.9270	Mean dependent var	28547.9688
Adjusted R-squared	0.9262	S.D. dependent var	10651.4430
S.E. of regression	2893.8109	Akaike info criterion	18.7991
Sum squared resid	787169294.0627	Schwarz criterion	18.8526
Log likelihood	-900.3592	Hannan-Quinn criter.	18.8207
F-statistic	1193.0642	Durbin-Watson stat	0.7853
Prob(F-statistic)	0.0000		

Copy SVG

Cointegration Test (ADF on Residuals)	
Statistic	**Value**
ADF Statistic	-2.2785
p-value	0.5876
Result	Not Cointegrated

Copy SVG

Copy SVG

Short Run ARDL-ECM: D(Penumpang (000)) ~ C + ECT(-1) + D(Penumpang (000)) lags + D(Xs) lags				
Variable	**Coefficient**	**Std. Error**	**t-Statistic**	**Prob.**
C (Intercept)	106.9725	191.5829	0.5584	0.5781
ECT(-1)	-0.1207	0.0869	-1.3882	0.1687
D(Penumpang (000)(-1))	-0.2779	0.1297	-2.1431	0.0350
D(TJTP (000.000 km))	0.0256	0.1180	0.2172	0.8286
D(TJTP (000.000 km)(-1))	9.7068	0.7163	13.5504	0.0000
R-squared: 0.7089 | Adjusted R-squared: 0.6847 | F-statistic: 29.2243				

Copy SVG

Short Run ECM Fit & Diagnostics			
Statistic	**Value**	**Statistic**	**Value**
R-squared	0.7089	Mean dependent var	155.7283
Adjusted R-squared	0.6847	S.D. dependent var	3246.4308
S.E. of regression	1823.0603	Akaike info criterion	17.9374
Sum squared resid	279178117.1572	Schwarz criterion	18.1566
Log likelihood	-817.1187	Hannan-Quinn criter.	18.0259
F-statistic	29.2243	Durbin-Watson stat	1.9722
Prob(F-statistic)	0.0000		

Classical Assumptions Tests (Short-Run Residuals)			
Test	Statistic	Prob.	Conclusion
Normality (Jarque-Bera)	25.9256	0.0000	Not normal
Autocorrelation (Breusch-Godfrey LM)	0.9750	0.3234	No Autocorrelation
Heteroskedasticity (Breusch-Pagan)	7.2582	0.4027	Homoskedastic

Copy SVG

Correlogram of Residuals (Autocorrelation & Partial Correlation)				
Lag	Autocorrelation (AC)	Partial Correlation (PAC)	Q-Stat	Prob.
1	0.0266	0.0266	0.0678	0.7946
2	-0.0673	-0.0680	0.5070	0.7761
3	-0.1781	-0.1753	3.6219	0.3049
4	0.0219	0.0262	3.6696	0.4540
5	0.1700	0.1516	6.5715	0.2536
6	0.1095	0.0799	7.7886	0.2532
7	0.0381	0.0638	7.9377	0.3378
8	-0.0724	-0.0117	8.4818	0.3879
9	0.0065	0.0368	8.4862	0.4866
10	0.0732	0.0591	9.0564	0.5275
11	-0.0169	-0.0657	9.0872	0.6148
12	0.2677	0.2793	16.9065	0.1525
13	-0.1983	-0.2190	21.2498	0.0678
14	0.0013	0.0363	21.2500	0.0950
15	0.0211	0.0770	21.3003	0.1270
16	0.1133	0.0258	22.7720	0.1196

Q-Stat is Ljung-Box Q statistic for residual white noise test. Prob is Chi-Square p-value.

Q-Statistic adalah statistik Ljung-Box untuk uji *white noise* residual. Jika p-value > 0,05 pada semua lag, residual tidak memiliki pola autokorelasi yang tersisa (residual bersifat *white noise*), yang menandakan model sudah cukup baik.

Automated Interpretation
Insight
The Cointegration Test (ADF) shows that the variables are NOT cointegrated (p > 0.05). Proceed with caution.
The ECT(-1) coefficient is NOT negative and significant, suggesting that short-run deviations do not reliably correct towards the long-run equilibrium.
Examine the Short Run ARDL-ECM table and Correlogram to interpret short-term dynamic effects and residual white noise.

Grafik yang dihasilkan:

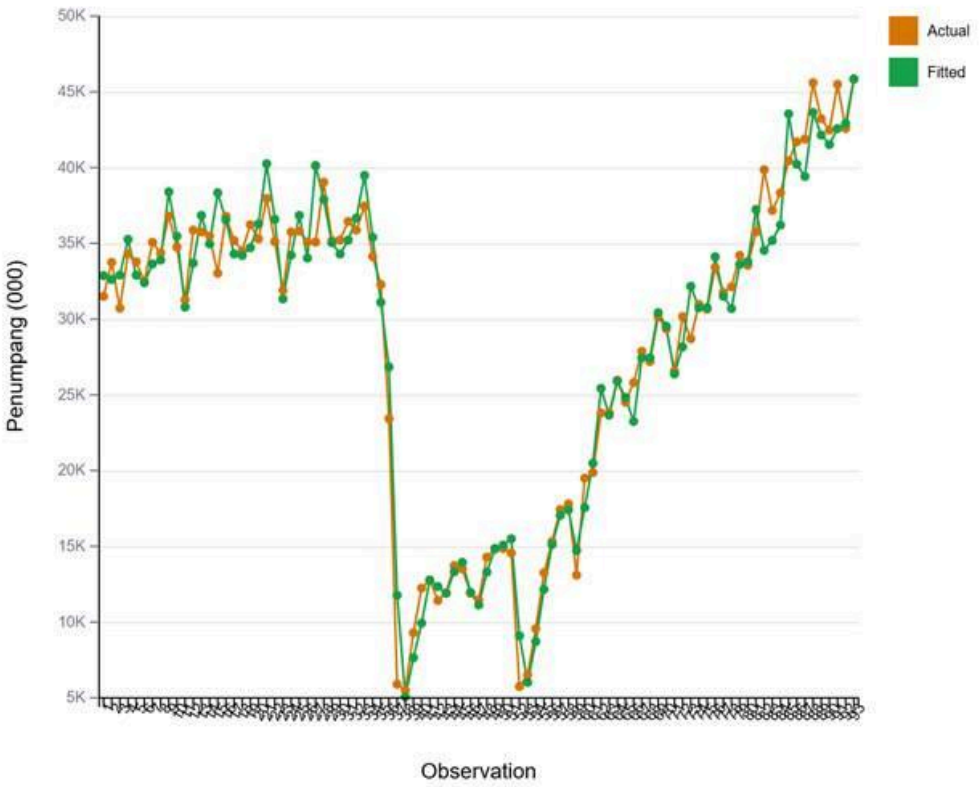
Actual vs Fitted Plot : Grafik garis ganda (Multiple Line Chart) menampilkan nilai aktual (Actual) dan nilai prediksi (Fitted) dari model ARDL tak terbatas. Berguna untuk menilai seberapa baik model mereproduksi data asli.

Residuals Plot Grafik garis (Line Chart) : menampilkan residual dari model ARDL tak terbatas dari waktu ke waktu. Residual yang acak (tidak berpola) mengindikasikan model yang baik.

Residual Correlogram Plot (ACF & PACF): Grafik garis ganda menampilkan nilai ACF dan PACF per lag, memberikan gambaran visual tentang pola autokorelasi tersisa pada residual.

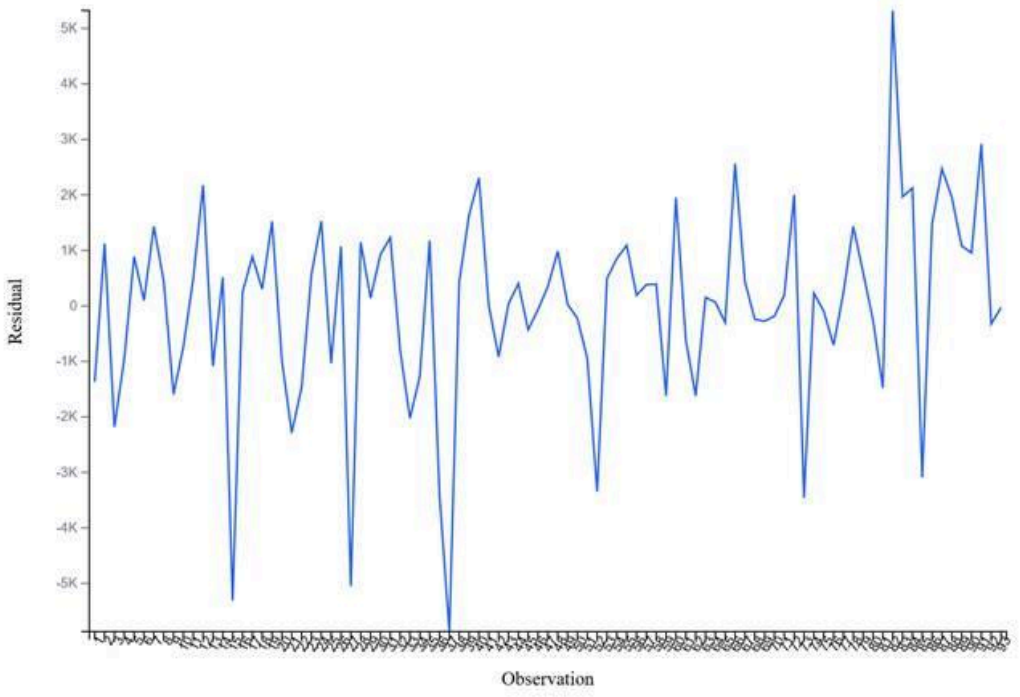
Actual vs Fitted Plot (ARDL(2, 3))

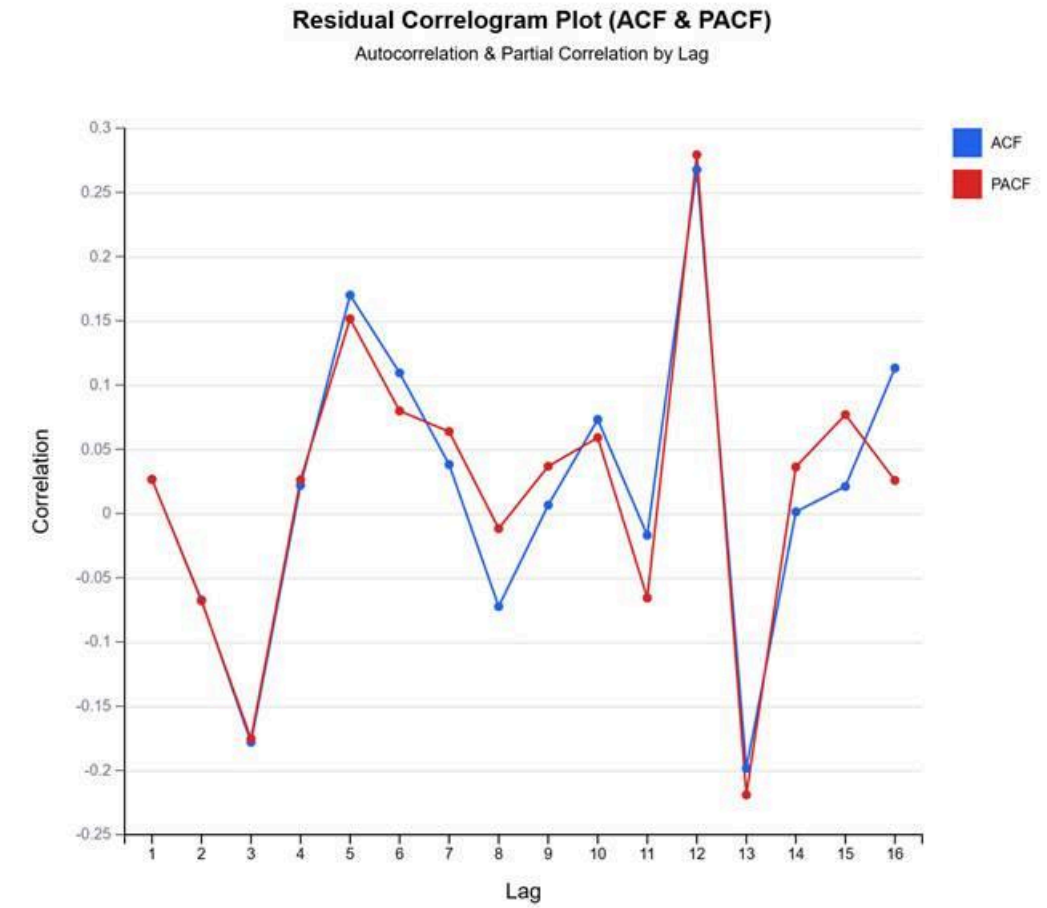
Dependent Variable: Penumpang (000)

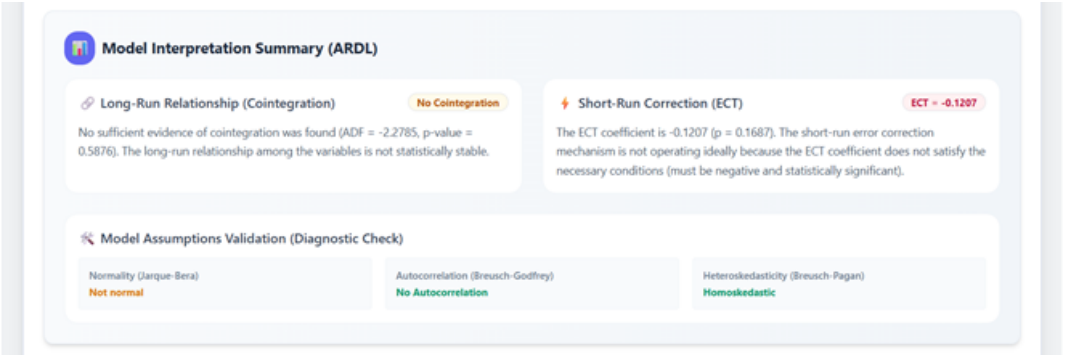


Residuals Plot (ARDL(2, 3))

Unrestricted ARDL Residuals







8. Jika sebelumnya Anda mencentang opsi Save Residuals, klik tombol data yang terdapat pada sisi kiri bawah halaman untuk melihat variabel residual baru (RES_LR_1 dan/atau RES_SR_1) yang telah disimpan ke dalam dataset.

5. Validasi Menu

Berikut beberapa validasi dari konfigurasi menu ARDL.

1. Peringatan belum memilih variabel dependen dan/atau independen

Apabila pengguna menekan tombol OK tanpa memilih variabel dependen dan/atau variabel independen, maka akan muncul notifikasi peringatan:

"Please select at least one dependent and one independent variable"

2. Peringatan data tidak mencukupi

Apabila jumlah data yang valid setelah pemotongan lag kurang dari 10 observasi, maka akan muncul notifikasi:

"Insufficient data points (minimum 10 required)"

3. Peringatan ketika menggunakan variabel bukan numerik

Apabila pengguna memilih variabel yang bukan bertipe numerik (misalnya variabel teks atau tanggal), maka analisis tidak dapat dilanjutkan dan akan muncul notifikasi error.

4. Peringatan ketika tidak mengonfigurasi periode waktu

Apabila konfigurasi periode waktu belum dilakukan, maka sistem akan menggunakan seluruh observasi yang tersedia. Pastikan konfigurasi waktu sudah benar sebelum menjalankan analisis.

ECM (Error Correction Model)

6. Tahapan Menggunakan Menu ECM

6.1. Tahapan

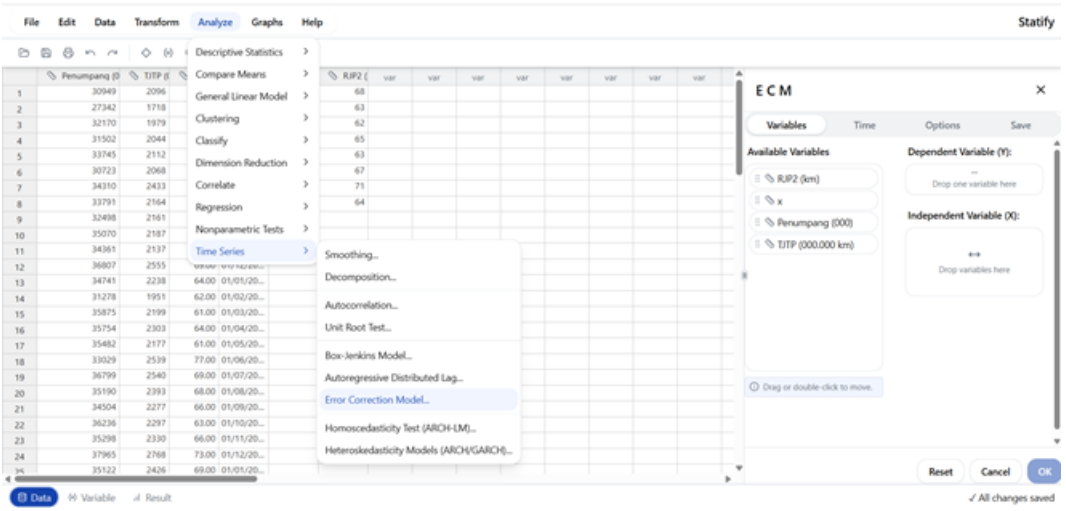
Menu ECM mengimplementasikan model koreksi kesalahan (Error Correction Model) klasik dua tahap Engle-Granger. Menu ini serupa dengan ARDL, namun tanpa lag tambahan pada variabel dependen di persamaan jangka pendek, sehingga cocok digunakan ketika model jangka pendek tidak memerlukan dinamika autoregresif dari variabel dependen.

Skenario analisis:

Pada panduan ini, kita akan menganalisis pengaruh TJTP terhadap jumlah Penumpang kereta api menggunakan model ECM klasik (satu variabel independen).

Ikuti langkah-langkah berikut.

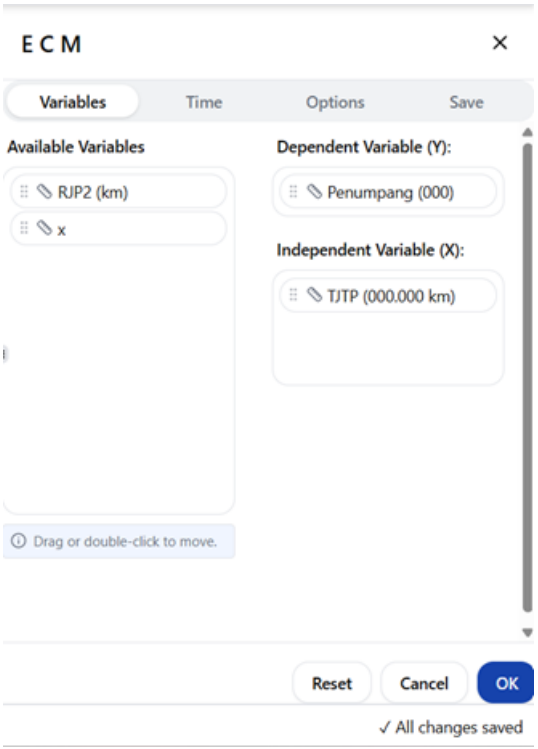
1. Klik Analyze → Time Series → ECM untuk masuk ke menu ECM.



2. Pada tab Variables, pilih variabel yang akan digunakan:

Pindahkan variabel Penumpang (000) ke kolom Dependent Variable.

Pindahkan variabel TJTP (000.000 km) ke kolom Independent Variable.



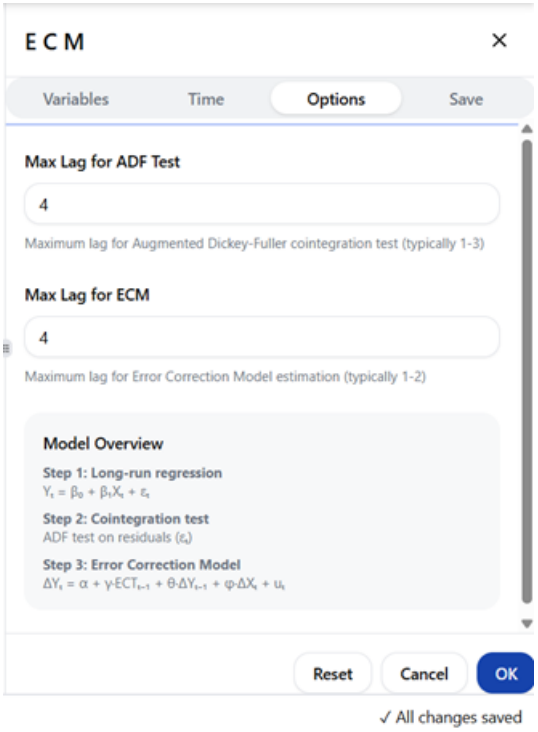
3. Pilih tab Time untuk menyesuaikan periode waktu.

Karena konfigurasi waktu sudah dilakukan pada tahapan sebelumnya, periode waktu pada tab ini dapat diabaikan karena aplikasi menyimpan hasil konfigurasi sebelumnya.

4. Pilih tab Options untuk mengatur parameter lag:

Max Lag ADF: 4 — jumlah lag maksimum untuk uji ADF pada residual.

Max Lag ECM: 4 — jumlah lag maksimum untuk model ECM jangka pendek.

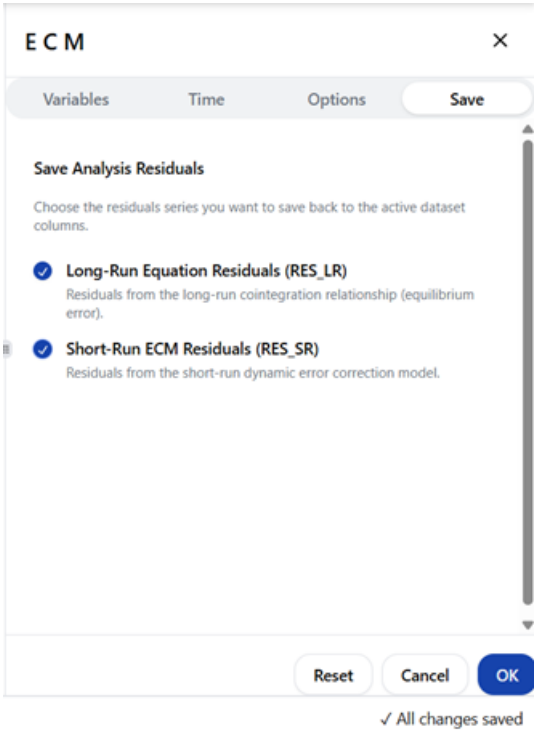


Lag yang lebih besar meningkatkan keandalan uji ADF namun mengurangi derajat kebebasan. Untuk data bulanan, nilai 4–12 umumnya digunakan.

5. Pilih tab Save jika ingin menyimpan residual ke dataset:

Long-Run Equation Residuals (RES_LR)

Short-Run ECM Residuals (RES_SR)



6. Setelah itu klik OK.

7. Selanjutnya Anda akan dipindahkan ke halaman Result dan Anda dapat melihat output ECM yang terdiri atas beberapa tabel berikut.



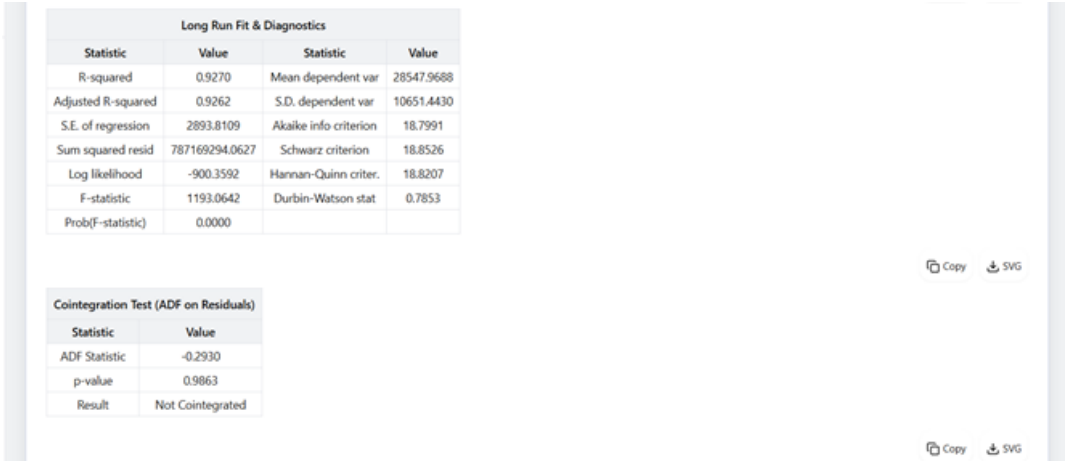
Long Run Regression: Penumpang (000) ~ C + TJTP (000.000 km)

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C (Intercept)	2592.9207	807.3917	3.2115	0.0018
TJTP (000.000 km)	14.2841	0.4135	34.5408	0.0000

R-squared: 0.9270 | Adjusted R-squared: 0.9262 | F-statistic: 1193.0642

Copy SVG

ECM klasik menggunakan OLS untuk mengestimasi persamaan jangka panjang. Koefisien TJTP menunjukkan elastisitas jangka panjang penumpang terhadap total jarak tempuh.



Long Run Fit & Diagnostics

Statistic	Value	Statistic	Value
R-squared	0.9270	Mean dependent var	28547.9688
Adjusted R-squared	0.9262	S.D. dependent var	10651.4430
S.E. of regression	2893.8109	Akaike info criterion	18.7991
Sum squared resid	787169294.0627	Schwarz criterion	18.8526
Log likelihood	-900.3592	Hannan-Quinn criter.	18.8207
F-statistic	1193.0642	Durbin-Watson stat	0.7853
Prob(F-statistic)	0.0000		

Copy SVG

Cointegration Test (ADF on Residuals)

Statistic	Value
ADF Statistic	-0.2930
p-value	0.9863
Result	Not Cointegrated

Copy SVG



Short Run (ECM): D(Penumpang (000)) ~ C + ECT(-1) + D(TJTP (000.000 km))

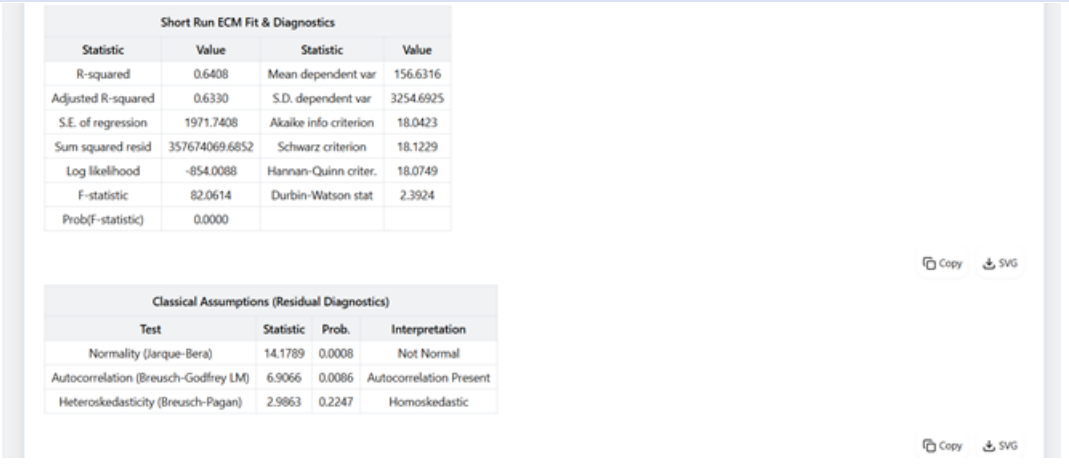
Variable	Coefficient	Std. Error	t-Statistic	Prob.
C (Intercept)	86.3929	202.4150	0.4268	0.6705
ECT(-1)	-0.2654	0.0746	-3.5585	0.0006
D(TJTP (000.000 km))	9.6675	0.7546	12.8108	0.0000

R-squared: 0.6408 | Adjusted R-squared: 0.6330 | F-statistic: 82.0614

Copy SVG

Perbedaan ECM vs ARDL:

Pada ECM, persamaan jangka pendek hanya mengandung D(X) tanpa lag D(Y). Ini menyebabkan model lebih sederhana namun lebih rentan terhadap autokorelasi residual.



Short Run ECM Fit & Diagnostics

Statistic	Value	Statistic	Value
R-squared	0.6408	Mean dependent var	156.6316
Adjusted R-squared	0.6330	S.D. dependent var	3254.6925
S.E. of regression	1971.7408	Akaike info criterion	18.0423
Sum squared resid	357674069.6852	Schwarz criterion	18.1229
Log likelihood	-854.0088	Hannan-Quinn criter.	18.0749
F-statistic	82.0614	Durbin-Watson stat	2.3924
Prob(F-statistic)	0.0000		

Copy SVG

Classical Assumptions (Residual Diagnostics)

Test	Statistic	Prob.	Interpretation
Normality (Jarque-Bera)	14.1789	0.0008	Not Normal
Autocorrelation (Breusch-Godfrey LM)	6.9066	0.0086	Autocorrelation Present
Heteroskedasticity (Breusch-Pagan)	2.9863	0.2247	Homoskedastic

Copy SVG

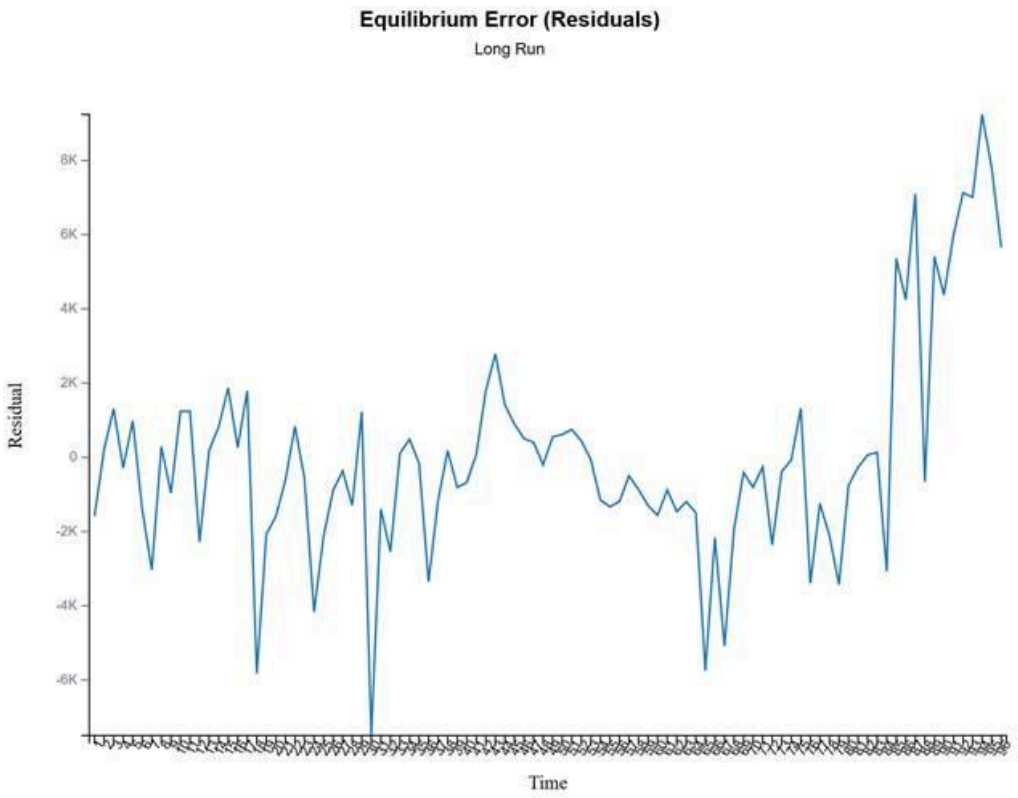
Correlogram of ECM Residuals (ACF & PACF)				
Lag	Autocorrelation (AC)	Partial Correlation (PAC)	Q-Stat	Prob.
1	-0.2000	-0.2000	3.9212	0.0477
2	0.2772	0.2471	11.5358	0.0031
3	-0.1375	-0.0514	13.4297	0.0040
4	0.1269	0.0349	15.0614	0.0048
5	0.1223	0.2130	16.5927	0.0055
6	0.0660	0.0755	17.0439	0.0093
7	0.0981	0.0590	18.0513	0.0118
8	-0.0202	0.0036	18.0943	0.0205
9	0.0526	-0.0043	18.3905	0.0308
10	0.1221	0.1309	20.0069	0.0291
11	-0.1182	-0.1543	21.5401	0.0282
12	0.2601	0.1702	29.0502	0.0040
13	-0.3020	-0.2119	39.3021	0.0002
14	0.2038	-0.0140	44.0254	0.0001
15	-0.0927	0.0885	45.0157	0.0001
16	0.1493	0.0279	47.6173	0.0001

Ljung-Box Q-statistic tests for null hypothesis of zero autocorrelation up to lag k.

Copy SVG

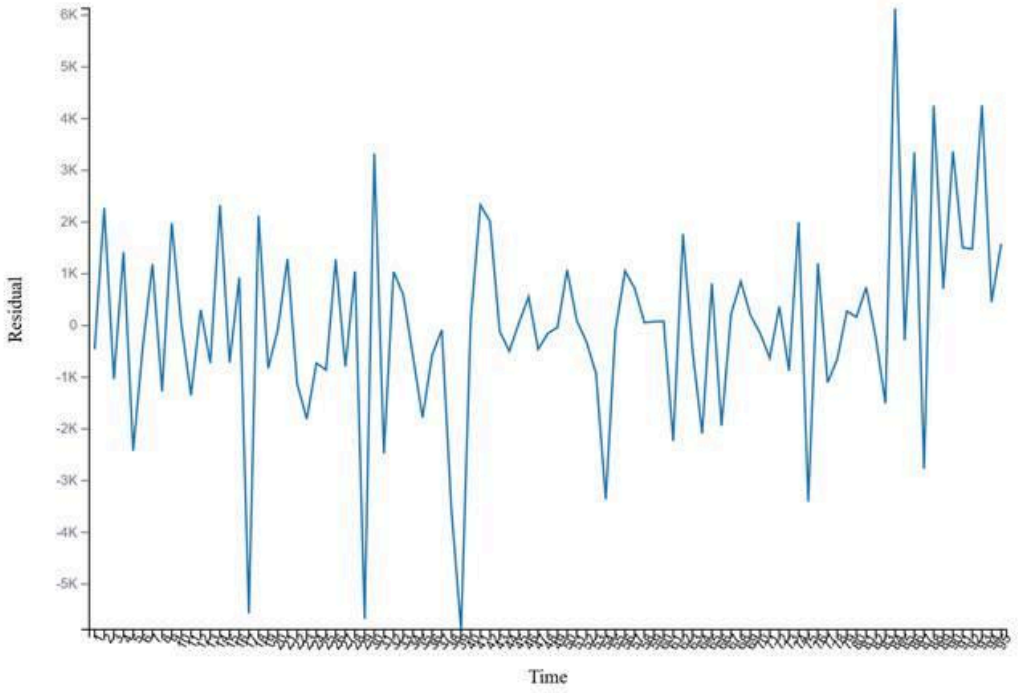
Copy SVG

Model Interpretation	
Component	Description
Cointegration	Variables are NOT cointegrated.
Short-Run ECM	ECM is valid. The Error Correction Term (ECT) is negative and significant (p = 0.0006), indicating adjustment towards long-run equilibrium at a speed of 26.54% per period.



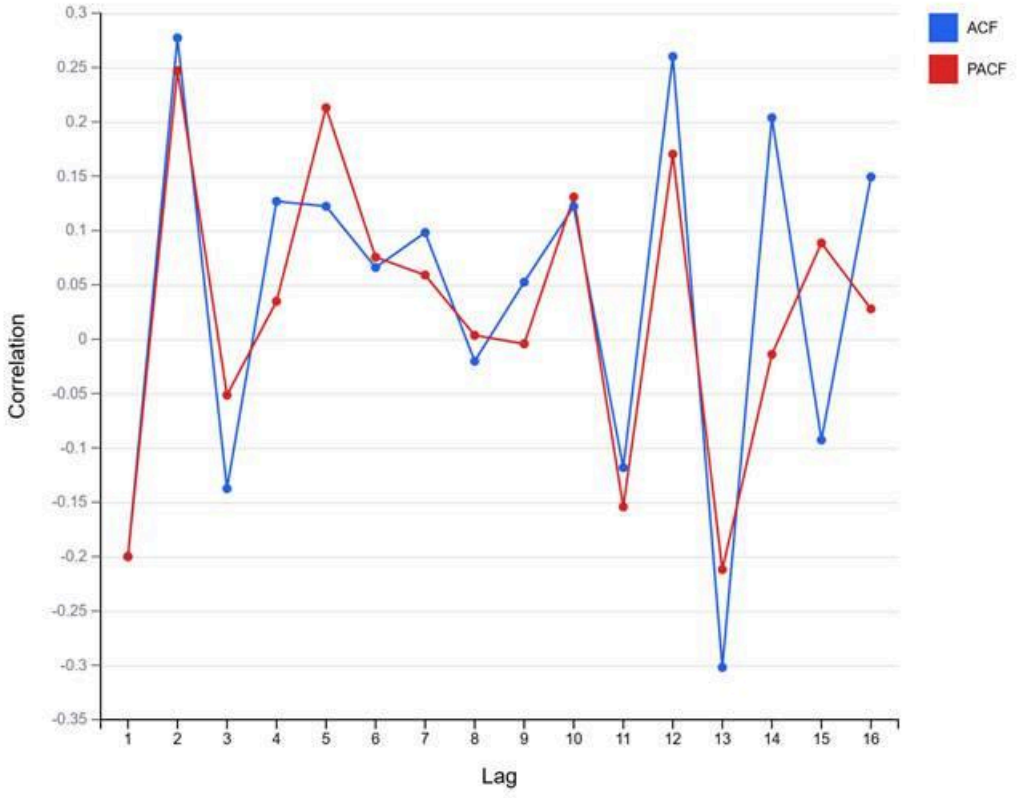
ECM Residuals

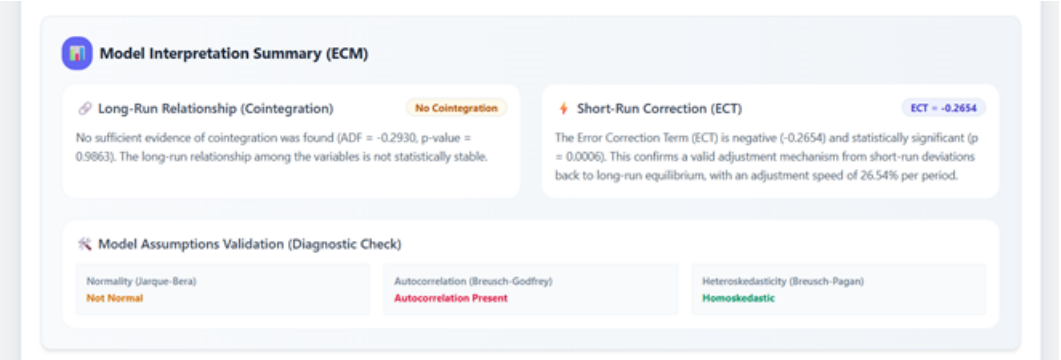
Short Run



ECM Residual Correlogram Plot (ACF & PACF)

Autocorrelation & Partial Correlation by Lag





8. Jika sebelumnya Anda mencentang opsi Save Residuals, klik tombol data di sisi kiri bawah halaman untuk melihat variabel residual yang telah disimpan.

7. Validasi Menu

Berikut beberapa validasi dari konfigurasi menu ECM.

1. Peringatan belum memilih variabel

Apabila pengguna menekan tombol OK tanpa memilih variabel dependen dan/atau variabel independen, maka akan muncul notifikasi:

"Please select both dependent and independent variables"

2. Peringatan data tidak mencukupi

Apabila jumlah data yang valid kurang dari 10 observasi, maka akan muncul notifikasi:

"Insufficient data points (minimum 10 required)"

3. Peringatan ketika menggunakan variabel bukan numerik

Apabila pengguna memilih variabel bertipe bukan numerik (misalnya variabel Periode/tanggal), maka analisis tidak dapat diproses.

4. Peringatan ketika tidak mengonfigurasi periode waktu

Pastikan konfigurasi waktu sudah benar sebelum menjalankan analisis.

Homoscedascity Test

8. Tahapan Menggunakan Menu Homoscedascity Test

8.1. Tahapan

Menu Homoscedasticity Test digunakan untuk menguji ada atau tidaknya efek ARCH (heteroskedastisitas bersyarat autoregresif) pada suatu seri data. Statify memungkinkan pengujian langsung pada variabel mana saja yang tersedia di dataset termasuk residual yang disimpan dari menu ARDL, ECM, maupun Box-Jenkins Model (ARIMA).

Skenario analisis:

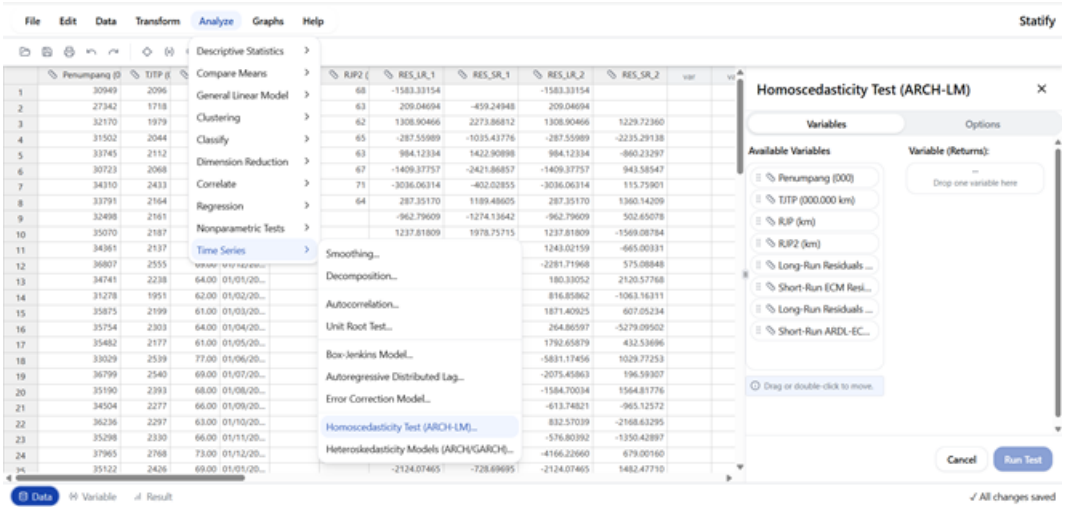
Kita akan menguji apakah residual jangka pendek (RES_SR) dari analisis ECM sebelumnya mengandung efek ARCH, yang berarti perlu dimodelkan dengan GARCH.

Prasyarat:

Pastikan Anda sudah menjalankan menu ECM dengan opsi Save Short-Run ECM Residuals (RES_SR) dicentang, sehingga variabel RES_SR_1 tersedia di dataset.

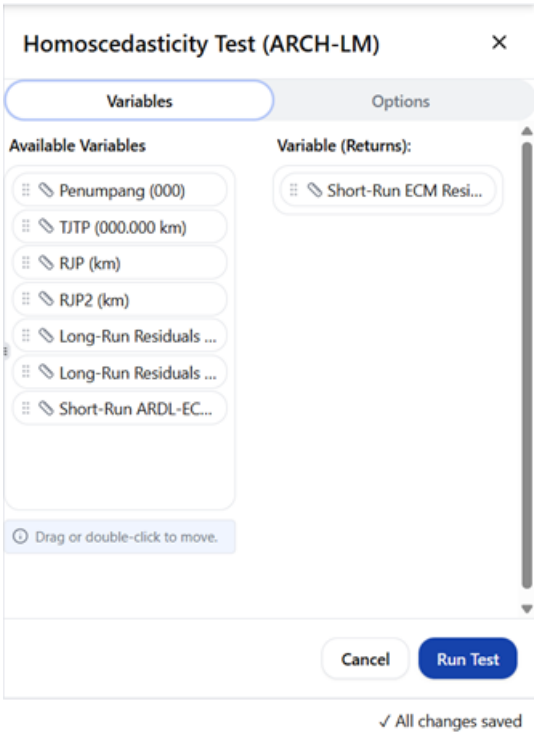
Ikuti langkah-langkah berikut.

1. Klik Analyze → Time Series → Homoscedasticity Test untuk masuk ke menu.



2. Pada tab Variables, pilih variabel residual yang akan diuji:

Pindahkan variabel RES_SR_1 (residual jangka pendek ECM) ke kolom Selected Variable. Apabila Anda ingin menguji ARCH effect langsung pada seri level (bukan residual), Anda dapat memilih variabel Penumpang (000) secara langsung.



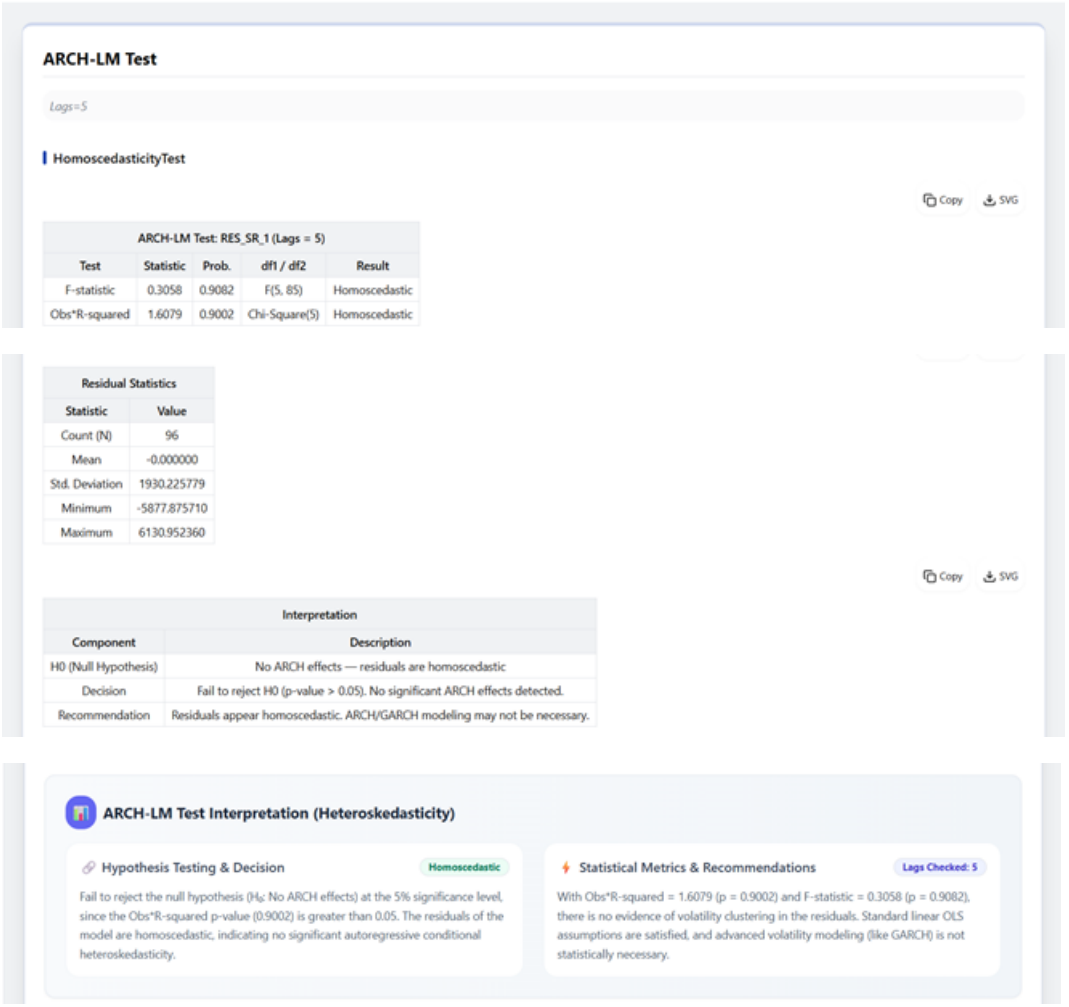
3. Pilih tab Options untuk mengatur parameter pengujian:

Number of Lags (q): 5 yaitu jumlah lag squared residuals dalam auxiliary regression.



Untuk data bulanan, lag 4–12 sering digunakan. Lag yang lebih besar mendeteksi pola ARCH yang lebih panjang namun mengurangi derajat kebebasan.

4. Setelah itu klik Run Test.
5. Selanjutnya Anda akan dipindahkan ke halaman Result dan Anda dapat melihat output ARCH-LM Test sebagai berikut.



9. Validasi Menu

Berikut beberapa validasi dari konfigurasi menu Homoscedasticity Test.

1. Peringatan belum memilih variabel

   Apabila pengguna menekan tombol Run Test tanpa memilih variabel, maka akan muncul notifikasi:

   "Please select a residual variable"

2. Peringatan data tidak mencukupi

   Apabila jumlah data yang valid kurang dari 10 observasi, maka akan muncul notifikasi:

   "Insufficient data points (minimum 10 required)"

3. Catatan mengenai pemilihan variabel

   Berbeda dengan EViews yang mensyaratkan equation window aktif, Statify menerima variabel kolom apa pun sebagai input uji ARCH-LM. Pengguna bertanggung jawab memastikan variabel yang dipilih adalah seri residual yang sesuai, bukan seri level asli.

MODUL REGRESI LOGISTIK BINER

A. Deskripsi Singkat

Analisis Regresi Logistik Biner dilakukan dalam rangka memodelkan keterkaitan antara satu variabel respons berskala biner dengan sehimpunan variabel penjelas yang dapat berskala numerik (kovariat) maupun kategorik (faktor). Berbeda dengan model regresi linier klasik yang mensyaratkan kenormalan galat serta kehomogenan ragam, regresi logistik biner tidak memodelkan nilai harapan respons secara langsung, melainkan memodelkan logaritma natural dari *odds* terjadinya suatu kejadian melalui fungsi hubung logit. Konsekuensi dari pemilihan fungsi hubung tersebut adalah nilai dugaan peluang yang dihasilkan model senantiasa terjamin berada pada selang tertutup nol sampai satu, sehingga dugaan yang diperoleh selalu memiliki tafsir probabilistik yang sahih.

Pengguna juga akan diperlihatkan proses pemeriksaan asumsi yang melekat pada regresi logistik biner, proses pembentukan *dummy* bagi variabel kategorik serta penetapan kategori rujukan, serta perbandingan hasil antara metode seleksi variabel, yaitu *Enter, Forward,* dan *Backward.*

B. Tujuan Demonstrasi

Panduan ini disusun sebagai panduan praktis untuk menggunakan perangkat lunak Statify dalam membangun, mendiagnosis, dan menginterpretasikan model regresi logistik biner. Melalui demonstrasi ini, pengguna diharapkan mampu memahami spesifikasi model logistik biner dan cara penduga parameternya bekerja, sehingga setiap angka pada hasil luaran dapat ditelusuri asal perhitungannya. Pengguna juga akan belajar mengonfigurasi tab-tab pada kotak dialog modul (*Variables, Assumption, Categorical, Options,* dan *Save*) sesuai kebutuhan analisis, serta memahami perbedaan metode seleksi variabel *Enter, Forward,* dan *Backward* beserta konsekuensinya. Selain itu, panduan ini membahas cara memeriksa asumsi regresi logistik biner dan langkah yang perlu diambil jika ada asumsi yang tidak terpenuhi. Terakhir, pengguna akan dituntun untuk menginterpretasikan koefisien, *odds ratio*, ukuran kebaikan suai, dan ketepatan klasifikasi model secara benar sesuai kaidah statistika inferensia.

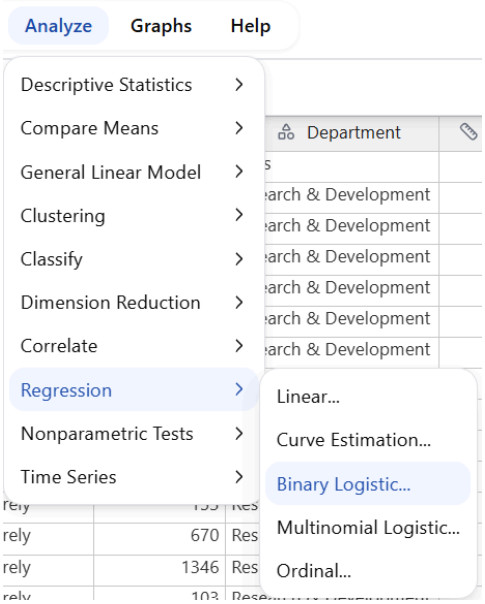
C. Material Demonstrasi

1. Dataset yang dapat diakses pada https://s.stis.ac.id/dataset_demoStatify64
2. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/
3. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64

D. Kegiatan Demonstrasi

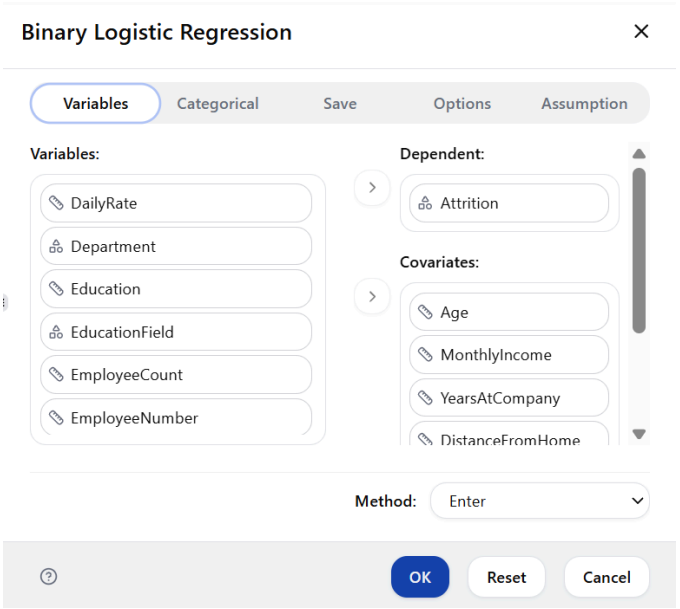
Demonstrasi Metode Enter

1. Tahap persiapan dilakukan dengan mengimpor dataset ke lembar kerja Statify melalui menu ***File > Import Data > CSV Data***. Apabila tampilan pratinjau dataset berhasil muncul, tekan Impor.
2. Pilih menu ***Analyze > Regression > Binary Logistic***.

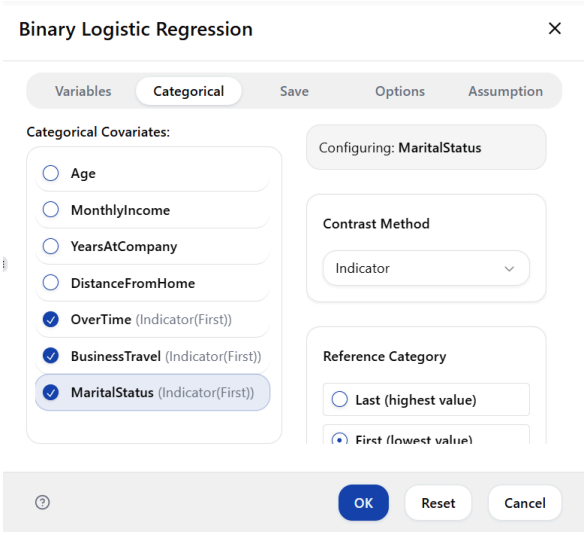


3. Klik tab Variables. Tab ini digunakan untuk menetapkan struktur model.
    - Pindahkan variabel *Attrition* ke kotak *Dependent*. Karena variabel ini bertipe teks dengan dua kategori, sistem akan menyandikan kategori secara otomatis mengikuti urutan abjad, sehingga No memperoleh kode 0 dan Yes memperoleh kode 1. Dengan demikian, seluruh koefisien yang dihasilkan menafsirkan kecenderungan karyawan untuk keluar, bukan untuk bertahan. Konfirmasikan penyandian ini pada tabel *Dependent Variable Encoding* di halaman luaran sebelum melakukan interpretasi.
    - Pindahkan ketujuh variabel penjelas, yaitu *Age, BusinessTravel, DistanceFromHome, MaritalStatus, MonthlyIncome, OverTime,* dan *YearsAtCompany,* ke kotak *Covariates*. Perlu diperhatikan bahwa tab *Variables* pada modul ini hanya menyediakan kotak *Dependent* dan *Covariates*; tidak terdapat kotak *Factors* yang terpisah. Penetapan status kategorik atas *OverTime, BusinessTravel,* dan *MaritalStatus* dilakukan pada tab *Categorical* sebagaimana diuraikan pada langkah berikutnya.
    - Pada opsi *Regression Method*, pilih *Enter* untuk demonstrasi pertama. Metode ini memasukkan seluruh variabel secara serentak sehingga hasilnya dapat dijadikan model rujukan ketika dibandingkan dengan hasil metode bertahap. Opsi yang sama

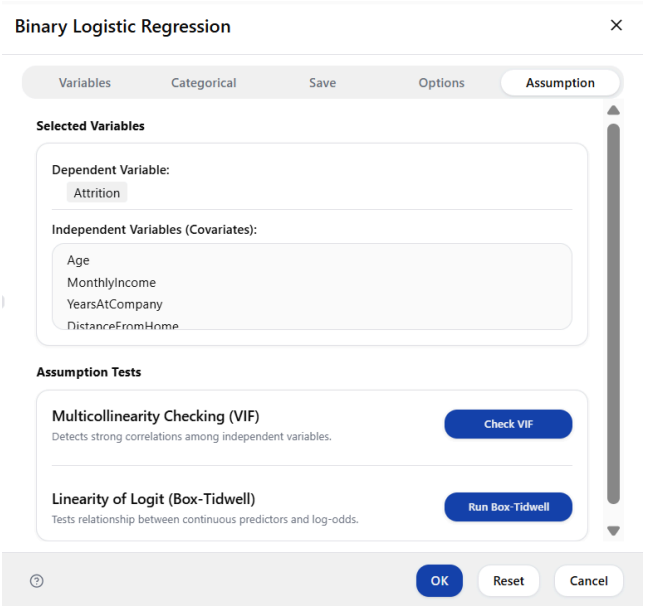
memuat enam ragam bertahap lainnya, yaitu *Forward: Conditional, Forward: LR, Forward: Wald, Backward: Conditional, Backward: LR,* dan *Backward: Wald*.



4. Klik tab Categorical. Tab ini menentukan cara faktor kategorik diubah menjadi *dummy*.
    - Daftar Categorical Covariates memuat seluruh variabel yang telah ditempatkan pada kotak Covariates. Pastikan centang kotak di samping *OverTime, BusinessTravel,* dan *MaritalStatus* agar ketiganya diperlakukan sebagai faktor dan diubah menjadi *dummy*. Variabel yang tidak dicentang tetap diperlakukan sebagai kovariat numerik.
    - Klik nama faktor pada daftar, pilih skema kontras *Indicator* pada bagian *Contrast Method*, tetapkan *Reference Category* pada pilihan *First*, kemudian tekan *Change* agar perubahan diterapkan. Ulangi untuk ketiga faktor. Label di samping nama variabel akan berubah menjadi *Indicator(First)* sebagai penanda bahwa pengaturan telah tersimpan. Dengan penetapan ini, kategori rujukan masing-masing faktor berturut-turut adalah *No, Non-Travel,* dan *Divorced.* Perlu dicatat bahwa pengaturan bawaan sistem adalah *Indicator(Last)*, yang akan menjadikan kategori terakhir menurut urutan abjad sebagai rujukan, yaitu *Yes, Travel_Rarely,* dan *Single*.

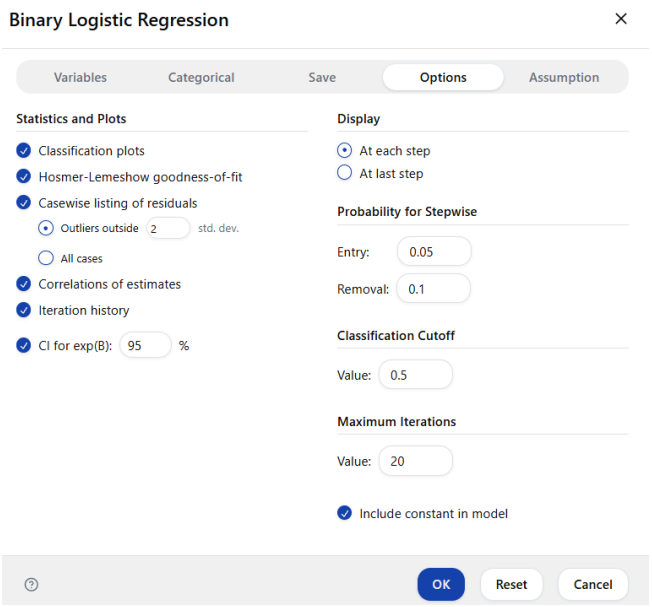


5. Klik tab Assumption. Berbeda dengan tab lainnya yang berisi kotak centang, tab ini menyajikan ringkasan variabel terpilih beserta dua uji diagnostik yang dijalankan melalui tombol tersendiri. Hasil kedua uji tidak muncul pada tab ini, melainkan langsung dikirimkan ke halaman *Result*.
    - ***Multicollinearity Checking (VIF)***: tekan tombol Check *VIF* untuk menghitung nilai *VIF* dan *tolerance*. Tombol ini baru aktif apabila sekurang-kurangnya dua kovariat telah dipilih. Perlu dipahami bahwa perhitungan dilakukan atas matriks kovariat, yaitu ketika setiap faktor masih terwakili oleh satu kolom kode bilangan bulat, sehingga tabel luaran memuat satu baris per variabel, bukan satu baris per peubah boneka. Pemeriksaan ini penting mengingat model memuat *Age, YearsAtCompany,* dan *MonthlyIncome* yang secara substantif saling berkorelasi.
    - ***Linearity of Logit (Box–Tidwell)***: tekan tombol *Run Box–Tidwell* untuk menguji kelinieran hubungan antara kovariat numerik dan logit. Tombol ini memerlukan variabel dependen serta sekurang-kurangnya satu kovariat. Mesin membentuk satu model teraugmentasi yang memuat seluruh suku $x \cdot \ln(x)$ secara serentak, bukan satu model terpisah bagi setiap kovariat. Variabel dengan paling banyak empat nilai unik dilewati secara otomatis dan dilaporkan pada tabel *Variables Excluded from Box–Tidwell Test*.



6. Klik tab Options. Tab ini mengatur statistik tambahan yang ditampilkan serta parameter pengendali algoritma.
    - ***Classification plots***: menampilkan sebaran dugaan peluang menurut kelompok teramati sehingga daya pisah model dapat dinilai secara visual.
    - ***Hosmer–Lemeshow goodness of fit***: menampilkan uji kelayakan model. Opsi ini wajib dicentang.
    - ***Casewise listing of residuals***: menampilkan daftar pengamatan dengan sisaan melampaui ambang tertentu. Tersedia dua pilihan, yaitu *Outliers outside* dengan ambang yang dapat diatur (secara *default* 2 simpangan baku) dan *All cases* yang menampilkan seluruh pengamatan. Pilihan kedua sebaiknya dihindari pada data berukuran besar karena menghasilkan tabel yang sangat panjang.
    - ***Correlations of estimates***: menampilkan matriks korelasi antar penduga parameter, berguna untuk mendeteksi ketergantungan linier antara koefisien.
    - ***Iteration history***: menampilkan nilai *−2 Log Likelihood* serta koefisien pada setiap iterasi, sehingga kestabilan dan kecepatan konvergensi dapat diperiksa.
    - ***CI for exp(B)***: menampilkan selang kepercayaan bagi *odds ratio*. Pada demonstrasi ini, taraf nyata ditetapkan sebesar 5 persen sehingga nilai yang diisikan adalah 95.
    - ***Display***: menentukan apakah luaran ditampilkan pada setiap langkah (*At each step*) ataukah hanya pada langkah terakhir (*At last step*). Pengaturan ini hanya berpengaruh pada metode bertahap; pada metode *Enter* kedua pilihan menghasilkan luaran yang sama. Untuk demonstrasi metode *Forward* dan *Backward*, pertahankan pilihan At each step agar seluruh langkah dapat ditelusuri.
    - ***Classification cutoff***: titik potong penggolongan, secara *default* 0,5. Nilai ini dapat disesuaikan apabila proporsi kejadian sangat timpang.

- ***Maximum iterations***: batas maksimum iterasi, secara *default* 20. Nilai ini hanya perlu dinaikkan apabila sistem melaporkan status tidak konvergen.
- ***Probability for stepwise***: ambang peluang pemasukan (*Entry*) dan pengeluaran *(Removal*) bagi metode bertahap, secara *default* 0,05 dan 0,10. Pengaturan ini tidak berpengaruh pada metode Enter.
- ***Include constant in model***: mempertahankan konstanta dalam model. Opsi ini hendaknya tetap aktif kecuali terdapat alasan teoritis yang kuat untuk meniadakannya.



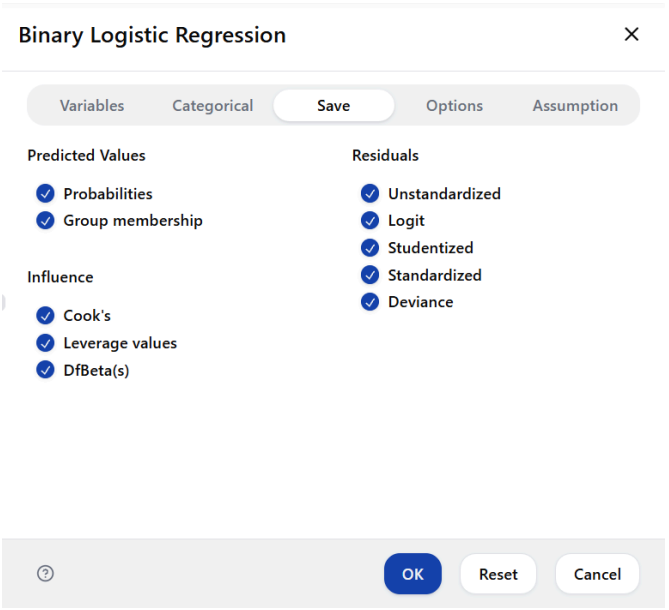
7. Klik tab Save. Tab ini membentuk kolom variabel baru secara otomatis pada lembar kerja sehingga hasil pemodelan dapat ditelusuri pada tataran unit pengamatan.

Tabel 1. Variabel Baru yang Dapat Dibentuk melalui Tab Save

Kelompok	Pilihan	Kegunaan analitik
Predicted Values	*Probabilities*	Menyimpan dugaan peluang $\hat{\pi}_i$ bagi setiap karyawan (kolom PRE_1); menjadi dasar pemeringkatan risiko dan penyusunan kurva ROC di luar modul
Predicted Values	*Group membership*	Menyimpan hasil penggolongan pada titik potong yang ditetapkan; menjadi dasar penyusunan tabel klasifikasi
Residuals	*Unstandardized*	Selisih $y_i - \hat{\pi}_i$ sebagai bentuk sisaan paling dasar
Residuals	*Standardized (ZResid)*	Sisaan Pearson terbakukan; digunakan untuk mendeteksi pengamatan menyimpang
Residuals	*Studentized*	Sisaan yang memperhitungkan pengaruh penghapusan pengamatan terhadap kecocokan model
Residuals	*Logit*	Sisaan pada skala logit; berguna memeriksa kelinieran hubungan

Residuals	*Deviance*	Sumbangan setiap pengamatan terhadap statistik deviance
Influence	*Cook's distance*	Mengukur besarnya perubahan seluruh koefisien apabila suatu pengamatan dihapus
Influence	*Leverage values*	Mengukur keterpencilan pengamatan pada ruang variabel penjelas
Influence	*DfBeta(s)*	Mengukur perubahan setiap koefisien secara terpisah akibat penghapusan satu pengamatan

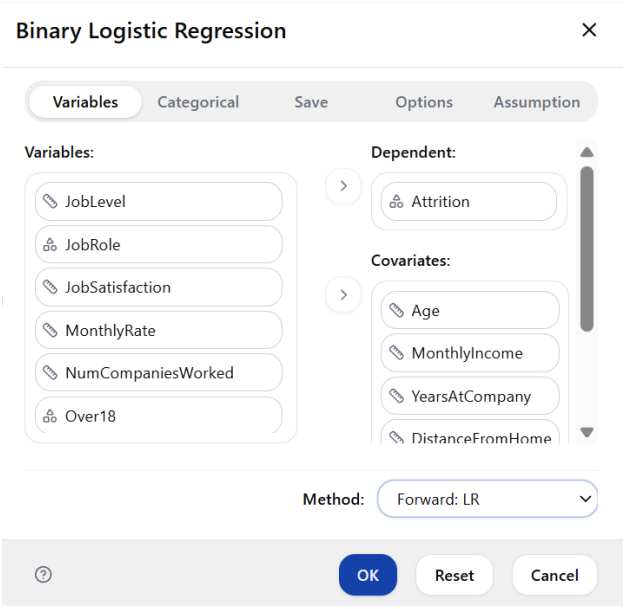
Pada demonstrasi ini, centang sekurang-kurangnya Probabilities, Group membership, Standardized residuals, dan Cook's distance agar diagnostik dapat direproduksi secara mandiri oleh pengguna.



8. Tekan tombol OK untuk menjalankan analisis, *output* akan ditampilkan setelah proses konvergen pada halaman *result*.

Demonstrasi Metode Forward

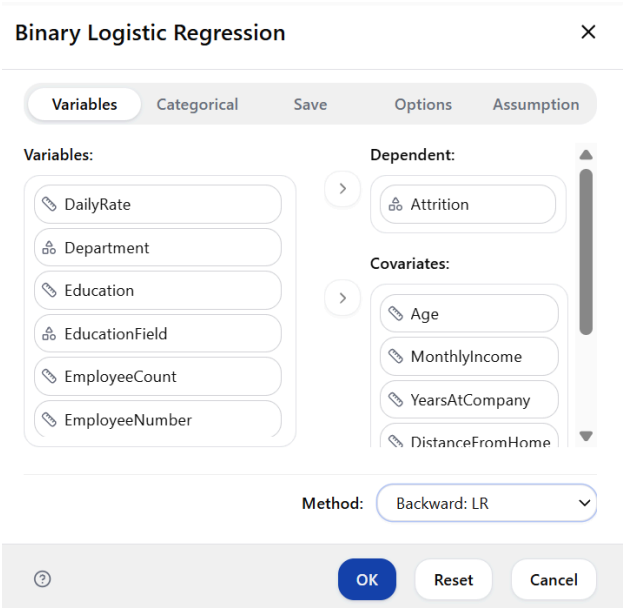
1. Ulangi langkah pada Bagian Kegiatan Demonstrasi Metode Enter dengan konfigurasi variabel yang sama, tetapi ubah pilihan pada opsi *Regression Method* di tab *Variables* menjadi *Forward: LR*.



2. Pastikan ambang peluang pada opsi *Probability for Stepwise* di tab *Options* tetap pada nilai baku, yaitu 0,05 untuk pemasukan (*Entry*) dan 0,10 untuk pengeluaran (*Removal*), serta pilihan *Display* tetap pada *At each step* agar seluruh langkah dapat ditelusuri.
3. Tekan tombol OK untuk menjalankan analisis, *output* akan ditampilkan setelah proses konvergen pada halaman *result*.

Demonstrasi Metode Backward

1. Ulangi langkah pada Bagian Kegiatan Demonstrasi Metode Enter dengan konfigurasi variabel yang sama, tetapi ubah pilihan pada opsi *Regression Method* di tab *Variables* menjadi *Backward: LR*.



2. Pastikan ambang peluang pada opsi *Probability for Stepwise* di tab *Options* tetap pada nilai baku, yaitu 0,05 untuk pemasukan (*Entry*) dan 0,10 untuk pengeluaran (*Removal*), serta pilihan *Display* tetap pada *At each step* agar seluruh langkah dapat ditelusuri.
3. Tekan tombol OK untuk menjalankan analisis, *output* akan ditampilkan setelah proses konvergen pada halaman *result*.

MODUL REGRESI ORDINAL

A. Deskripsi Singkat

Analisis Regresi Logistik Ordinal dilakukan dalam rangka menganalisis variabel respons berskala ordinal (>2 kategori). Sistem akan menghitung *J-1* persamaan logit untuk *J* kategori yang didefinisikan. Selain membangun model, pengguna akan diperlihatkan proses pengecekan asumsi *parallel lines*, di mana model dianggap valid apabila menghasilkan koefisien regresi yang identik di setiap kategori variabel respons.

B. Tujuan Demonstrasi

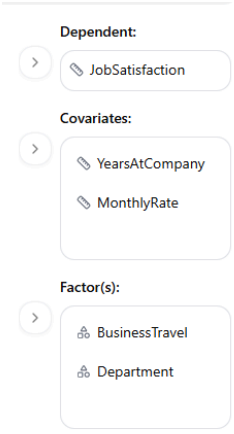
Panduan penggunaan ini bertujuan sebagai panduan praktis dalam rangka penggunaan/demonstrasi perangkat lunak Statify untuk membangun dan menganalisis model regresi ordinal. Panduan ini secara khusus difokuskan pada kasus di mana variabel respons memiliki lebih dari dua kategori berskala ordinal, hingga pada tahap interpretasi hasil analisisnya.

C. Material Demonstrasi

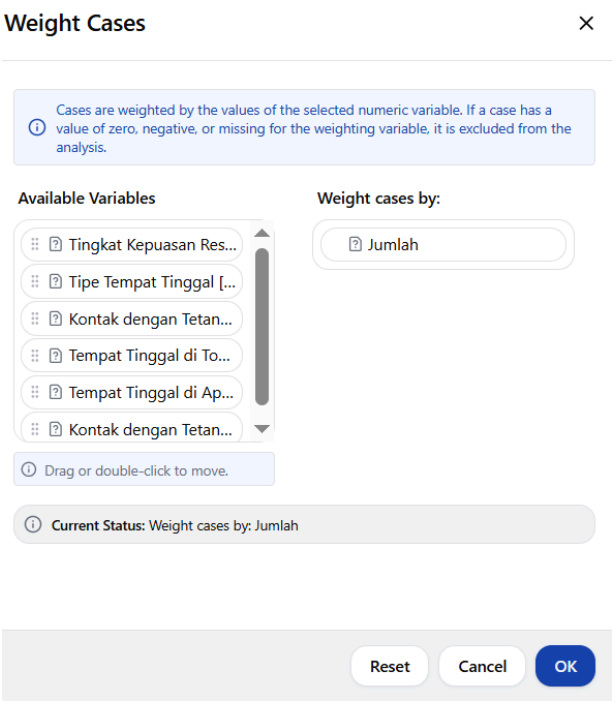
1. Dataset yang dapat diakses pada https://s.stis.ac.id/dataset_demoStatify64
2. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/
3. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64

D. Kegiatan Demonstrasi

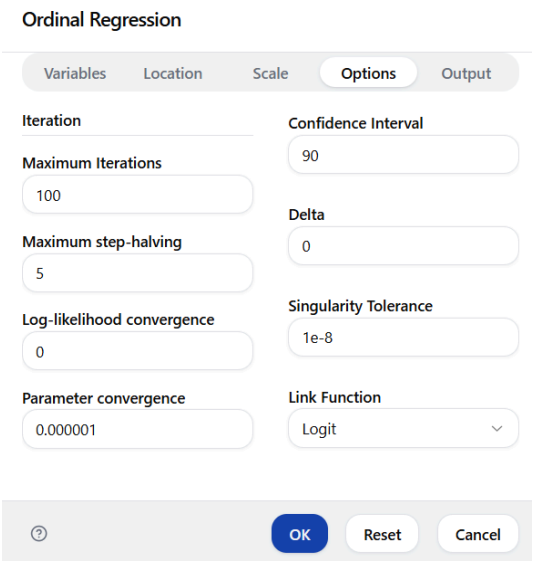
1. Tahap persiapan dilakukan dengan mengimport dataset ke lembar kerja Statify. ***File > Import Data > CSV Data***. Jika tampilan/preview dataset berhasil muncul, maka tekan ***Impor.***
2. Pilih menu ***Analyze > Regression > Ordinal.***
3. Inputkan variabel "JobSatisfaction" sebagai variabel Y ke kolom **Dependent** dan variabel X meliputi "BusinessTravel", "Departement" ke kolom **Factors** serta "YearsAtCompany", "MonthlyRate" ke kolom **Covariates** seperti pada gambar di bawah ini.



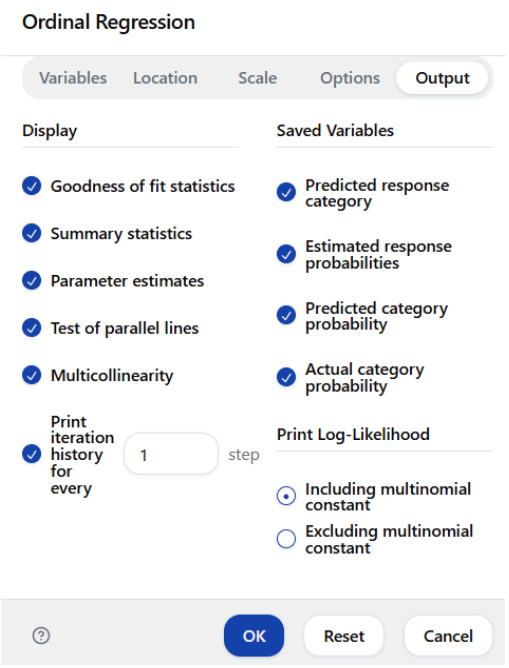
4. Perlu diperhatikan bahwa dataset yang digunakan adalah data mikro atau data individu. Ketika analisis menggunakan data mikro, maka langsung dapat menjalankan menu Regresi Ordinal. Tetapi, jika dataset merupakan data yang sudah dibobotkan, maka perlu diaktifkan pembobot terlebih dahulu ke menu ***Data > Weight Cases*** dan inputkan variabel yang digunakan sebagai pembobot lalu klik ***OK***, baru menjalankan analisis Regresi Ordinal seperti biasa. Contoh kasus penggunaan data pembobot ditunjukkan pada gambar di bawah ini.



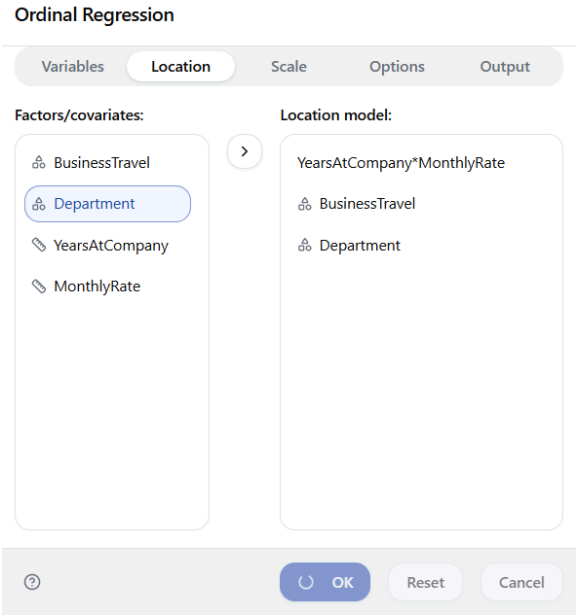
5. Pada bagian ***Link Function,*** Anda dapat memilih model transformasi yang ingin digunakan. Pada demonstrasi pertama gunakan link logit.
6. Melalui menu ***Options***, pengguna dapat mengatur batas iterasi serta menyesuaikan nilai Confidence Interval (Selang Kepercayaan). Pada demo ini, tingkat signifikansi yang ditetapkan sebesar 1% ($\alpha = 0{,}01$), maka opsi Confidence Interval perlu diubah secara manual menjadi 99.



7. Pada menu ***Output,*** centang bagian Display sesuai dengan apa yang Anda inginkan untuk ditampilkan sebagai result/hasil nantinya.
    - **Print iteration history for every 1 step(s)**: Menampilkan riwayat proses iterasi estimasi parameter langkah demi langkah. Digunakan untuk memeriksa apakah algoritma estimasi berhasil mencapai konvergensi (converged) secara stabil atau mengalami kendala matematis.
    - **Goodness of fit statistics**: Menghasilkan statistik uji Chi-square Pearson dan Deviance (Likelihood-ratio). Digunakan untuk menguji apakah model yang dibentuk sudah cocok (fit) dan sesuai dengan data observasi (diharapkan nilai $p > 0,05$).
    - **Summary statistics**: Menampilkan nilai Cox & Snell, Nagelkerke, dan McFadden. Digunakan untuk mengukur seberapa besar proporsi variasi dari variabel terikat (kepuasan lingkungan kerja) yang dapat dijelaskan oleh kombinasi variabel prediktor dalam model.
    - **Parameter estimate**: Menampilkan tabel koefisien regresi, standar eror, statistik Wald, p-value, dan interval kepercayaan. Digunakan untuk mengetahui arah serta besarnya pengaruh masing-masing faktor dan kovariat terhadap kecenderungan peningkatan kategori kepuasan.
    - **Test of parallel lines**: Menguji asumsi utama regresi ordinal (proportional odds assumption). Digunakan untuk memastikan bahwa pengaruh (slopes/koefisien) dari variabel prediktor bersifat konsisten dan sejajar di setiap ambang batas (threshold) kategori variabel terikat.



8. Pada menu ***Saved Variables*** akan membuat kolom variabel baru secara otomatis di dalam lembar kerja.
9. Gunakan menu ***Location*** untuk menspesifikasi interaksi antara variabel dalam membangun model. Tahan SHIFT sambil menekan variabel apa saja yang ingin diinteraksikan.



10. Lanjutkan pengujian untuk ***Link Function*** dan ***Options*** yang beragam.

MODUL REGRESI MULTINOMIAL

A. Deskripsi Singkat

Analisis Regresi Logistik Multinomial dilakukan dalam rangka menganalisis variabel respons berskala nominal (>2 kategori tanpa tingkatan). Sistem akan menghitung J-1 persamaan logit untuk J kategori yang didefinisikan berdasarkan kategori acuan (reference group). Selain membangun model, pengguna akan diperlihatkan proses eksplorasi raw data dan data yang sudah diolah hingga evaluasi kebaikan model (goodness-of-fit).

B. Tujuan Demonstrasi

Panduan penggunaan ini bertujuan sebagai panduan praktis dalam rangka penggunaan/demonstrasi perangkat lunak Statify untuk membangun dan menganalisis model regresi multinomial. Panduan ini secara khusus difokuskan pada kasus di mana variabel respons memiliki lebih dari dua kategori berskala nominal, hingga pada tahap interpretasi hasil analisisnya untuk pengambilan keputusan retensi karyawan.

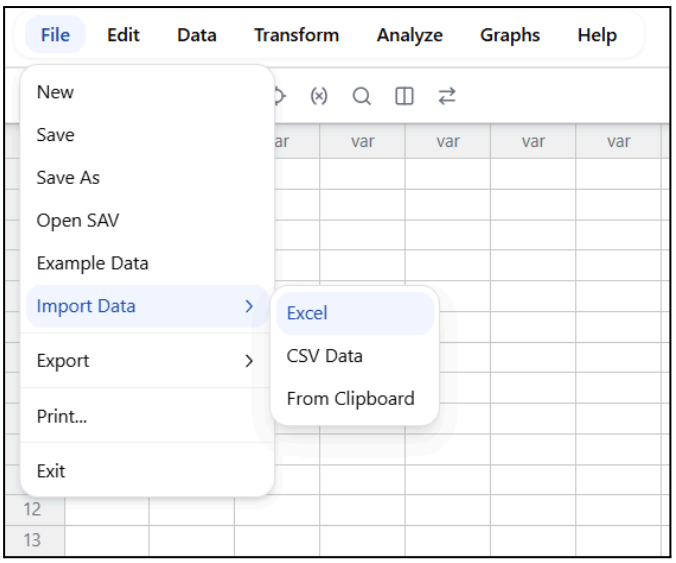
C. Material Demonstrasi

1. Data mentah (raw data) dapat diakses pada link berikut dataset_datamentah_MLR
2. Data dengan bobot dapat diakses pada link berikut dataset_bobot_MLR
3. Aplikasi statify dapat diakses pada link berikut https://statify-dev.student.stis.ac.id/

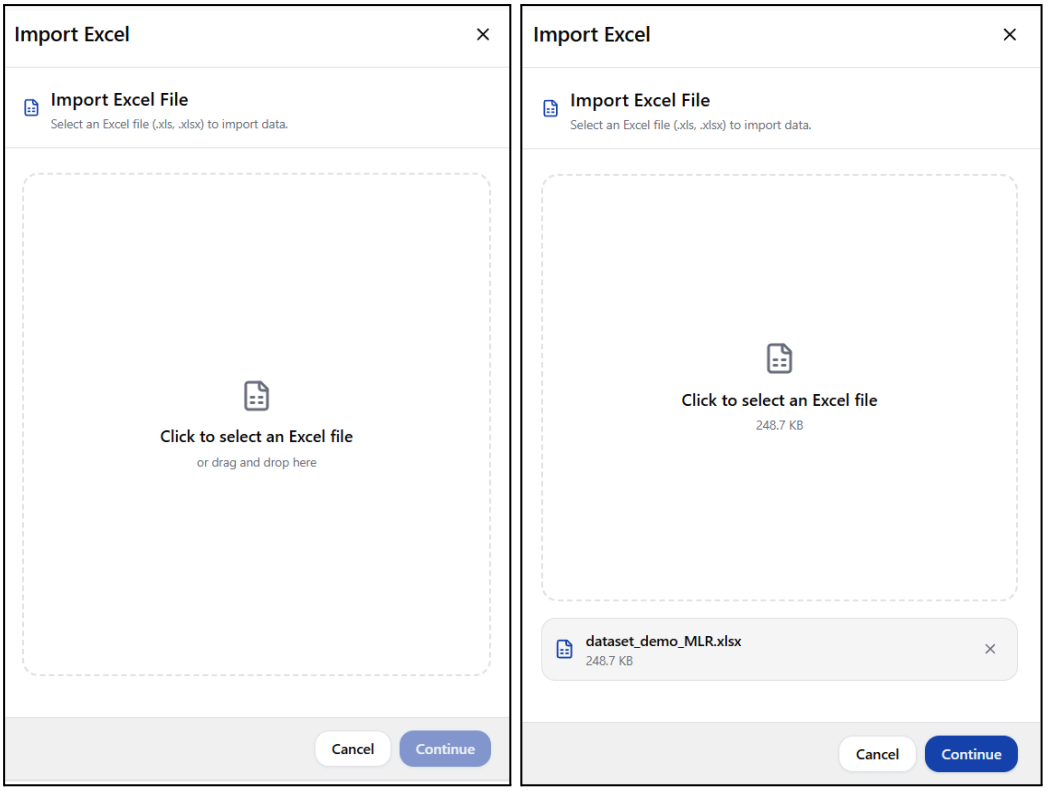
D. Analisis menggunakan data mentah atau raw data

Pada demonstrasi ini, analisis regresi logistik multinomial ini bertujuan untuk mengidentifikasi berbagai faktor yang berhubungan dengan karakteristik karyawan, khususnya pada status pernikahan (marital status). Analisis dilakukan dengan mengeksplorasi hubungan antara status pernikahan karyawan dengan variabel kualitas keseimbangan kehidupan kerja (work life balance) sebagai faktor kategorikal, serta mempertimbangkan variabel kontinu seperti usia (age) dan pendapatan bulanan (monthly income) sebagai kovariat. Dataset yang digunakan merupakan data fiktif yang dikembangkan oleh para data scientist IBM. Berikut langkah-langkah untuk memulai analisis regresi logistik multinomial menggunakan statify :

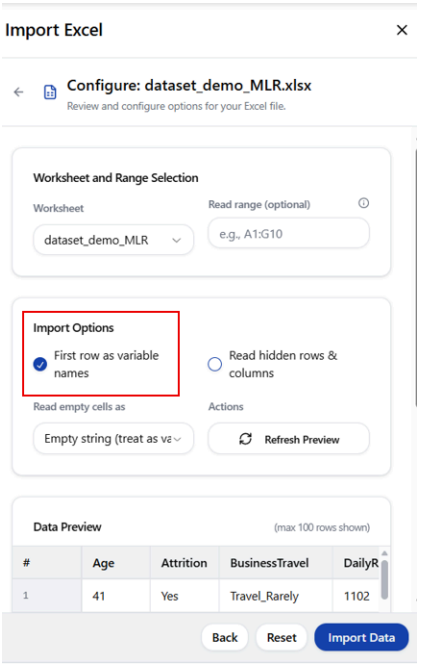
1. Silahkan unduh data berikut ini Dataset Regresi Multinomial
2. Buka situs web statify https://statify-dev.student.stis.ac.id/dashboard/data
3. Klik File → Import Data →Excel Data.



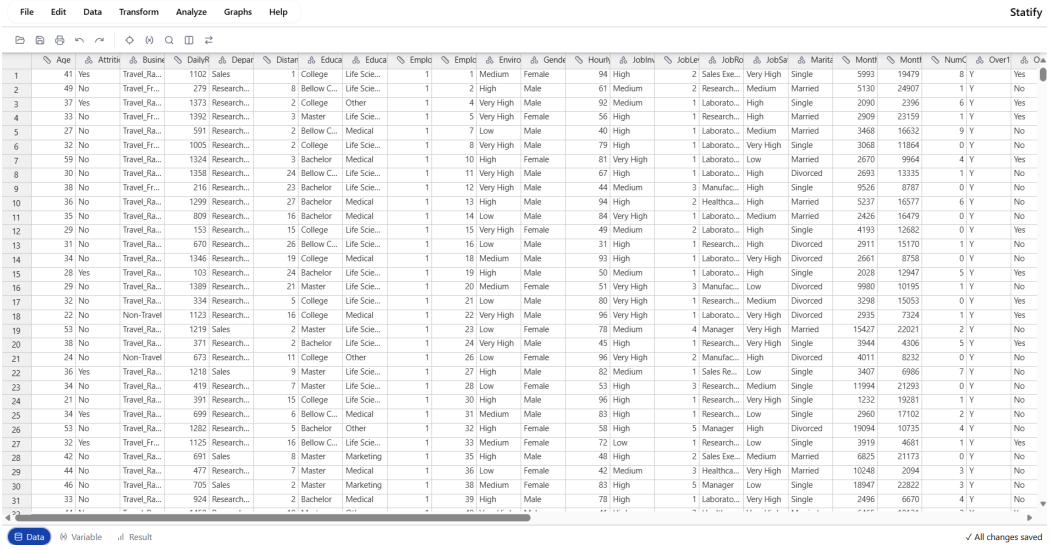
4. Klik untuk memilih dataset yang sudah diunduh sebelumnya.



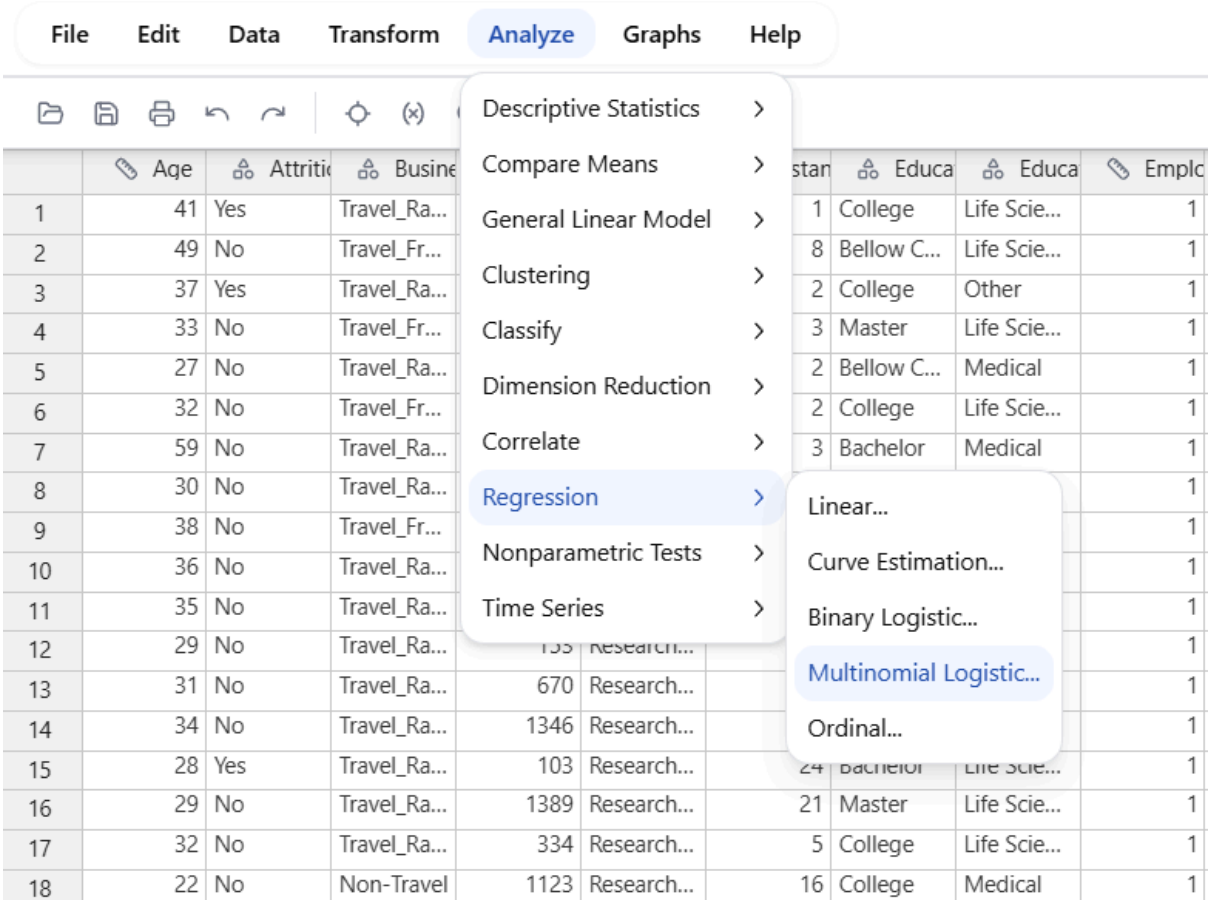
5. Klik **Continue** untuk melanjutkan.
6. Konfigurasi import data sesuai dengan gambar di bawah ini. Perhatikan bagian **Data Preview** untuk mengecek data yang diimport.



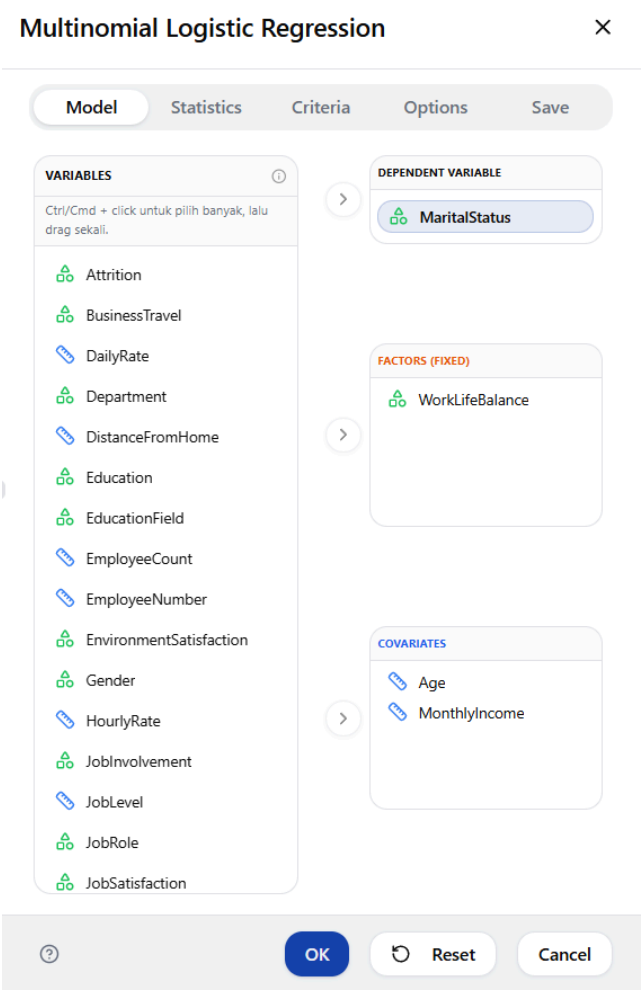
7. Klik **Import Data** untuk melanjutkan,



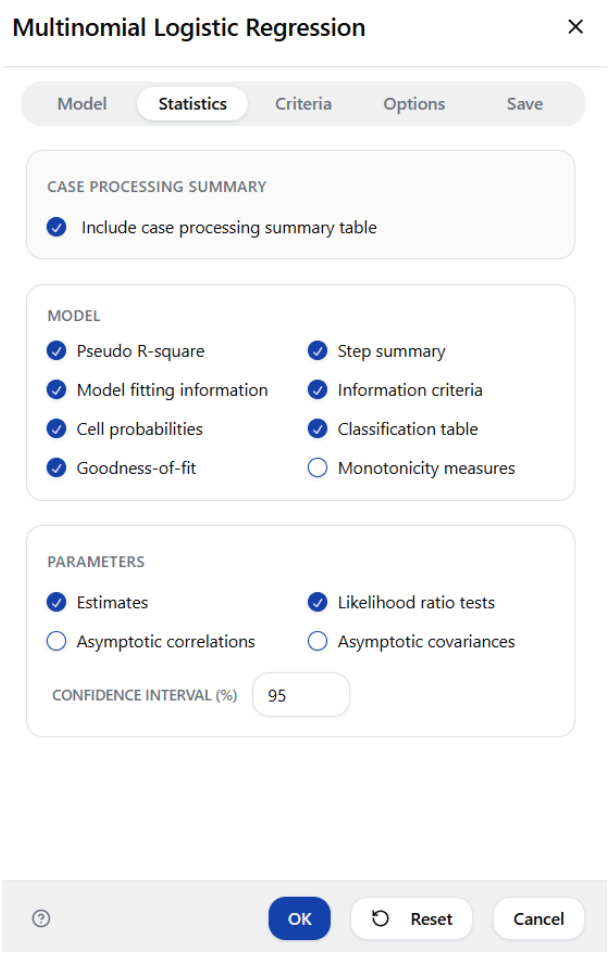
8. Klik Analyze → Regression → Multinomial Logistic.



9. Drag variabel **MaritalStatus** ke **Dependent Variable**, **WorkLifeBalance** ke **Factors (Fixed)**, dan variabel **Age dan MonthlyIncome** ke **Covariates**.



10. Klik tab **Statistics** untuk menentuk analisis yang akan kita gunakan.

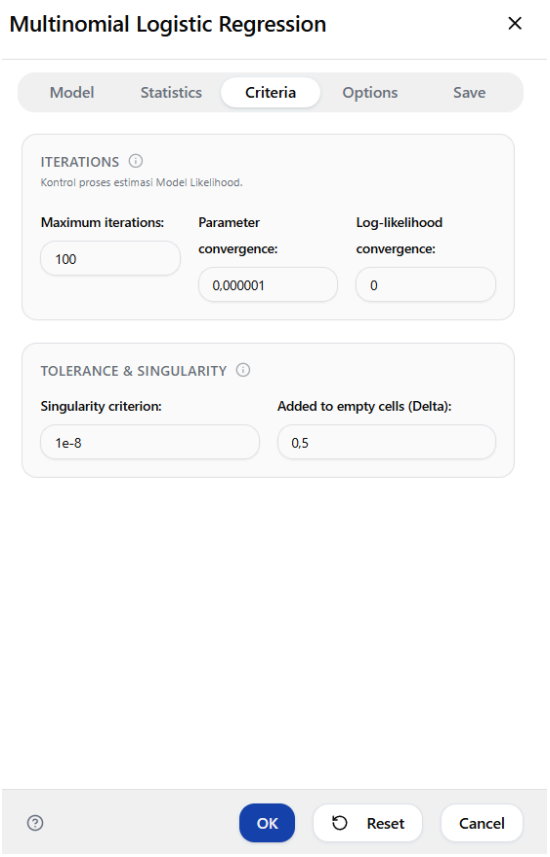


Keterangan :

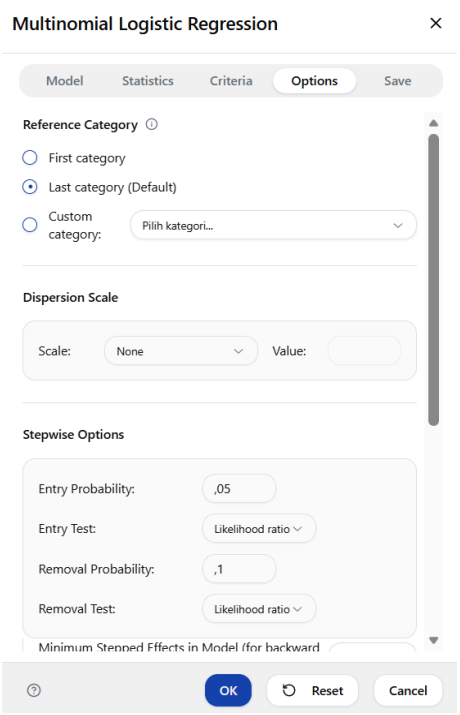
- **Pseudo R-square** : Menampilkan nilai **Cox & Snell R^2**, **Nagelkerke R^2**, dan **McFadden R^2** sebagai ukuran kemampuan model dalam menjelaskan variasi pada variabel dependen.
- **Step summary** : Menampilkan ringkasan proses estimasi model, termasuk status konvergensi dan jumlah iterasi **Newton-Raphson**, serta riwayat penambahan atau pengurangan variabel apabila menggunakan metode *Stepwise*.
- **Model fitting information** : Menampilkan perbandingan nilai **-2 Log Likelihood**, **Chi-Square (χ^2)**, *df*, dan *p-value* antara model tanpa prediktor (*Intercept Only*) dan model penuh (*Final*) untuk mengevaluasi peningkatan kesesuaian model.
- **Information criteria** : Menampilkan nilai **Akaike Information Criterion (AIC)** dan **Bayesian Information Criterion (BIC)** yang digunakan untuk membandingkan dan mengevaluasi beberapa model, dengan nilai yang lebih kecil menunjukkan model yang relatif lebih optimal.
- **Cell probabilities** : Menampilkan estimasi probabilitas keanggotaan setiap kombinasi nilai prediktor (*subpopulation/cells*) pada masing-masing kategori variabel dependen.

- **Classification table** : Menampilkan matriks klasifikasi yang membandingkan kategori aktual dengan kategori hasil prediksi model, termasuk persentase ketepatan klasifikasi dan akurasi keseluruhan.
- **Goodness-of-fit** : Menampilkan hasil uji kesesuaian model menggunakan **Pearson Chi-Square** dan **Deviance Chi-Square**, beserta *df* dan *p-value*, untuk mengevaluasi kesesuaian model dengan data observasi.
- **Monotonicity measures** : Menampilkan ukuran korelasi peringkat, seperti **Spearman's Rho**, untuk mengevaluasi keselarasan urutan kategori hasil prediksi dengan kategori observasi aktual.

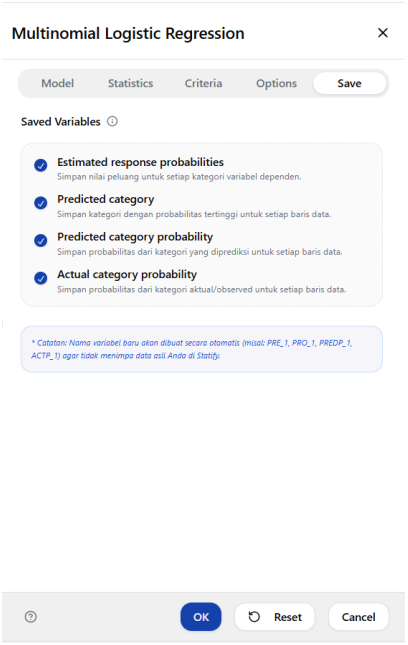
11. Lalu klik tab **Criteria** untuk menentukan kriteria yang akan kita gunakan pada alogaritma Regresi Multinomial.



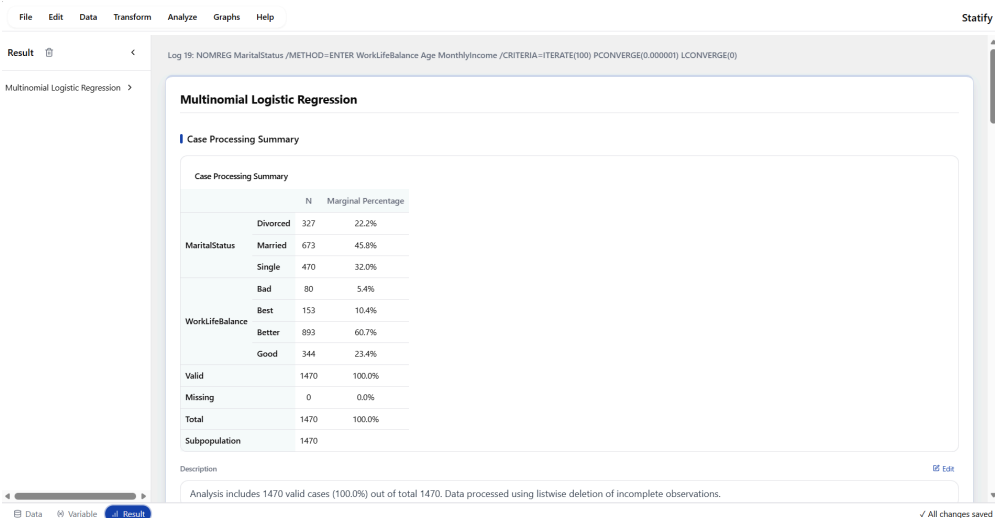
12. Pada tab **Option** kita dapat mengedit kategori referensi, Dispersion Scale, Stepwise Option, dan Hierarchy.



13. Untuk menyimpan Variabel prediksi klik tab **Save.** Kemudian pilih variabel yang akan disimpan.



14. Klik **Ok** untuk memproses model. Hasil analisis akan keluar pada tab **Result**



Keterangan :

Keterangan :

- **Case Processing Summary**: Menampilkan ringkasan jumlah dan persentase observasi yang valid (*Valid Cases*), data hilang (*Missing Cases*), serta total observasi yang digunakan dalam analisis setelah penerapan *listwise deletion*.
- **Model Fitting Information**: Menampilkan perbandingan nilai *-2 Log Likelihood* antara model tanpa prediktor (*Intercept Only*) dan model dengan seluruh prediktor (*Final*), serta statistik Chi-Square (χ^2), *df*, dan *p-value* untuk menguji signifikansi model secara simultan.
- **Pseudo R-Square**: Menampilkan nilai **Cox & Snell R^2**, **Nagelkerke R^2**, dan **McFadden R^2** sebagai ukuran kemampuan model dalam menjelaskan variasi pada variabel dependen.
- **Goodness-of-Fit**: Menampilkan hasil uji kesesuaian model menggunakan **Pearson Chi-Square** dan **Deviance Chi-Square**, beserta *df* dan *p-value*, untuk menilai kesesuaian model dengan data observasi.
- **Likelihood Ratio Tests**: Menampilkan kontribusi dan signifikansi masing-masing variabel prediktor terhadap model berdasarkan statistik Chi-Square (χ^2), *df*, dan *p-value* dari uji rasio likelihood.
- **Parameter Estimates**: Menampilkan estimasi koefisien regresi logistik (**B**), *Standard Error* (SE), statistik Wald, *df*, *p-value*, **Odds Ratio (Exp(B))**, serta **95% Confidence Interval** untuk setiap prediktor pada masing-masing kategori dibandingkan dengan kategori acuan (*reference category*).
- **Classification Table**: Menampilkan perbandingan antara kategori aktual dan kategori hasil prediksi model dalam bentuk matriks klasifikasi, termasuk persentase ketepatan klasifikasi setiap kategori dan akurasi keseluruhan (*Overall Percentage Accuracy*).

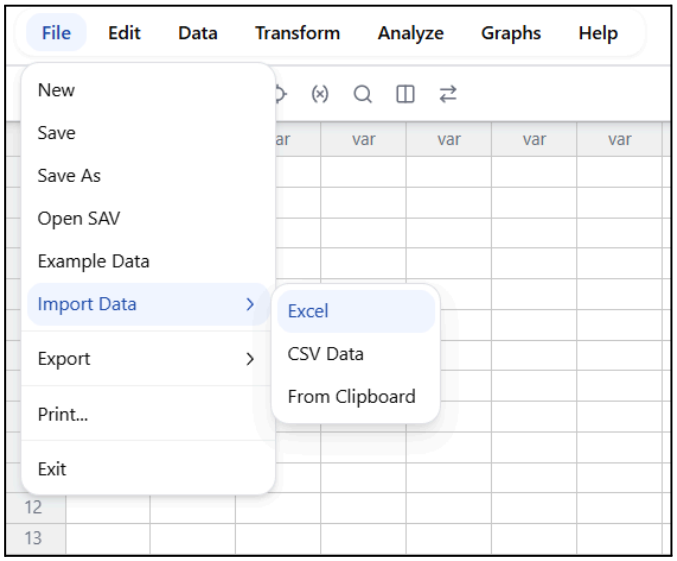
- **Asymptotic Covariance & Correlation Matrix**: Menampilkan matriks kovarians dan korelasi antarestimasi parameter untuk melihat hubungan atau ketergantungan antarparameter dalam model.
- **Step Summary / Stepwise Trace (Opsional)**: Menampilkan proses penambahan atau pengurangan variabel prediktor pada setiap tahap (*step*) apabila analisis menggunakan metode seleksi *Stepwise*, baik *Forward* maupun *Backward*.
- **Monotonicity & Cell Probabilities (Opsional)**: Menampilkan probabilitas keanggotaan kategori untuk setiap observasi serta ukuran monotonisitas, seperti korelasi peringkat Spearman (*Spearman's rank correlation*), antara kategori aktual dan hasil prediksi.

Analisis menggunakan data dengan bobot

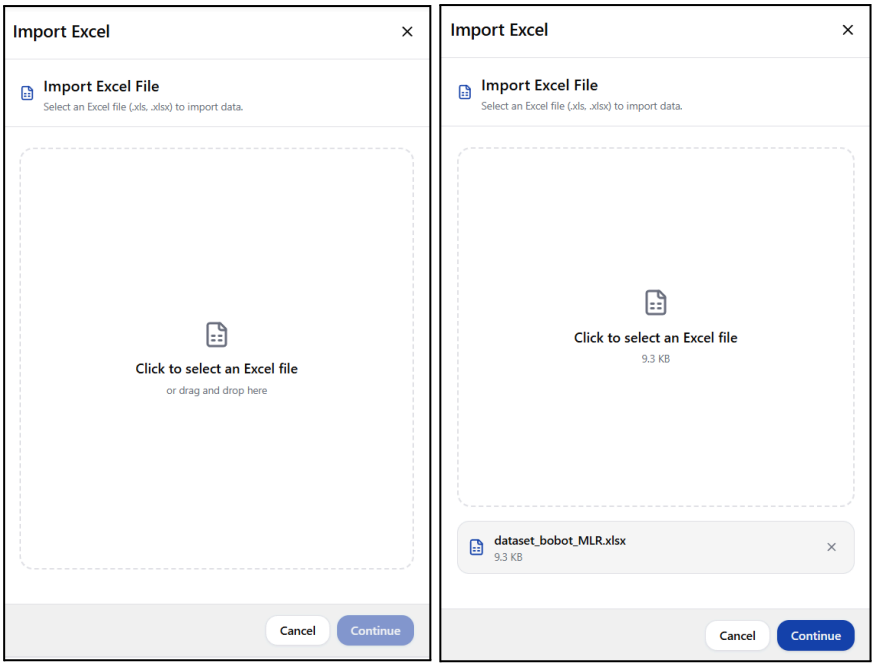
Analisis dilakukan menggunakan data yang telah diolah dan dikalibrasi dengan menerapkan bobot sampel (sampling weights) untuk memastikan representativitas estimasi terhadap populasi. Penerapan penimbang ini krusial dalam mengakomodasi probabilitas penarikan sampel yang tidak seragam serta mengoreksi potensi bias non-respons, sehingga parameter model regresi logistik multinomial yang dihasilkan dapat mencerminkan karakteristik populasi secara akurat.

a. Tahapan input data

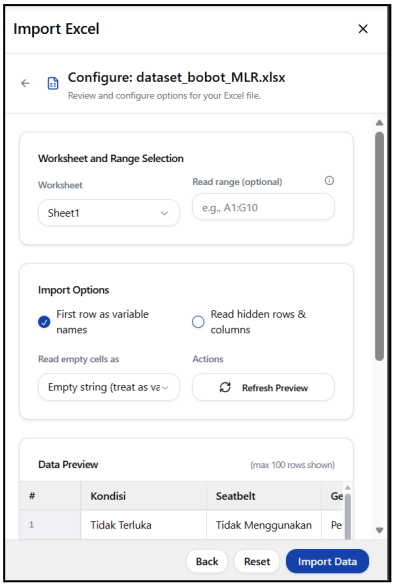
1. Silahkan unduh data berikut Dataset Bobot MLR
2. Buka situs web Statify https://statify-dev.student.stis.ac.id/dashboard/data
3. Klik **File → Import Data → Excel Data.**



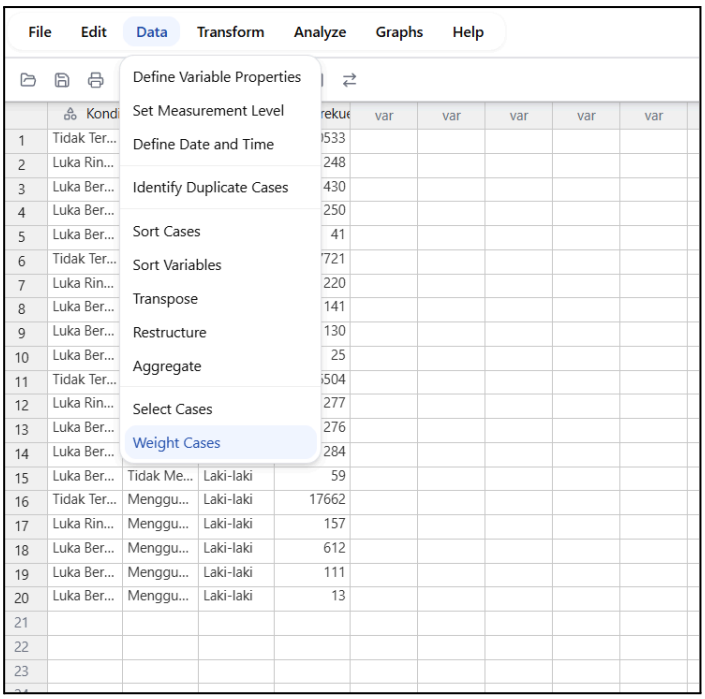
4. Klik untuk memilih dataset yang sudah diunduh sebelumnya.



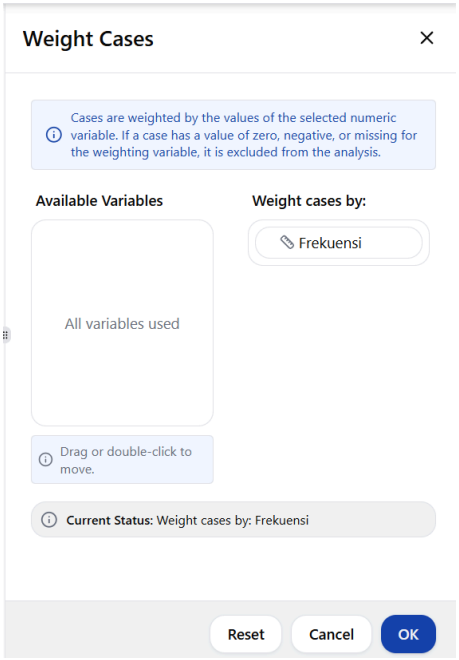
5. Klik **Continue** untuk melanjutkan.



6. Konfigurasi import data sesuai dengan gambar di bawah ini. Perhatikan bagian **Data Preview** untuk mengecek data yang diimport.
7. Klik **Import Data** untuk melanjutkan,
8. Kemudian klik **Data → Weight Cases** untuk melakukan pembobotan berdasarkan frekuensi.



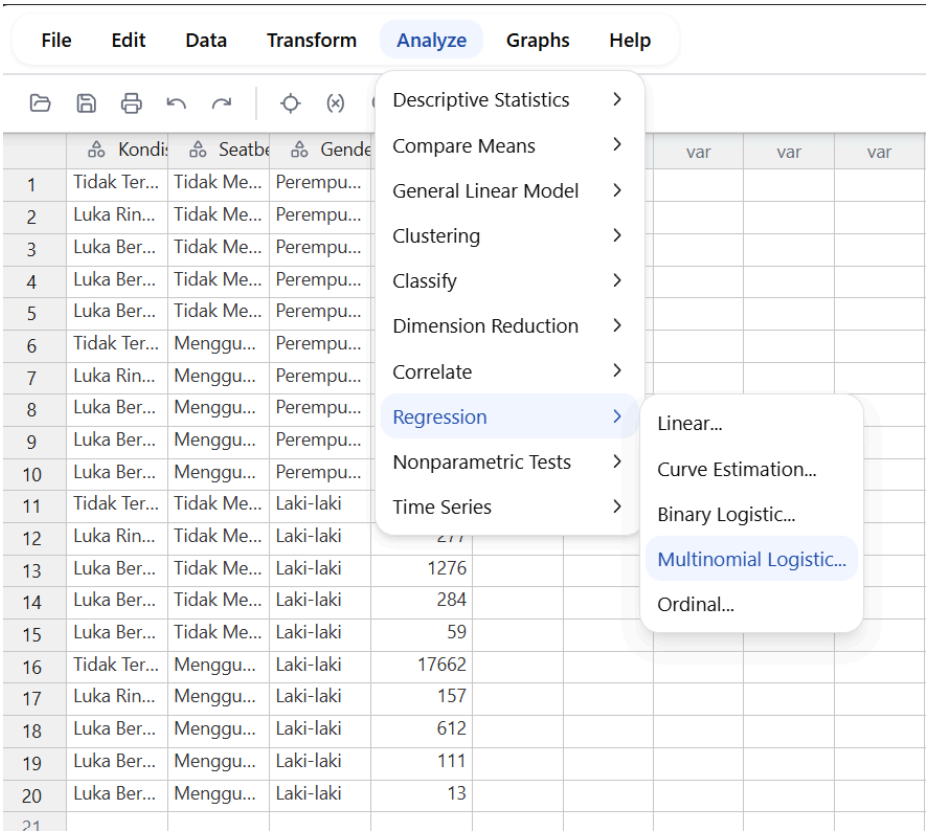
9. Lalu drag variabel **frekuensi** ke kolom **Weight cases by**.



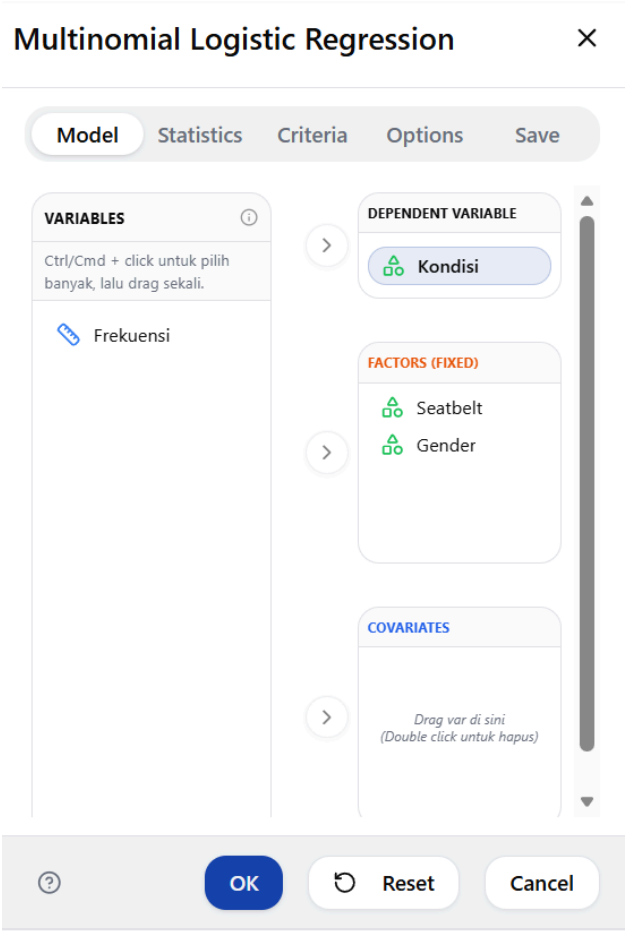
10. Klik **OK**, data tersebut telah selesai dilakukan pembobotan.

b. Tahapan analisis Regresi Multinomial

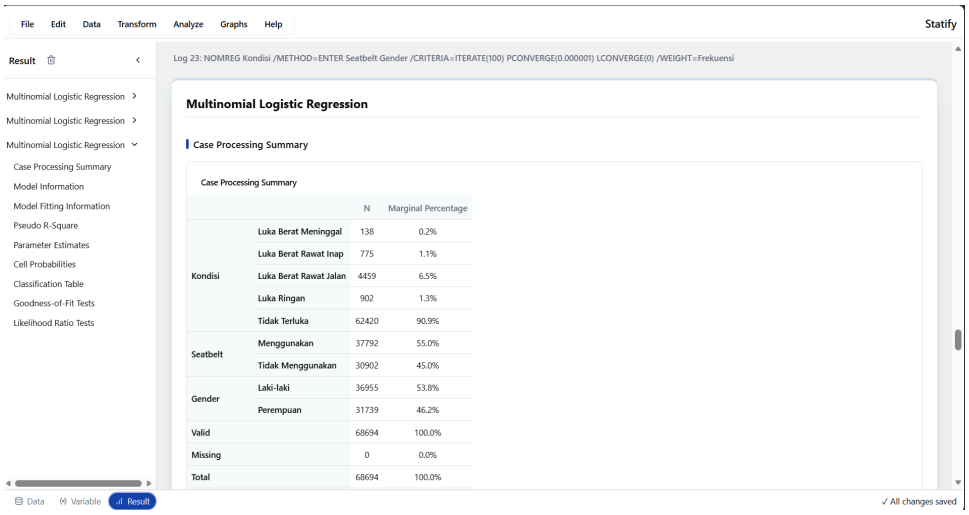
1. Klik **Analyze → Regression → Multinomial Logistic**.



2. Drag variabel **Kondisi** ke kolom **Dependent Variable**, variabel **Seatbelt** dan **Gender** ke kolom **Factors (Fixed)**.



3. Untuk tab Statistics, Criteria ,Option, dan Save dapat disesuaikan dengan kebutuhan analisis pada demo ini menggunakan default aplikasi. Klik OK



4. Hasil analisis akan ditampilkan pada tab **Result**.

MODUL ANALISIS DISKRIMINAN

E. Deskripsi Singkat

Analisis diskriminan dilakukan untuk membentuk fungsi pembeda dari sekumpulan variabel independen berskala numerik guna memisahkan objek ke dalam kelompok yang telah ditetapkan sebelumnya, sekaligus mengklasifikasikan objek baru ke dalam salah satu kelompok tersebut. Sistem akan memeriksa pemenuhan asumsi, membentuk fungsi diskriminan, serta menunjukkan kontribusi masing-masing variabel terhadap pemisahan kelompok dengan matriks struktur. Selain pembentukan fungsi, pengguna juga akan diperlihatkan hasil klasifikasi beserta ketepatannya, validasi silang leave-one-out, dan visualisasi ruang diskriminan berupa combined-groups plot, separate-groups plot, serta territorial map untuk memahami pola pemisahan antarkelompok. .

F. Tujuan Demonstrasi

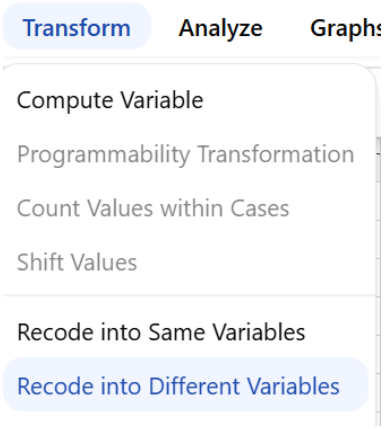
Panduan penggunaan ini bertujuan untuk memberikan pemahaman praktis mengenai tahapan pelaksanaan analisis diskriminan menggunakan perangkat lunak Statify. Kegiatan demonstrasi mencakup pemeriksaan asumsi, pengaturan variabel dan parameter analisis, pemilihan metode pemodelan, proses pembentukan fungsi diskriminan, hingga hasil pembacaan hasil klasifikasi dan evaluasi ketepatan model.

G. Material Demonstrasi

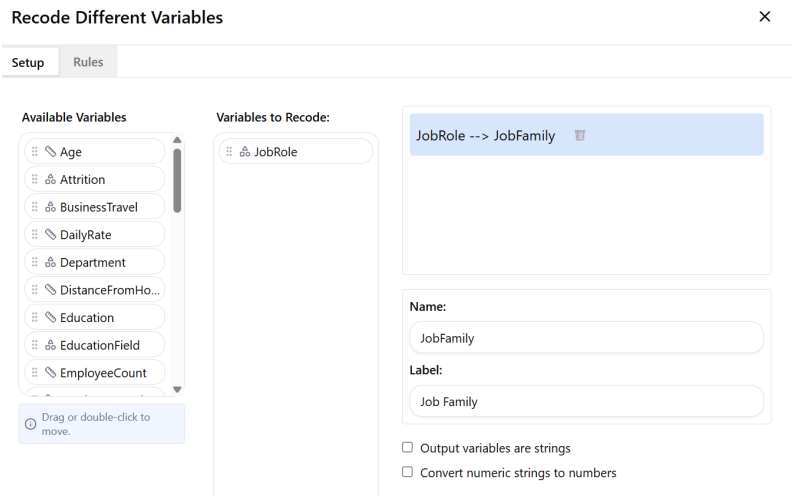
4. Dataset yang dapat diakses pada https://s.stis.ac.id/dataset_demoStatify64
5. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/
6. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64

H. Kegiatan Demonstrasi

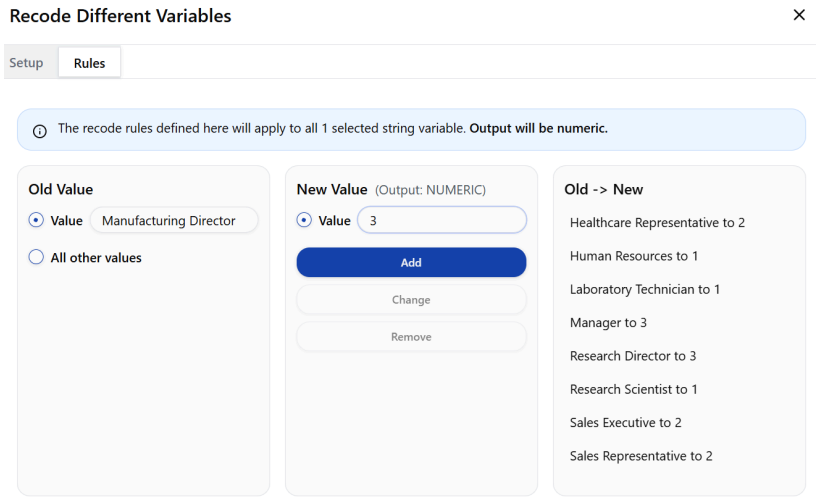
- Tahap persiapan dilakukan dengan mengimport dataset ke lembar kerja Statify. ***File > Import Data > CSV Data***. Jika tampilan/preview dataset berhasil muncul, maka tekan ***Impor.***
- Sebelum melakukan analisis diskriminan, lakukan Recode Into Different Variable dengan memilih menu ***Transform > Recode into Different Variables***.



- Pindahkan / *drag* variabel **JobRole** ke kotak Variables to Recode, lalu tekan variable **JobRole → JobRole_recoded**, dan ubah *name* menjadi **JobFamily** dan *label* menjadi **Job Family** seperti berikut.

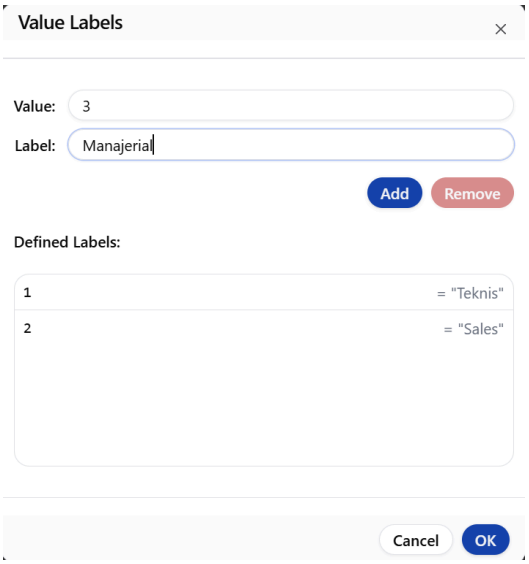


- Setelahnya, tekan tab ***Rules*** dan masukkan nama jabatan di *Old Value* dan isikan kode nya di *New Value* dan tekan ***add*** seperti berikut. Ulangi hingga kesembilan nilai **JobRole** selesai dipetakan. Penulisan nama jabatan harus sama persis dengan yang tertera pada data, termasuk penggunaan huruf besar dan spasinya.

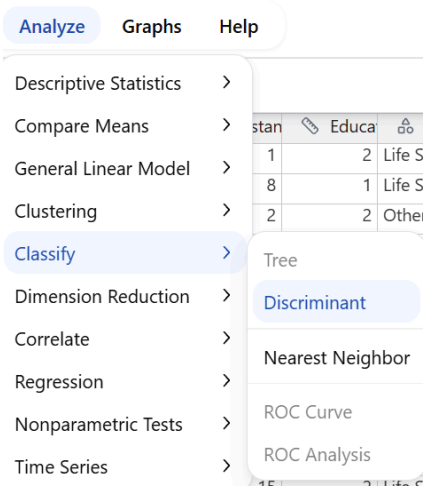


  - Laboratory Technician → 1
  - Research Scientist → 1
  - Human Resources → 1
  - Sales Executive → 2
  - Sales Representative → 2
  - Healthcare Representative → 2
  - Manager → 3
  - Research Director → 3
  - Manufacturing Director → 3

- Setelah itu tekan **Ok**, dan variabel **JobFamily** akan muncul sebagai variabel baru dan dapat dilihat pada kolom paling kanan.
- Buka tab **Variable** pada bagian bawah lembar kerja, lalu tekan kolom **Values** di baris **JobFamily**. Lengkapi keterangan variabel dengan label nilai 1 untuk Teknis, nilai 2 untuk Sales, dan nilai 3 untuk Manajerial. Setelah itu tekan **Ok**.



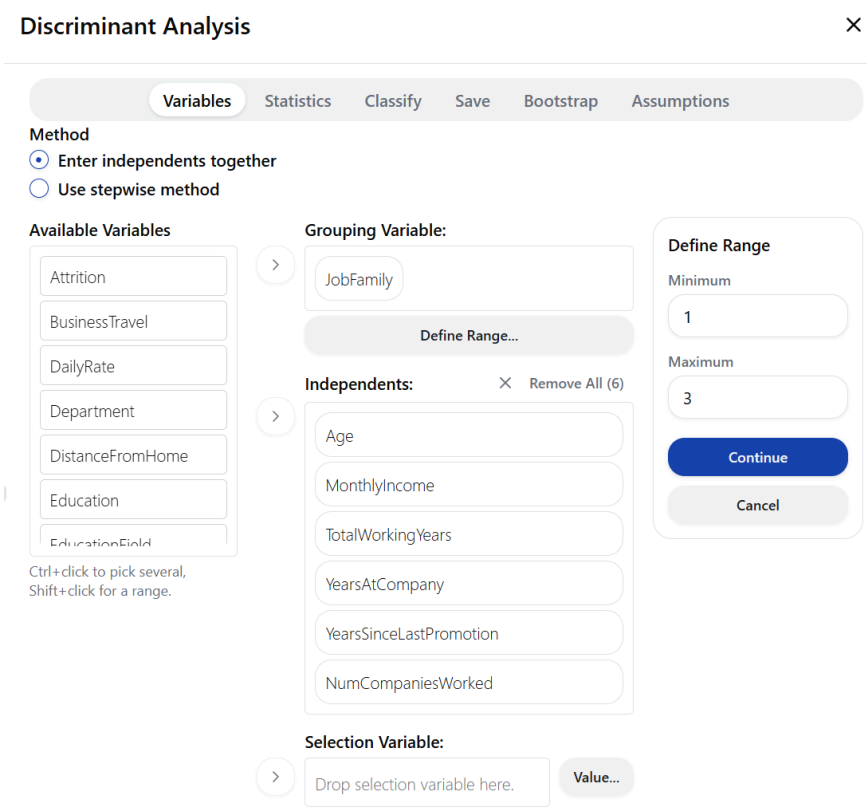
- Pilih menu ***Analyze > Classify > Discriminant***



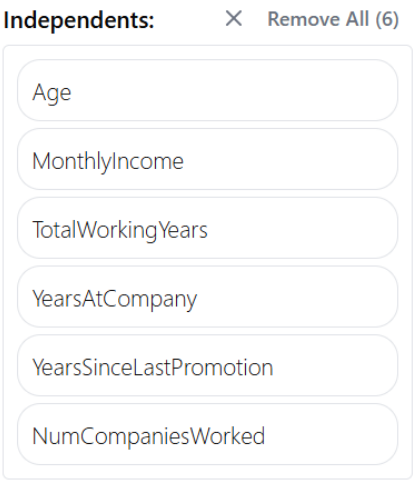
- Ketika menu **Discriminant** terbuka, klik tab **Variables**.

Skenario 1: Metode Enter Independents Together

- Pada bagian **Method**, pilih **Enter Independents Together** agar seluruh variabel independen diestimasi secara serentak.
- Lalu pindahkan variabel **Job Family** ke kotak **Grouping Variable** dengan cara *drag-and-drop* atau klik dua kali pada nama variabel.
- Klik tombol **Define Range**, lalu isikan **Minimum** dengan 1 dan **Maximum** dengan 3 sebagai berikut.

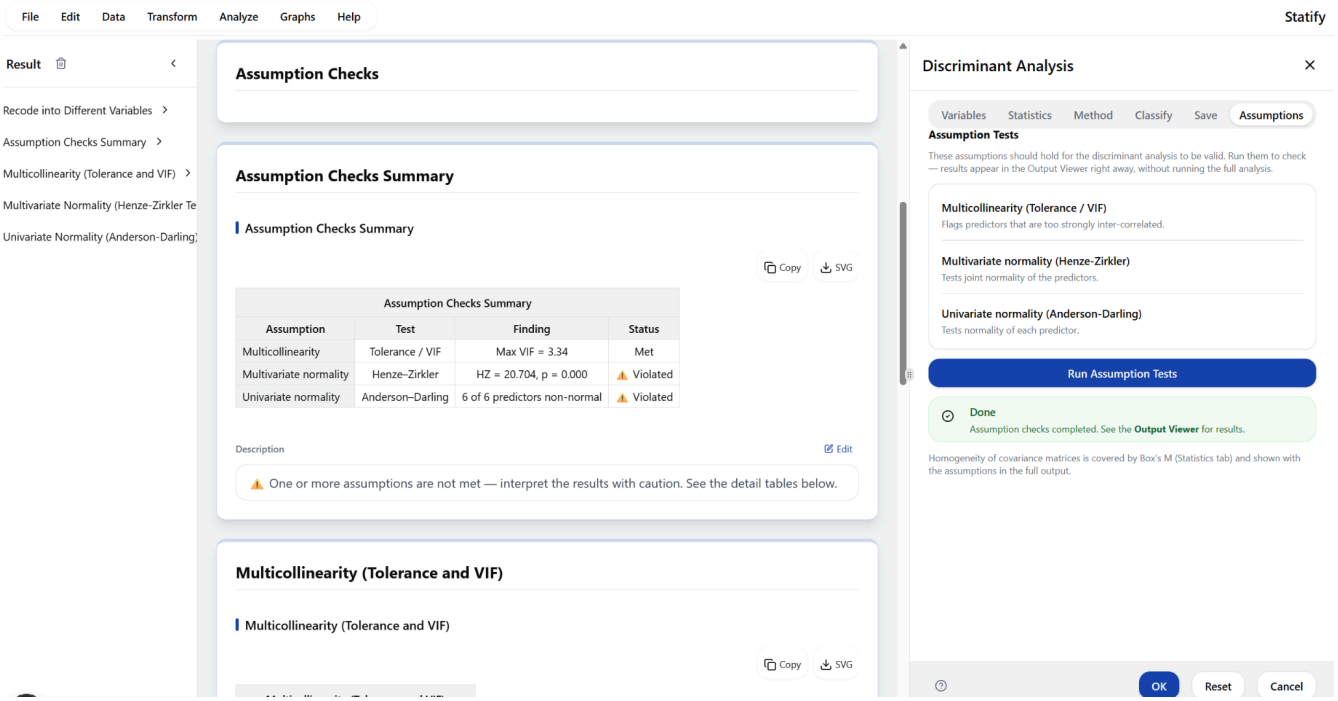


- Pindahkan enam variabel dengan cara *drag-and-drop* satu per satu atau pindahkan sekaligus dengan tekan Ctrl+klik atau Shift+klik, kemudian ditekan tombol panah. Keenam variabel diantaranya yaitu **Age**, **MonthlyIncome**, **TotalWorkingYears**, **YearsAtCompany**, **YearsSinceLastPromotion**, dan **NumCompaniesWorked** ke kotak **Independents** sebagai berikut.

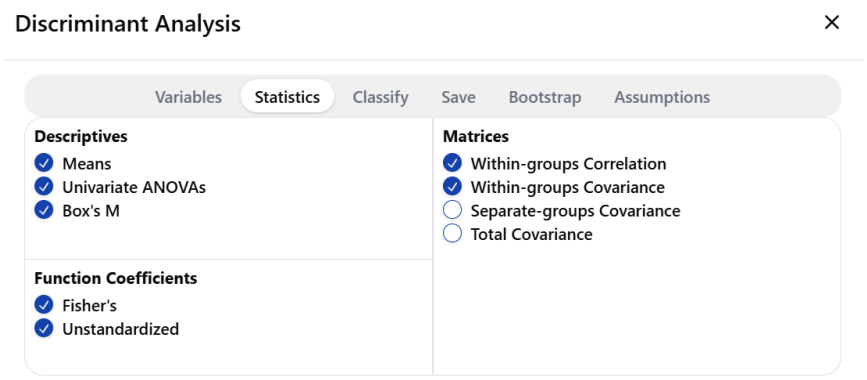


- Klik tab **Assumptions**. Sebelum fungsi diskriminan dibentuk, kelayakan data perlu diperiksa terlebih dahulu. Tekan tombol **Run Assumptions Tests** untuk menjalankan pemeriksaan multikolinearitas (Tolerance dan VIF), normalitas multivariat (uji Henze-Zirkler), serta

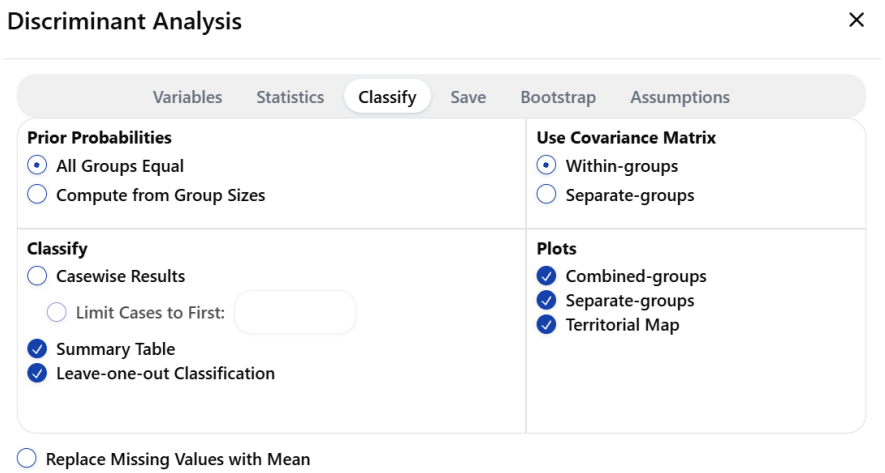
normalitas univariat setiap variabel independen (uji Anderson-Darling). Hasil pemeriksaan langsung dikirim ke halaman **Result** sebagai berikut.



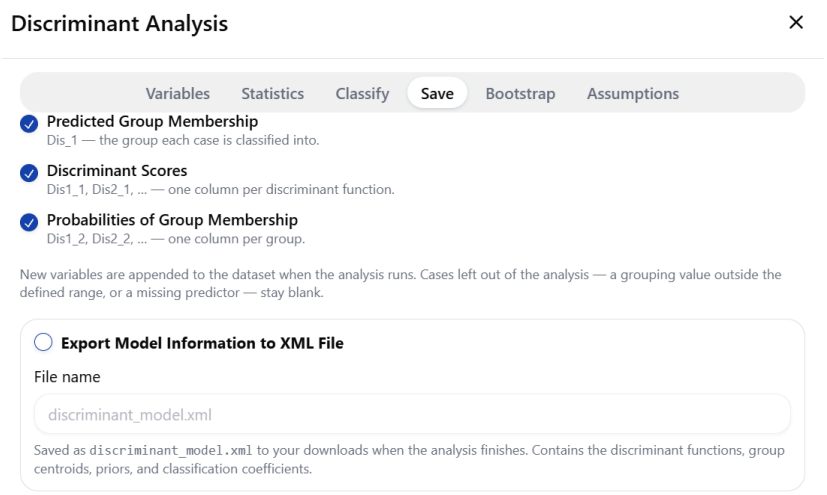
- Klik tab **Statistics**. Tab ini menentukan tabel deskriptif dan koefisien yang ditampilkan pada keluaran.
    - Pada kolom **Descriptives**, centang **Means** untuk menampilkan rata-rata dan simpangan baku setiap variabel pada masing-masing rumpun, **Univariate ANOVAs** untuk menguji perbedaan rata-rata setiap variabel antarkelompok secara terpisah, dan **Box's M** untuk menguji asumsi kesamaan matriks kovarians antarkelompok.
    - Pada kolom **Function Coefficients**, centang **Fisher's** untuk menampilkan koefisien fungsi klasifikasi dan **Unstandardized** untuk menampilkan koefisien fungsi diskriminan kanonik yang digunakan menghitung skor diskriminan setiap kasus.
    - Pada kolom **Matrices**, centang **Within-groups Correlation** dan **Within-groups Covariance** untuk menampilkan struktur hubungan antarvariabel setelah pengaruh kelompok dikeluarkan.



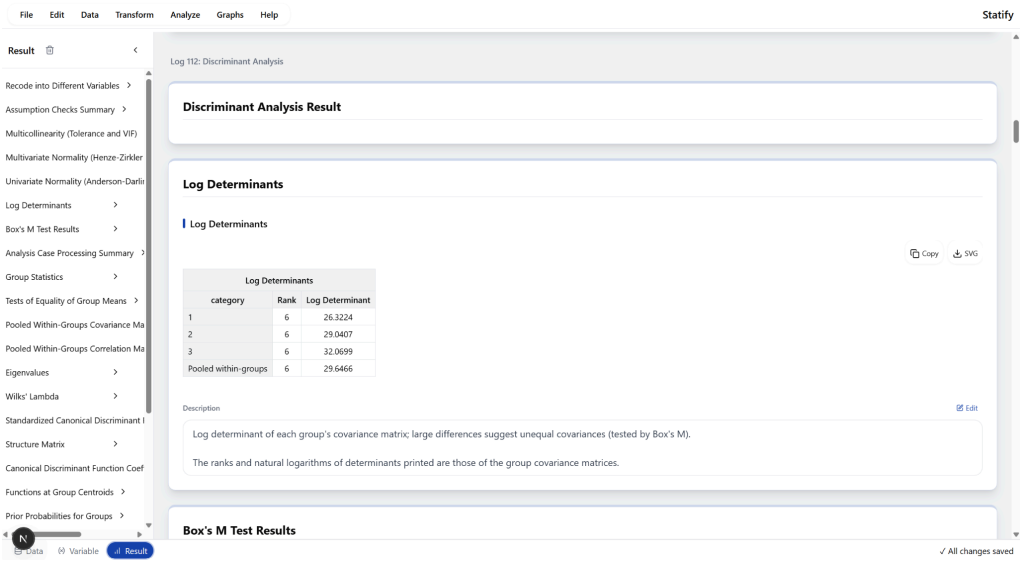
- Klik tab **Classify**. Tab ini mengatur aturan klasifikasi serta keluaran evaluasi dan visualisasinya.
    - Pada kolom **Prior Probabilities**, pilih **All groups equal** sehingga setiap rumpun diberi peluang awal sebesar 1/3.
    - Pada kolom **Use Covariance Matrix**, pilih **Within-groups** sesuai asumsi analisis diskriminan linier.
    - Pada kolom **Classify**, centang **Summary Table** untuk menampilkan matriks konfusi beserta persentase ketepatan klasifikasi, dan **Leave-one-out Classification** untuk memperoleh ketepatan hasil validasi silang.
    - Pada kolom **Plots**, centang **Combined-groups**, **Separate-groups**, dan **Territorial Map** untuk memvisualisasikan posisi kasus dan wilayah klasifikasi pada ruang diskriminan.



- Klik tab **Save** apabila hasil analisis ingin disimpan sebagai variabel baru pada lembar kerja. Centang **Predicted Group Membership** untuk menyimpan kelompok hasil prediksi, **Discriminant Scores** untuk menyimpan skor setiap fungsi, dan **Probabilities of Group Membership** untuk menyimpan peluang keanggotaan setiap kelompok. Variabel baru tersebut dapat dilihat kembali melalui tab Data.

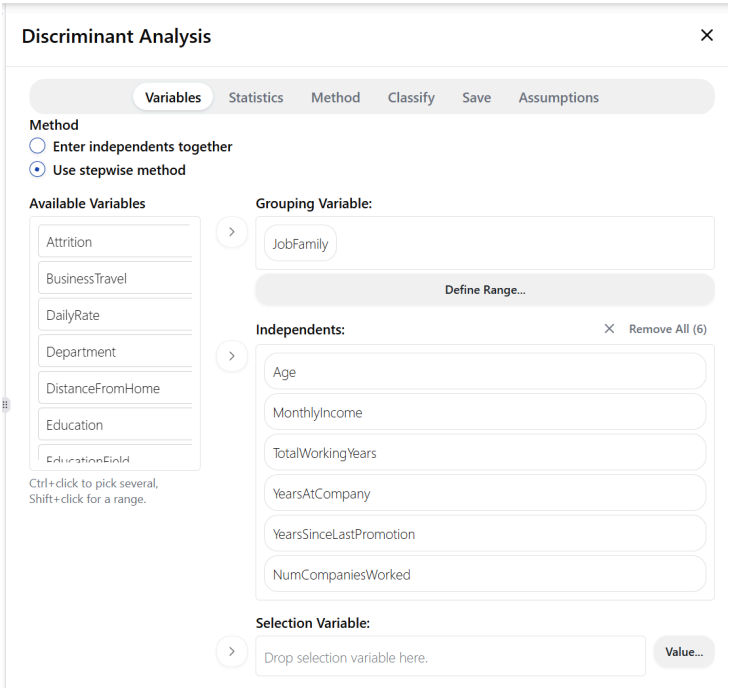


- Terakhir, klik **OK**. Tombol ini hanya aktif apabila variabel pengelompok dan sekurang-kurangnya satu variabel independen telah dipilih. Selanjutnya pengguna akan dipindahkan ke halaman **Result** untuk membaca keluaran analisis.

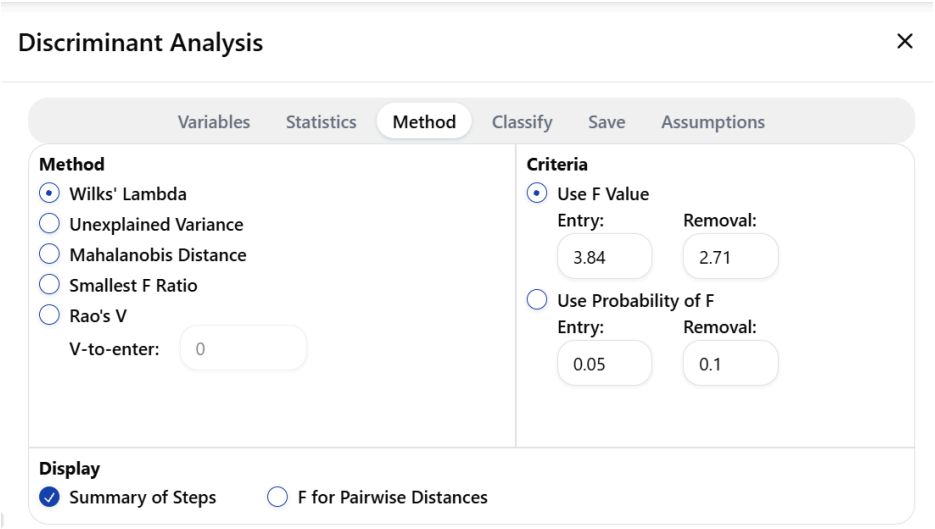


Skenario 2: Metode Use Stepwise Method

1. Buka kembali menu ***Analyze > Classify > Discriminant***. Konfigurasi variabel tidak perlu diulang karena aplikasi menyimpan hasil konfigurasi sebelumnya.
2. Pada tab **Variables**, pilih **Use Stepwise Method**. Ketika metode stepwise dipilih, tab **Method** akan muncul secara otomatis seperti berikut.



3. Klik tab **Method** dan pilih kriteria seleksi variabel. Statify menyediakan metode Wilks' Lambda, Unexplained Variance, Mahalanobis Distance, Smallest F Ratio, dan Rao's V. Pada demonstrasi ini digunakan metode **Wilks' Lambda** dengan kriteria bawaan, yaitu nilai F minimum untuk masuk sebesar 3,84 dan nilai F maksimum untuk keluar sebesar 2,71.
4. Pada bagian **display**, ceklis summary of steps. Tampilan akan menjadi seperti berikut.



5. Klik **OK**. Keluaran akan memuat tabel Variables Entered/Removed, Variables in the Analysis, Variables Not in the Analysis, dan Wilks' Lambda per langkah. Keluaran dapat diakses pada halaman **Result**.
6. Anda dapat melakukan uji coba dengan metode lain yang berbeda selain Wilks' Lambda, seperti Unexplained Variance, Mahalanobis Distance, Smallest F Ratio, dan Rao's V dengan mengganti method di tab **Method**.

MODUL NEAREST NEIGHBOR

1. Deskripsi Singkat

Analisis *Nearest Neighbor* dilakukan dalam rangka mengidentifikasi dan mengelompokkan pengamatan atau entitas terdekat berdasarkan ukuran jarak (*distance metric*) terhadap variabel predictor yang ditentukan. Sistem akan memproses perhitungan jarak antardata secara otomatis untuk menentukan *k* tetangga terdekat (*k-Nearest Neighbors*) atau memetakan kedekatan karakteristik antarsampel. Selain menghasilkan pemetaan dan klasifikasi/prediksi, pengguna akan diperlihatkan visualisasi sebaran data serta evaluasi tingkat akurasi model untuk memastikan ketepatan pengelompokan yang dihasilkan.

2. Tujuan Demonstrasi

Panduan penggunaan ini bertujuan sebagai panduan praktis dalam rangka penggunaan/demonstrasi perangkat lunak Statify untuk menjalankan dan menganalisis modul *Nearest Neighbor*. Panduan ini secara khusus difokuskan pada alur konfigurasi parameter jarak, penentuan jumlah tetangga (*k*), hingga pada tahap interpretasi hasil pemetaan dan evaluasi performa modelnya.

3. Material Demonstrasi

a. Dataset yang dapat diakses pada https://s.stis.ac.id/dataset_demoStatify64

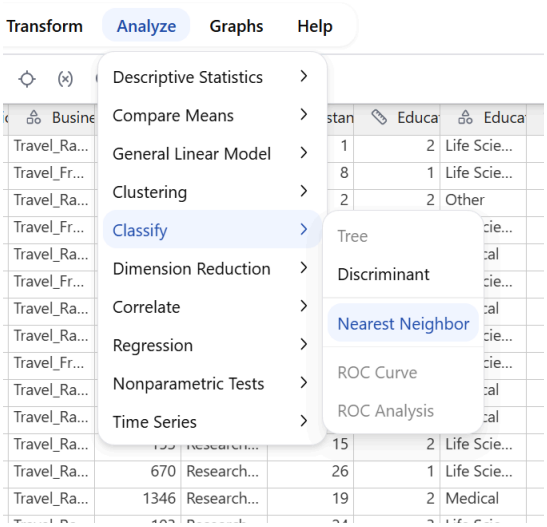
b. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/

c. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64

4. Kegiatan Demonstrasi

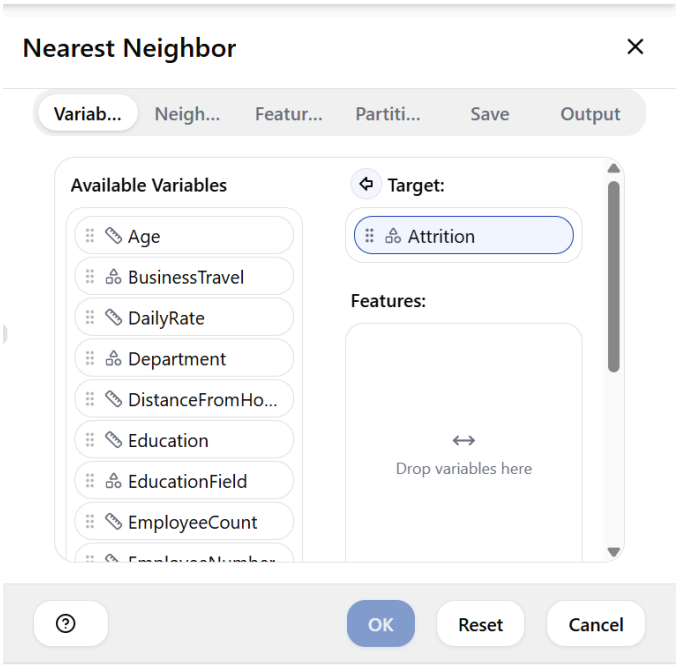
Tahap persiapan dilakukan dengan mengimport dataset ke lembar kerja Statify. *File* > *Import Data* > *CSV Data*. Jika tampilan/preview dataset berhasil muncul, maka tekan *Impor*.

Pilih menu *Analyze* > *Classify* > *Nearest Neighbor*

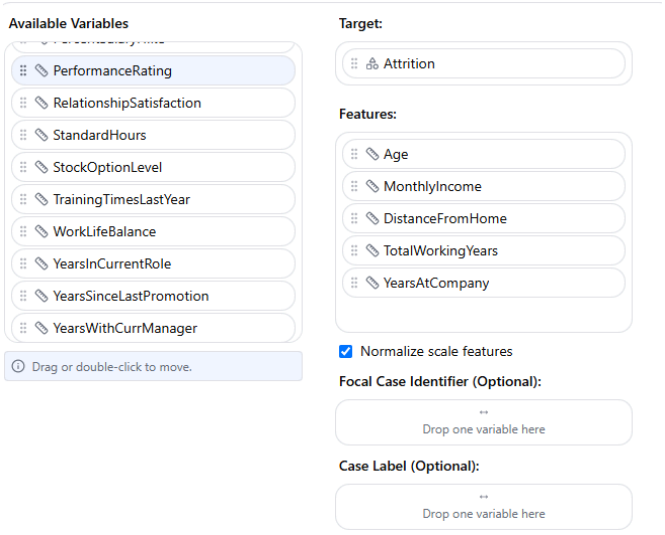


a. Skenario 1: Konfigurasi Default

1. Pengisian **Kolom Target** dapat dilakukan dengan fitur *drag-and-drop*, klik dua kali pada variabel, atau memilih variabel lalu mengklik tombol panah di samping Kolom Target. Pada demonstrasi ini, pilih Attrition sebagai variabel target (variabel yang akan diprediksi). Pada tahap ini akan menggunakan variabel kategorik terlebih dahulu untuk pengujian.



2. Pengisian Kolom Features dapat dilakukan dengan cara *drag-and-drop*, atau memilih variabel lalu mengklik tombol panah di samping Kolom Features. Pada demonstrasi ini, masukkan variabel-variabel penentu seperti Age, MonthlyIncome, DistanceFromHome, TotalWorkingYears, dan YearsAtCompany ke dalam Kolom Features (variabel bebas yang digunakan untuk menghitung jarak dan memetakan tetangga terdekat).



Pastikan “Normalize scale features” tercentang untuk menyamakan skala seluruh variabel fitur numerik, sehingga variabel dengan rentang nilai besar dalam nilai aslinya tidak mendominasi perhitungan jarak dibanding variabel berentang kecil.

3. Selain itu, di Tab Variabel terdapat Focal Case Identifier dan Case Label yang bersifat opsional, dapat digunakan jika dalam pengujian mahasiswa ingin mengeksplorasi modul ini.
   a. Focal Case Identifier

      Focal case adalah titik data spesifik yang ingin dianalisis secara mendalam untuk melihat siapa saja k tetangga terdekatnya. Variabel yang dimasukkan adalah variabel penanda bernilai positif di kasus/observasi mana yang ingin ditandai sebagai focal case. Hal ini tidak mempengaruhi analisis, hanya saja grafik yang dihasilkan nantinya ada penanda observasi Focal case.
   b. Case Label

      Variabel ini tidak digunakan dalam perhitungan matematis, melainkan hanya berfungsi sebagai label/nama pembeda di tampilan output, sehingga memudahkan Anda mengetahui observasi mana yang sedang diamati daripada hanya melihat nomor baris data.
4. Klik OK sehingga analisis berjalan dan memunculkan Halaman Output. Perhatikan bahwa Output yang muncul adalah sebagai berikut.
   a. Case Processing Summary

      Merangkum pembagian sampel data observasi yang digunakan, mencakup pembagian sampel (*training* dan *holdout*), jumlah total sampel yang memenuhi syarat dan diproses, serta jumlah data yang di-*exclude* karena mengandung *missing value*.
   b. Classification Table

      Tabel ini membandingkan kelas aktual (Observed) dengan kelas hasil prediksi model (Predicted) pada masing-masing partisi sampel:
      - Partition (Training & Holdout): Evaluasi performa klasifikasi dipisahkan berdasarkan kelompok sampel Training dan Holdout.
      - Observed vs. Predicted (No / Yes): Menunjukkan jumlah data observasi aktual untuk kategori kelas "No" atau "Yes" yang diprediksi dengan benar atau salah oleh model KNN.
      - Percent Correct: Persentase ketepatan klasifikasi untuk tiap-tiap kategori kelas target.
      - Overall Percent: Proporsi persentase distribusi hasil prediksi akhir model untuk setiap kelas target secara keseluruhan.

c. Error Summary

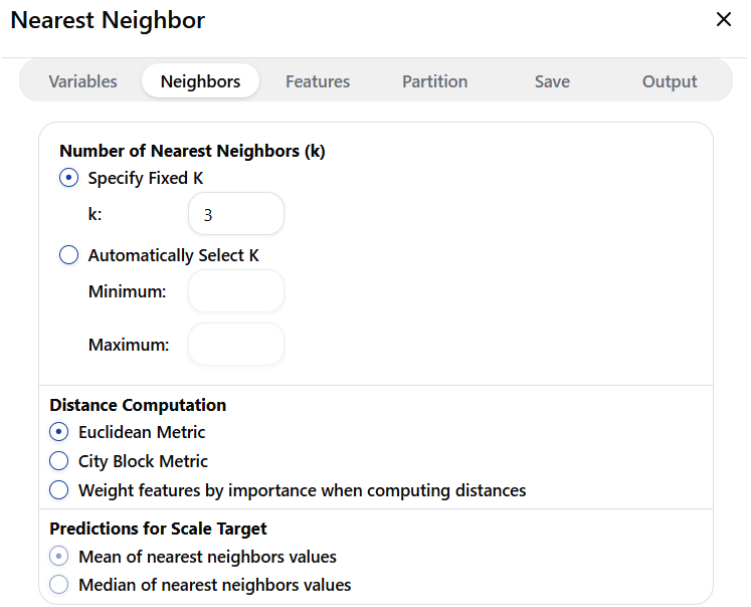
   Ringkasan tingkat kesalahan prediksi klasifikasi (*misclassification rate*) dari model yang terbentuk

d. Predictor Space

   Grafik 2 dimensi jika variabel features < 3, berbentuk 3D jika variable features ≥ 3.

b. Skenario 2: Konfigurasi pada Tab Neighbor

Kembali ke jendela Data, kemudian memilih *Nearest Neighbor* dan masuk ke Tab Neighbors. **Tab Neighbors** berfungsi untuk mengatur jumlah tetangga terdekat (*k*) yang digunakan dalam analisis, metode perhitungan jarak antarobservasi, serta metode prediksi jika variabel target berskala kontinu/skala. Secara *default*, tampilan pada tab **Neighbors** dikonfigurasi seperti pada gambar berikut.



1. Number of Nearest Neighbors (k)

   Opsi ini digunakan untuk menentukan berapa banyak tetangga terdekat yang akan dijadikan acuan dalam pemetakan atau klasifikasi:

   a. Specify Fixed K: Menentukan jumlah tetangga (k) secara manual dengan memasukkan angka spesifik tertentu (secara default bernilai 3).

   b. Automatically Select K: Membiarkan sistem mencari nilai k paling optimal secara otomatis berdasarkan batas rentang Minimum dan Maximum yang Anda tentukan. **Gunakan ini untuk pengujian skenario kedua dengan nilai minimum 3 dan maksimum 10.**

2. Distance Computation

   Opsi ini digunakan untuk memilih metode perhitungan jarak (distance metric) antar titik data/observasi:

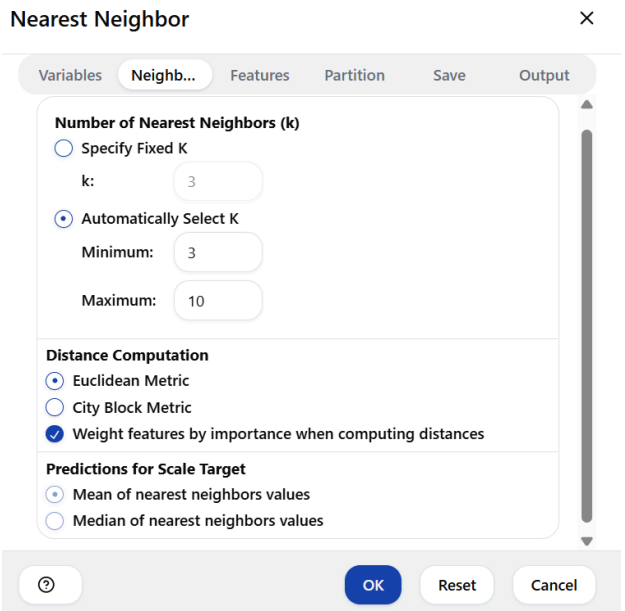
   a. Euclidean Metric: Menghitung jarak lurus (garis lurus) antara dua titik dalam ruang multidimensi. Metode ini merupakan opsi standar (default). **Gunakan metric ini untuk skenario ini.**
   b. City Block Metric (Manhattan Distance): Menghitung jarak berdasarkan total selisih mutlak dari setiap koordinat variabel.

3. Weight features by importance when computing distances memberikan bobot pada setiap variabel features berdasarkan tingkat kepentingannya saat menghitung jarak, sehingga variabel yang lebih berpengaruh memiliki efek lebih besar. **Centang pilihan ini untuk skenario kedua ini.**
4. Predictions for Scale Target

   Opsi ini khusus digunakan apabila variabel target yang dianalisis berupa data numerik/kontinu (bukan kategorikal):

   a. Mean of nearest neighbors values: Mengambil nilai rata-rata (mean) dari k tetangga terdekat sebagai hasil prediksi (default).
   b. Median of nearest neighbors values: Mengambil nilai tengah (median) dari k tetangga terdekat sebagai hasil prediksi (lebih tahan terhadap outlier).

5. Berikut merupakan konfigurasi saat ini:



   Klik OK untuk kemudian masuk ke halaman output.

6. Terdapat beberapa tambahan Output pada konfigurasi ini

   a. k Selection Error Log adalah grafik yang menampilkan proses evaluasi otomatis untuk menentukan nilai tetangga terdekat *k* paling optimal dalam algoritma

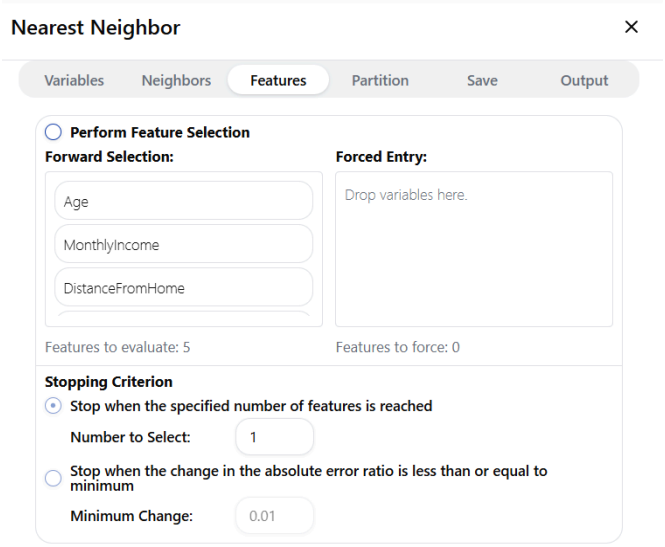
K-Nearest Neighbors,d alam rentang minimal hingga maksimal k. Sistem akan secara otomatis memilih *k* dengan *error* terendah.

b. Feature Importance Table memuat kalkulasi kontribusi prediktor berdasarkan metode sensitivitas penghapusan fitur (*leave-one-out feature importance*).

c. Predictor Importance Chart memvisualisasikan tingkat kontribusi relatif variabel prediktor berdasarkan nilai *Normalized Importance*.

c. Skenario 3: Konfigurasi pada Tab Features

Tab Features berfungsi untuk memilih dan menyaring variabel prediktor terbaik yang akan digunakan dalam pemodelan Nearest Neighbor, sehingga model menjadi lebih efisien dan terhindar dari variabel yang kurang relevan. Secara *default*, opsi seleksi fitur ini tidak diaktifkan (*disabled*) dan sistem akan menggunakan seluruh variabel yang telah dimasukkan di tab Variables pada kolom Features.



Sebelum melanjutkan, pada **Tab Neighbors nonaktifkan "**Weight features by importance when computing distance" terlebih dahulu.

1. Perform Feature Selection

   Centang opsi ini untuk melakukan pemilihan fitur secara otomatis menggunakan metode seleksi bertahap (Forward Selection).

   a. Forward Selection: Menampilkan daftar variabel calon fitur yang dievaluasi secara bertahap oleh sistem. Fitur akan ditambahkan satu per satu ke dalam model berdasarkan mana yang paling meningkatkan akurasi.

   b. Forced Entry: Tempat untuk memasukkan variabel tertentu yang wajib diikutsertakan dalam model Nearest Neighbor, tanpa melalui proses seleksi otomatis.

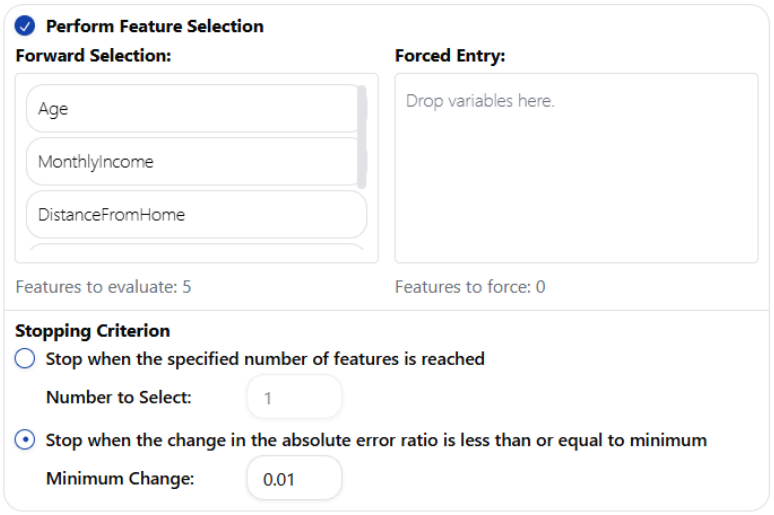
2. Stopping Criterion

   Opsi ini menentukan kriteria atau kapan sistem harus menghentikan proses penambahan variabel dalam Forward Selection:

   a. Stop when the specified number of features is reached: Menghentikan proses seleksi jika jumlah variabel yang terpilih sudah mencapai jumlah target yang ditentukan pada kolom Number to Select (misalnya bernilai 1 atau sesuai kebutuhan).

   b. Stop when the change in the absolute error ratio is less than or equal to minimum: Menghentikan proses seleksi jika penambahan variabel baru tidak lagi memberikan peningkatan performa/akurasi yang signifikan, yaitu ketika perubahan rasio absolute error sudah lebih kecil dari atau sama dengan nilai Minimum Change (secara default bernilai 0.01). **Centang pilihan ini**

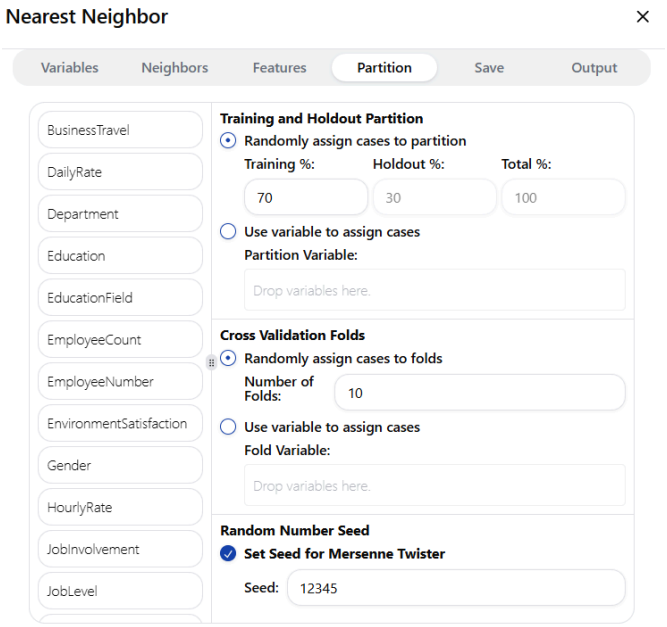
3. Berikut tampilannya setelah dilakukan konfigurasi pada Tab Features. Setelahitu klik OK.



4. Terdapat *output* yang berbeda lagi, yaitu k and Predictor Selection (Seleksi Nilai *k* dan Prediktor). Grafik ini memvisualisasikan alur kombinasi seleksi variabel prediktor secara bertahap menggunakan metode Forward Selection yang berjalan beriringan dengan penentuan nilai tetangga terdekat *k* secara otomatis. Hasilnya adalah grafik kombinasi jumlah *k* terbaik dan jumlah prediktor terbaik, yang memiliki *error* terkecil dalam proses Forward Selection.

d. Skenario 4: Konfigurasi pada Tab Partition

Tab Partition berfungsi untuk membagi data (dataset) menjadi subset data latih (*training*) dan data uji (*holdout*/*testing*), atau mengatur validasi silang (*cross-validation*) untuk menguji performa model secara obyektif.



Pada tahap ini akan digunakan Cross Validation Folds, sehingga perlu **menonaktifkan dahulu** "Perform Feature Selection" pada Tab Features

1. Training and Holdout Partition

   Opsi ini digunakan untuk membagi dataset menjadi data pembentukan model (training) dan data pengujian (holdout):

   a. Randomly assign cases to partition: Membagi sampel secara acak berdasarkan persentase yang ditentukan. Persentase default adalah 70% Training (digunakan untuk melatih model Nearest Neighbor) dan 30% Holdout (digunakan untuk menguji akurasi model).

   b. Use variable to assign cases: Membagi data berdasarkan indikator dari suatu variabel tertentu yang dimasukkan ke dalam kolom Partition Variable, yaitu kolom khusus berisikan 1 untuk data training, dan bilangan selain 1 untuk data holdout/test.

2. Cross Validation Folds

   Opsi ini aktif jika Anda memilih pencarian jumlah tetangga secara otomatis (Automatically Select K) pada tab Neighbors, guna mengevaluasi performa nilai k terbaik:

   a. Randomly assign cases to folds: Membagi data secara acak ke dalam sejumlah lipatan/grup (folds) yang ditentukan pada kolom Number of Folds (secara default 10 folds).

b. Use variable to assign cases: Mengelompokkan lipatan validasi berdasarkan kolom variabel tertentu yang dimasukkan pada kolom Fold Variable.

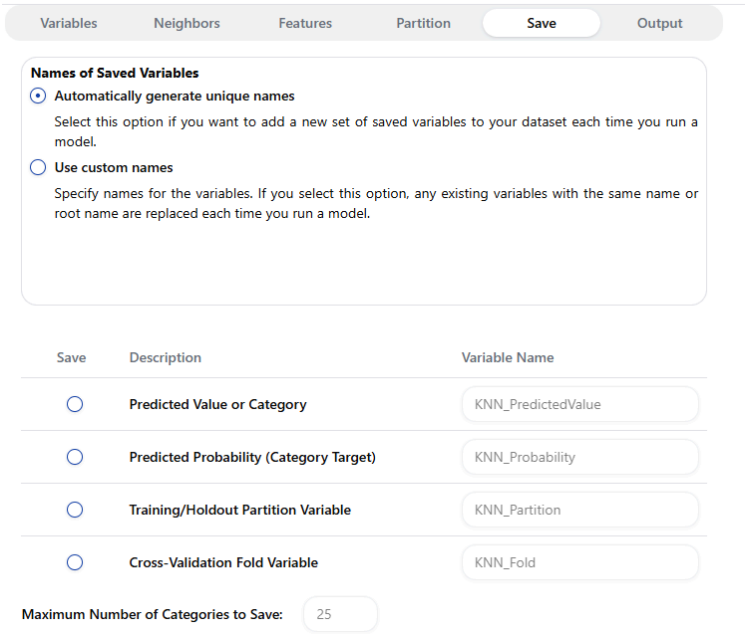
3. Random Number Seed

   Opsi ini digunakan untuk mengontrol pengacakan data agar hasil pembagian partisi dapat diulang kembali (*reproducible*). Centang ini untuk menetapkan angka acak awal (*seed*) pada kolom Seed. Jika nilai seed yang dimasukkan sama di pengujian berikutnya, maka pembagian data latih dan data uji akan menghasilkan acakan baris data yang persis sama. Pada pengujian ini gunakan angka 12345.

4. Klik OK. Output yang dihasilkan pada dasarnya sama dengan saat konfigurasi pada **Tab Neighbors** dengan pilihan Automatic Select K, Cross Fold Validation otomatis aktif. Jika ingin, pengguna dapat mengubah-ubah nilai Fold.

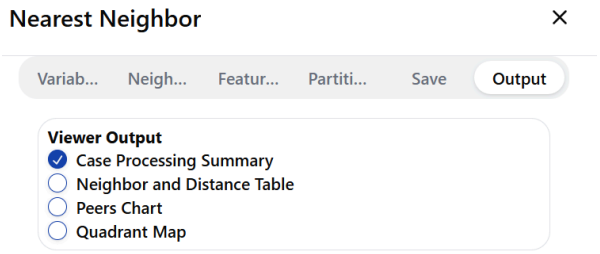
e. Save Variable dan Output

1. Tab Save



Tab Save digunakan untuk menyimpan hasil estimasi model, probabilitas prediksi, serta variabel pembagian sampel ke dalam dataset aktif sebagai kolom baru di jendela Data. Anda dapat memilih variabel baru apa yang ingin Anda simpan.

2. **Tab Output**



Tab Output digunakan untuk memilih jenis tabel ringkasan maupun visualisasi tambahan yang ingin ditampilkan pada panel hasil analisis (*Viewer Output*).

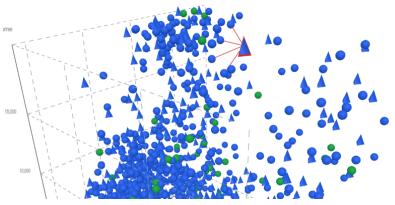
a. Neighbor and Distance Table menampilkan detail tetangga terdekat untuk setiap baris data. Nearest Neighbor adalah tetangga terdekat berada pada baris berapa, dan Nearest Distance adalah jarak antardata.

Neighbor Details

Neighbor Details								
Focal Record	Nearest Neighbor				Nearest Distance			
	1	2	3	4	1	2	3	4
1	598	1317	879	460	0.111	0.142	0.168	0.180
2	318	335	1143	931	0.182	0.263	0.295	0.347
3	491	119	378	1428	0.114	0.127	0.131	0.178
4	6	1086	1266	962	0.101	0.172	0.174	0.198
5	324	1057	999	406	0.085	0.126	0.130	0.133
6	4	1086	1114	215	0.101	0.146	0.147	0.161
7	226	701	233	898	0.255	0.265	0.336	0.367
8	1333	1137	1366	464	0.055	0.100	0.176	0.194
9	947	1451	769	993	0.272	0.272	0.299	0.299
10	1233	1430	410	399	0.180	0.288	0.357	0.360
11	607	1354	235	726	0.049	0.070	0.199	0.211
12	405	1234	1260	1335	0.163	0.172	0.176	0.181

b. Peers Chart

Klik salah satu titik data pada Prediction Space sehingga muncul garis jarak terhadap tetangga terdekatnya.



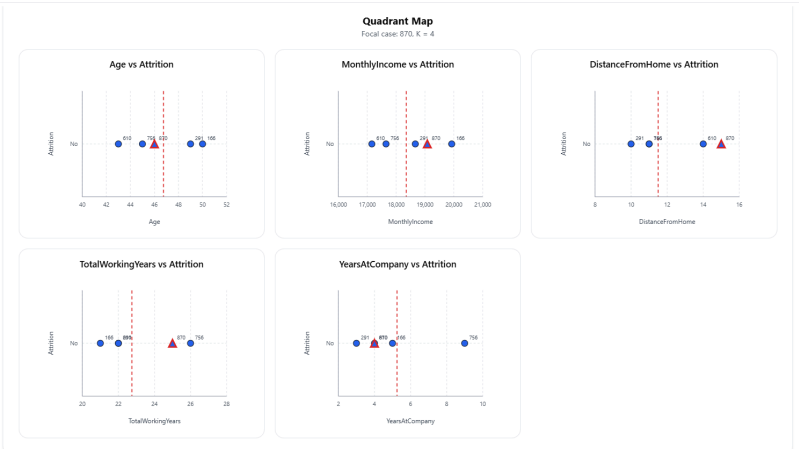
Maka pada Peers Chart akan ditampilkan grafik 2 dimensi sebanyak Feature yang digunakan pada klasifikasi dan letaknya terhadap tetangga terdekat pada

masing-masing Feature.



c. Quadrant Map

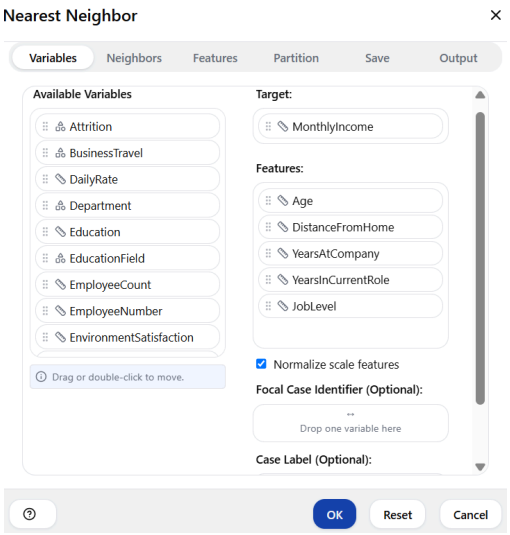
Jika pada Peers Chart menampilkan letak data terhadap tetangga terdekatnya, Quadrant Map menampilkan letak data terhadap rata-rata tetangga terdekatnya. Quadrant Map ini hanya untuk fitur numerik.



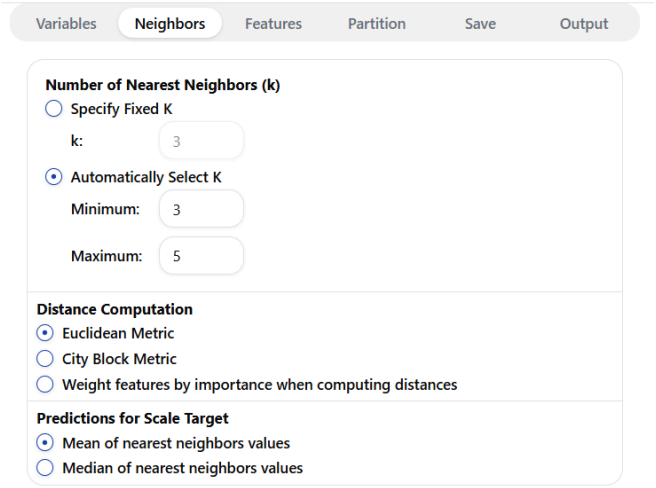
f. Skenario 5: Target berupa Numerik

Pada skenario sebelumnya, algoritma K-Nearest Neighbors (KNN) digunakan untuk menyelesaikan masalah klasifikasi, di mana variabel target berupa data kategorikal (memprediksi status Attrition: "Yes" atau "No"). Namun, algoritma KNN juga dapat digunakan untuk menyelesaikan kasus regresi, yaitu ketika variabel target yang ingin diprediksi bertipe numerik/kontinu. Prinsip dasar KNN Regresi tetap mengandalkan konsep kedekatan/kemiripan antar-observasi berdasarkan variabel prediktor.

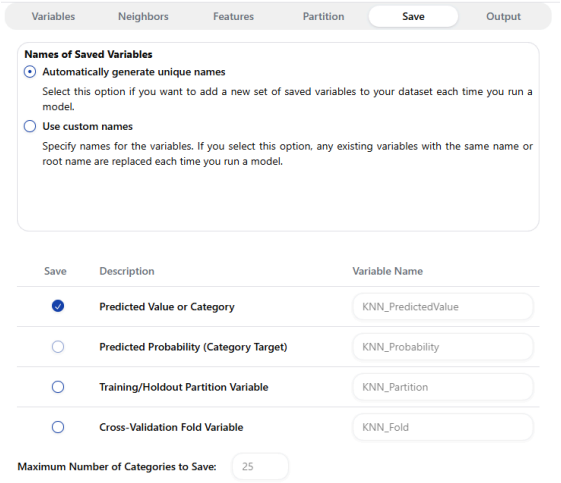
1. Gunakan variabel MonthlyIncome sebagai variabel target, sementara pada Features gunakan Age, DistanceFromHome, YearsAtCompany, YearsInCurrentRole, dan JobLevel.



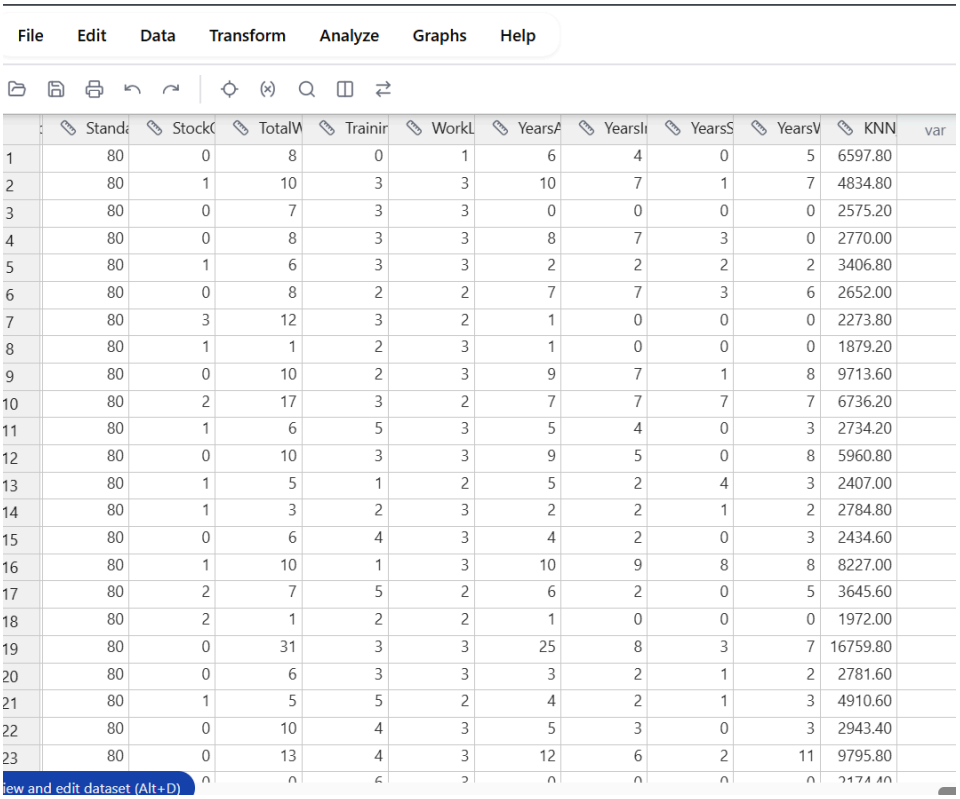
2. Selanjutnya pemilihan K otomatis dengan nilai min 3 dan max 5. Metrik penghitungan jarak gunakan Euclidean dan gunakan Mean untuk prediksi.



3. Kemudian pada Tab Save, pilih untuk menyimpan **Predicted Value or Category.** Tujuannya untuk membuat variabel baru hasil prediksi nilai MonthlyIncome.



4. Selanjutnya klik OK sehingga masuk ke Output Viewer. Kembali ke Jendela Data untuk melihat nilai hasil prediksi pada kolom paling kanan data.



File Edit Data Transform Analyze Graphs Help

	Standa	StockO	TotalW	Trainir	WorkL	YearsA	YearsIn	YearsS	YearsW	KNN	var
1	80	0	8	0	1	6	4	0	5	6597.80	
2	80	1	10	3	3	10	7	1	7	4834.80	
3	80	0	7	3	3	0	0	0	0	2575.20	
4	80	0	8	3	3	8	7	3	0	2770.00	
5	80	1	6	3	3	2	2	2	2	3406.80	
6	80	0	8	2	2	7	7	3	6	2652.00	
7	80	3	12	3	2	1	0	0	0	2273.80	
8	80	1	1	2	3	1	0	0	0	1879.20	
9	80	0	10	2	3	9	7	1	8	9713.60	
10	80	2	17	3	2	7	7	7	7	6736.20	
11	80	1	6	5	3	5	4	0	3	2734.20	
12	80	0	10	3	3	9	5	0	8	5960.80	
13	80	1	5	1	2	5	2	4	3	2407.00	
14	80	1	3	2	3	2	2	1	2	2784.80	
15	80	0	6	4	3	4	2	0	3	2434.60	
16	80	1	10	1	3	10	9	8	8	8227.00	
17	80	2	7	5	2	6	2	0	5	3645.60	
18	80	2	1	2	2	1	0	0	0	1972.00	
19	80	0	31	3	3	25	8	3	7	16759.80	
20	80	0	6	3	3	3	2	1	2	2781.60	
21	80	1	5	5	2	4	2	1	3	4910.60	
22	80	0	10	4	3	5	3	0	3	2943.40	
23	80	0	13	4	3	12	6	2	11	9795.80	

iew and edit dataset (Alt+D)

MODUL K-MEDOIDS

A. Deskripsi Singkat

Analisis K-Medoids dilakukan dalam rangka mengelompokkan (*clustering*) observasi ke dalam beberapa kelompok (*cluster*) berdasarkan kemiripan karakteristik pada variabel numerik yang ditentukan, tanpa memerlukan label kelompok sebelumnya. Berbeda dengan metode berbasis rata-rata seperti K-Means, pusat setiap kelompok pada K-Medoids adalah **medoid**, yaitu salah satu observasi nyata dari data yang memiliki total jarak terkecil ke seluruh anggota kelompoknya, sehingga hasilnya lebih tahan terhadap outlier dan lebih mudah diinterpretasikan sebagai kasus perwakilan. Sistem akan memproses perhitungan jarak antarobservasi secara otomatis untuk menentukan keanggotaan tiap cluster serta medoid yang mewakilinya. Selain menghasilkan pemetaan kelompok, pengguna akan diperlihatkan visualisasi sebaran cluster serta evaluasi kualitas pengelompokan (Silhouette dan Elbow) untuk memastikan ketepatan jumlah kelompok yang dihasilkan.

B. Tujuan Demonstrasi

Panduan penggunaan ini bertujuan sebagai panduan praktis dalam rangka penggunaan/demonstrasi perangkat lunak Statify untuk menjalankan dan menganalisis modul K-Medoids Clustering. Panduan ini secara khusus difokuskan pada alur konfigurasi ukuran jarak, pemilihan algoritma partisi (PAM, CLARA, CLARANS), penentuan jumlah *cluster* (k) baik secara manual maupun otomatis, hingga pada tahap interpretasi hasil pengelompokan dan evaluasi kualitas cluster yang dihasilkan.

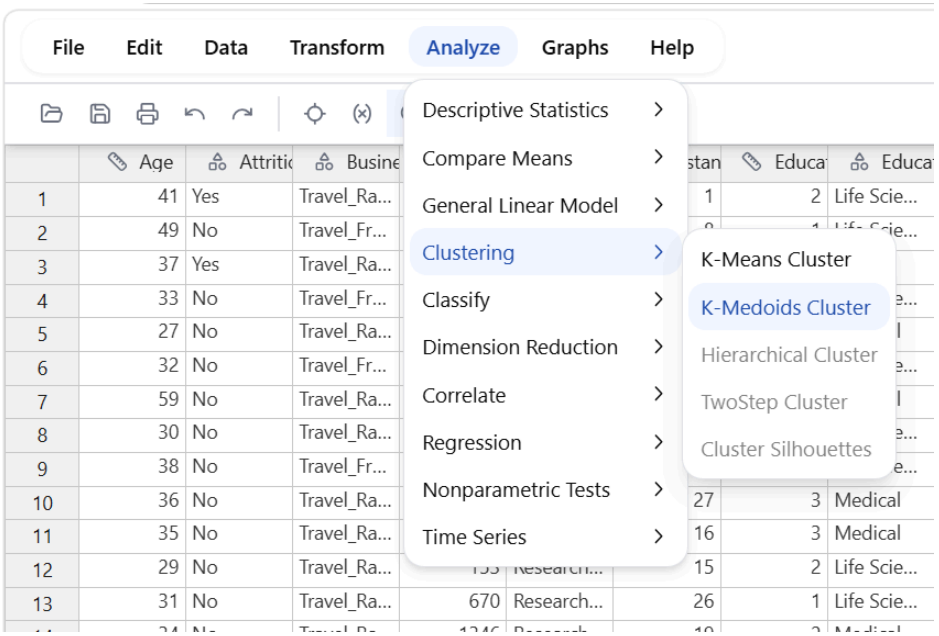
C. Material Demonstrasi

1. Dataset yang dapat diakses pada
2. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/
3. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64

D. Kegiatan Demonstrasi

Tahap persiapan dilakukan dengan mengimport dataset ke lembar kerja Statify. File > Import Data > CSV Data. Jika tampilan/preview dataset berhasil muncul, maka tekan Impor.

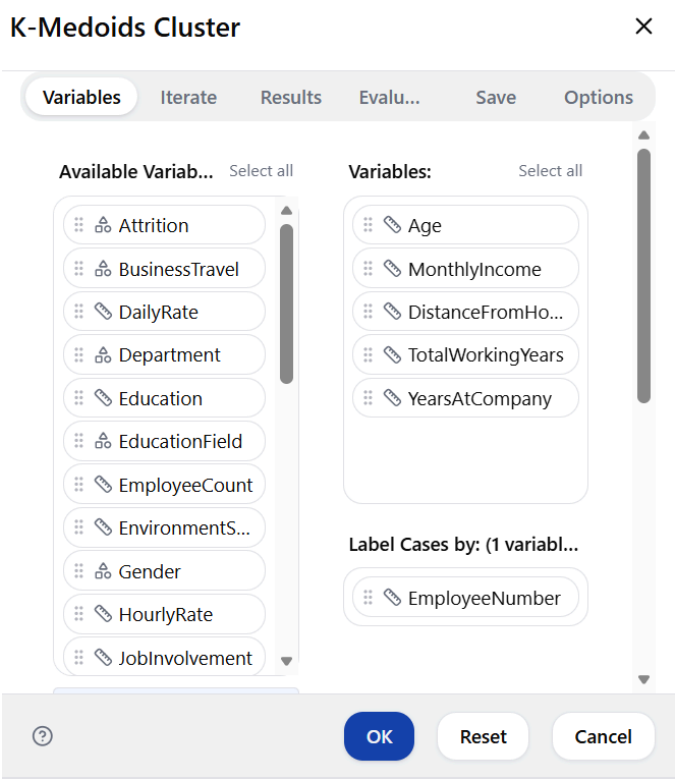
Pilih menu **Analyze > Clustering > K-Medoids Cluster**



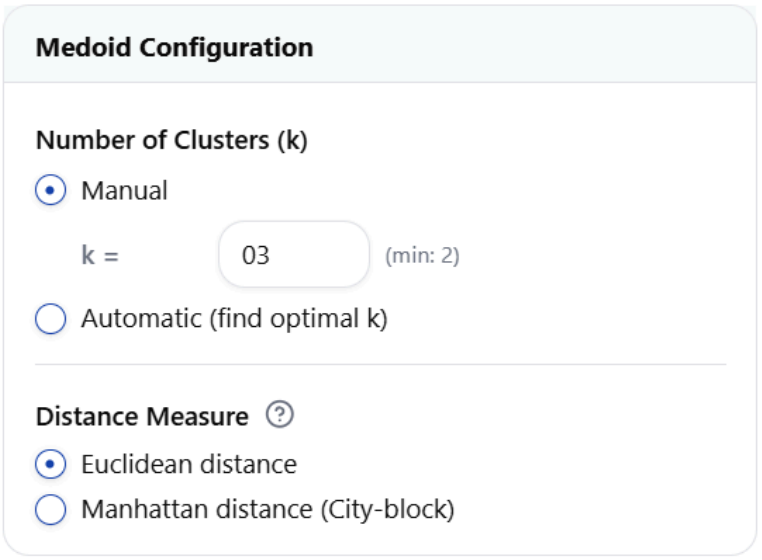
Skenario 1: Konfigurasi Default

Pengisian kotak Variables dapat dilakukan dengan fitur drag-and-drop, klik dua kali pada variabel, atau memilih variabel lalu mengklik tombol panah di samping kotak Variables. Pada demonstrasi ini, masukkan variabel numerik **Age, MonthlyIncome, DistanceFromHome, TotalWorkingYears,** dan **YearsAtCompany** sebagai dasar pengelompokan (variabel yang jaraknya akan dihitung untuk menentukan cluster).

1. Kotak **Label Cases by** bersifat opsional dan hanya menampung satu variabel. Pada demonstrasi ini, masukkan **EmployeeNumber** agar setiap observasi memiliki identitas yang jelas pada output, alih-alih hanya nomor baris.



2. **Number of Clusters**: pilih Manual, lalu isi k = 3.
3. **Distance Measure**: gunakan Euclidean (pilihan default).

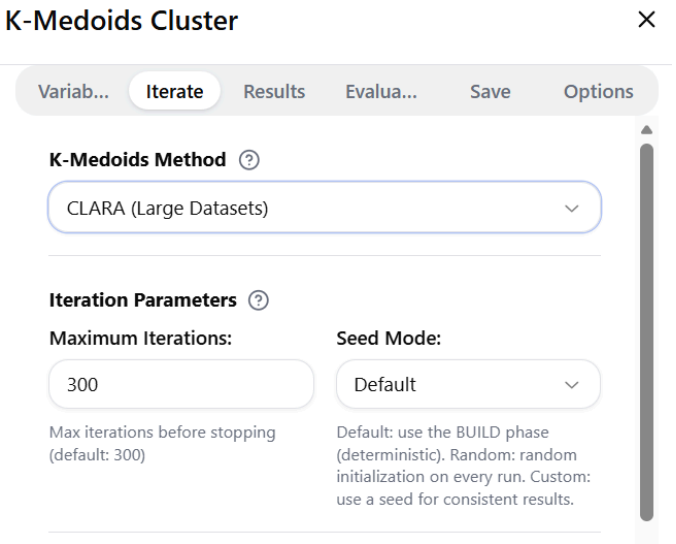


4. Klik OK sehingga analisis berjalan dan memunculkan Halaman Output. Perhatikan bahwa Output yang muncul adalah sebagai berikut.
    a. **Case Processing Summary**, merangkum jumlah total observasi yang diproses serta jumlah data yang di-exclude karena mengandung missing value.

b. **Cluster Membership**, tabel yang menunjukkan cluster tempat setiap observasi berada, lengkap dengan jarak ke medoidnya.
c. **Number of Cases per Cluster**, ringkasan jumlah observasi pada tiap cluster, untuk memeriksa apakah ada cluster yang terlalu kecil atau timpang.
d. **Cluster Medoids**, menampilkan observasi yang menjadi medoid tiap cluster beserta nilai variabelnya, yaitu kasus perwakilan yang dapat ditafsirkan sebagai profil kelompok.

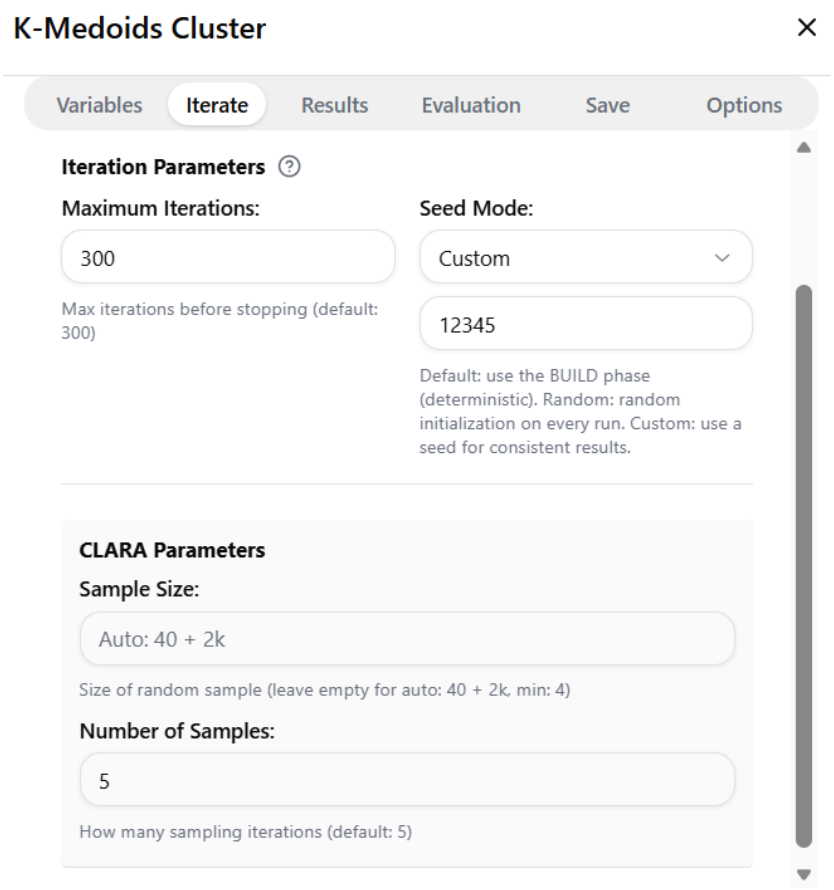
Skenario 2: Konfigurasi pada Tab Iterate

Kembali ke jendela Data, kemudian memilih K-Medoids Cluster dan masuk ke Tab Iterate. Tab Iterate berfungsi untuk memilih algoritma partisi yang dipakai beserta parameter iterasinya. Karena dataset yang digunakan berjumlah 1.470 observasi (tergolong dataset besar), gunakan skenario ini untuk beralih dari PAM ke algoritma CLARA.



1. K-Medoids Method
    a. PAM (Partitioning Around Medoids): algoritma klasik dua fase (BUILD dan SWAP), kualitas terbaik tetapi paling berat, cocok untuk data di bawah kurang lebih 1.000 kasus (pilihan default).
    b. CLARA (Large Datasets): menjalankan PAM pada beberapa sampel acak lalu mengevaluasi hasil terbaiknya pada seluruh data. Pilih metode ini untuk skenario kedua ini.
    c. CLARANS (Randomized Search): pencarian acak pada tetangga solusi, kompromi antara kecepatan dan kualitas.

2. ***Sample Size***: biarkan kosong agar dihitung otomatis (40 + 2k, untuk k = 3 bernilai 46).



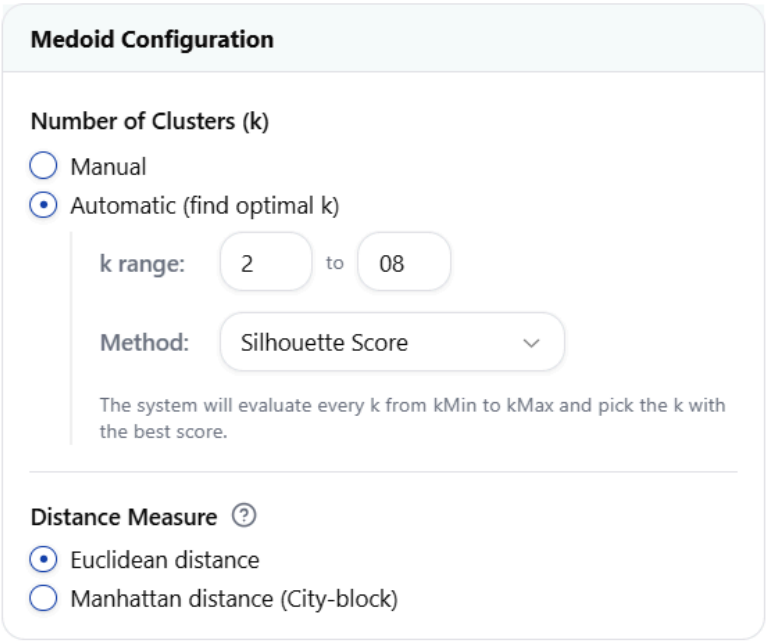
3. ***Number of Samples***: gunakan nilai default, yaitu 5.

4. ***Seed Mode***: pilih Custom, lalu isi kolom Seed dengan 12345 agar hasil pembagian sampel acak dapat direproduksi persis pada pengujian berikutnya.

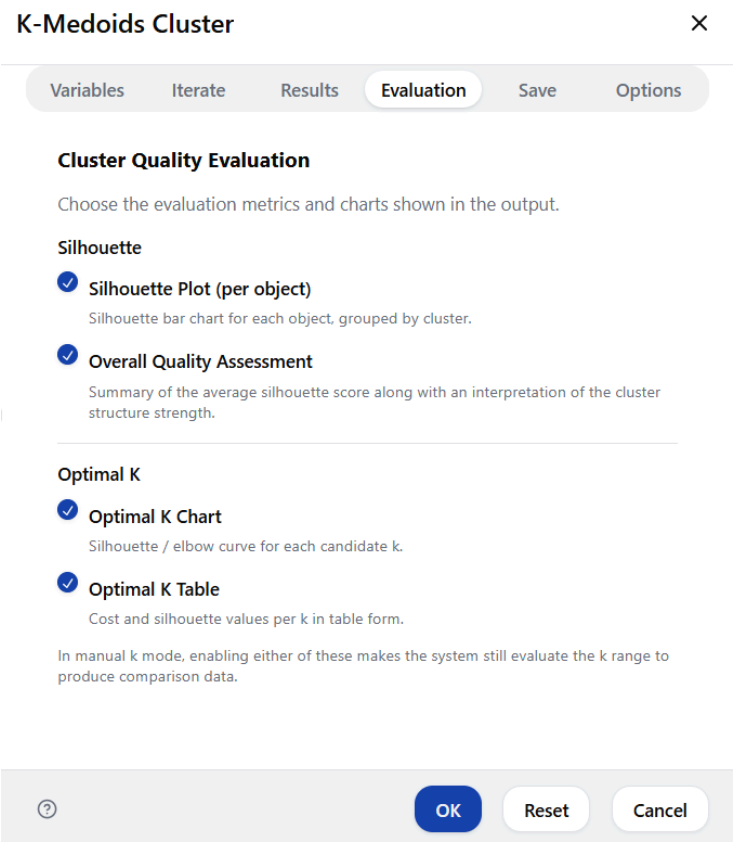
5. Klik OK untuk kemudian masuk ke halaman output. Terdapat perbedaan pada bagian Additional Information, yaitu Sampling History, yang menampilkan grafik dan tabel cost untuk setiap sampel yang diambil CLARA, menggantikan tabel konvergensi iterasi yang muncul pada metode PAM/CLARANS.

Skenario 3: Konfigurasi Automatic K dan Tab Evaluation

Kembali ke Tab Variables, ubah Number of Clusters dari Manual menjadi Automatic. Skenario ini digunakan untuk menguji pencarian k terbaik secara otomatis.



1. ***Automatic k range***: isi rentang Minimum = 2 dan Maximum = 8.
2. ***Automatic Method***: pilih Silhouette, yaitu k terbaik dipilih berdasarkan rata-rata skor silhouette tertinggi.
3. Masuk ke Tab Evaluation, kemudian centang:

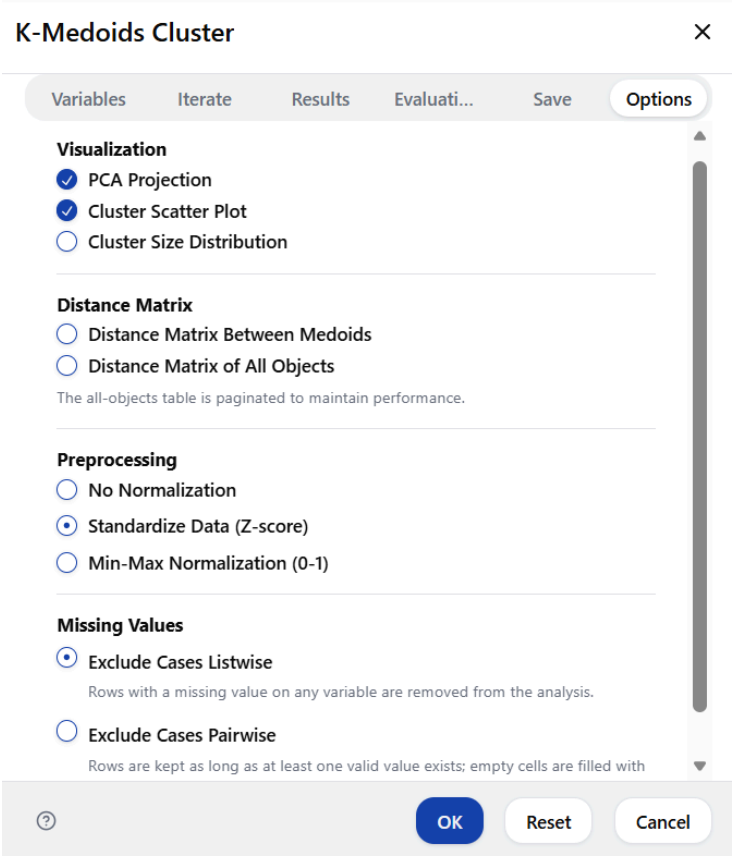


a. Silhouette Plot, untuk melihat skor silhouette tiap observasi per cluster.
b. Overall Quality Assessment, ringkasan skor silhouette rata-rata beserta interpretasi kekuatan struktur cluster.
c. Grafik K Optimal dan Tabel K Optimal, untuk membandingkan skor silhouette pada setiap kandidat k dalam rentang yang diuji.

4. Klik OK. Terdapat output tambahan berupa grafik kurva silhouette terhadap k, di mana sistem menandai k dengan skor rata-rata tertinggi sebagai k optimal.

Skenario 4: Konfigurasi pada Tab Options

Tab Options berfungsi untuk mengatur preprocessing data serta visualisasi tambahan pada output. Karena variabel yang digunakan memiliki satuan dan rentang yang jauh berbeda (misalnya MonthlyIncome berkisar ribuan hingga puluhan ribu, sedangkan Age dan DistanceFromHome hanya berkisar puluhan), gunakan skenario ini untuk menyamakan skala variabel terlebih dahulu.



1. Preprocessing: pilih Standardization (Z-score), agar variabel MonthlyIncome yang berskala besar tidak mendominasi perhitungan jarak dibanding variabel lain.

2. Visualization: centang PCA Projection dan Cluster Scatter Plot, agar sebaran cluster pada data multivariat dapat dilihat dalam bidang dua dimensi.
3. Missing Values: biarkan pada pilihan default, yaitu Exclude Cases Listwise.
4. Klik OK. Output tambahan yang muncul adalah grafik proyeksi PCA berwarna per cluster dan diagram pencar antarvariabel asli yang diwarnai menurut cluster.

Save Variable dan Output

1. Tab Save

   Tab Save digunakan untuk menyimpan hasil pengelompokan ke dalam dataset aktif sebagai kolom baru di jendela Data. Centang Cluster membership untuk menyimpan nomor cluster tiap observasi (kolom CLU_1), dan Distance from medoid untuk menyimpan jarak tiap observasi ke medoid clusternya (kolom DIS_1). Kolom DIS_1 dapat diurutkan menurun untuk menemukan observasi yang paling menyimpang dari medoidnya.

2. Tab Results

   Tab Results digunakan untuk memilih tabel tambahan yang ingin ditampilkan pada panel hasil analisis (Viewer Output), yang isinya menyesuaikan metode pada Tab Iterate:

   a. Konvergensi Algoritma, status dan histori iterasi cost, muncul untuk metode PAM dan CLARANS.
   b. Grafik Konvergensi Algoritma, grafik penurunan cost per iterasi sebagai section tersendiri.
   c. Histori Sampling, khusus metode CLARA, menggantikan kedua opsi konvergensi di atas.

3. Tab Options, Matriks Jarak

   Selain preprocessing, Tab Options juga menyediakan:

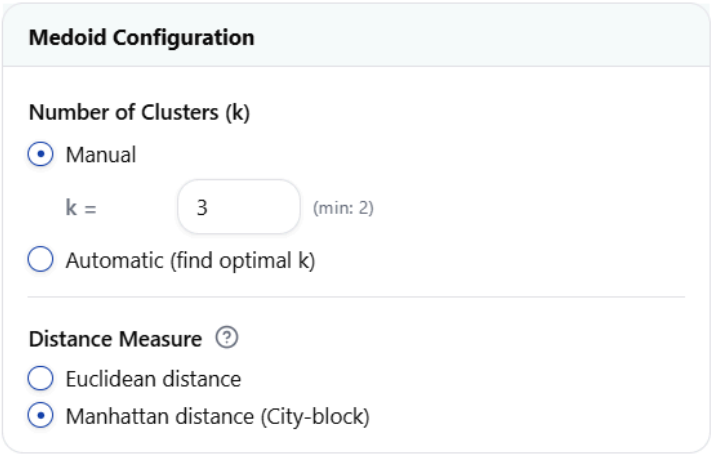
   a. Matriks Jarak Antar Medoid, menampilkan jarak antarmedoid untuk melihat cluster mana yang saling terpisah jauh atau berpotensi digabung.
   b. Matriks Jarak Semua Objek, matriks jarak lengkap antarseluruh observasi (dipaginasi, sebaiknya dihindari pada dataset sangat besar).

Skenario 5: Perbandingan Ukuran Jarak (Euclidean vs Manhattan)

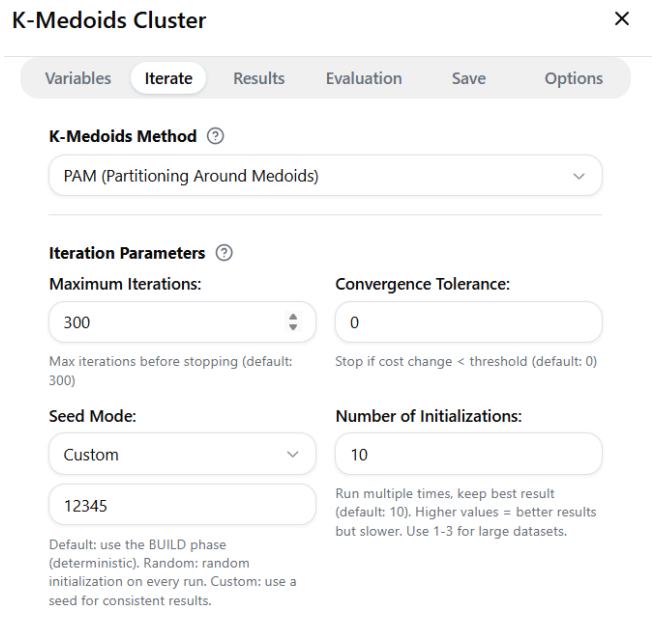
Pada skenario sebelumnya, K-Medoids dijalankan menggunakan jarak Euclidean. Karena K-Medoids meminimalkan total jarak (bukan kuadrat jarak seperti K-Means),

pemilihan ukuran jarak dapat memengaruhi ketahanan hasil terhadap outlier. Skenario ini digunakan untuk membandingkan pengaruh tersebut.

1. Kembali ke Tab Variables, gunakan variabel yang sama seperti Skenario 1: Age, MonthlyIncome, DistanceFromHome, TotalWorkingYears, YearsAtCompany, dengan Number of Clusters: Manual, k = 3.



2. Ubah Distance Measure menjadi Manhattan (City-block).



3. Pada Tab Iterate, gunakan kembali metode PAM dengan Seed Mode Custom, Seed 12345, agar hasil dapat dibandingkan secara adil dengan Skenario 1.
4. Klik OK, lalu bandingkan Total Cost dan Cluster Medoids hasil Manhattan dengan hasil Euclidean pada Skenario 1.

MODUL TEXT ANALYTICS: TEXT CLASSIFICATION DENGAN NAIVE BAYES

A. Deskripsi Singkat

Modul *Text Analytics* digunakan untuk mengklasifikasikan data teks, misalnya tweet, ulasan, atau komentar, ke dalam kategori tertentu menggunakan algoritma *Naive Bayes*. Modul ini terdiri atas tiga menu yang saling terhubung. Menu **String to Word Vector** melakukan pra-pemrosesan teks (*lowercase*, tokenisasi, penghapusan *stopword*, *stemming*, dan *n-gram*) serta mengubah teks menjadi kolom-kolom angka berupa bobot kata (TF, IDF, dan normalisasi). Menu **Naive Bayes** melatih dan mengevaluasi model klasifikasi dengan likelihood teks *Multinomial*, *Bernoulli*, atau *Complement*, yang dapat digabungkan dengan prediktor numerik dan kategorik. Teks mentah dapat langsung diproses di dalam menu ini sehingga kosakata hanya dibentuk dari data latih dan evaluasi terhindar dari kebocoran data (*data leakage*). Menu **Apply Model** menerapkan model yang telah diekspor ke data baru dengan resep pra-pemrosesan yang sama. Seluruh komputasi berjalan di peramban pengguna (sisi klien), dan pengguna akan diperlihatkan metrik evaluasi, *confusion matrix*, serta daftar kata yang paling berpengaruh pada setiap kelas.

B. Tujuan Demonstrasi

Panduan penggunaan ini bertujuan sebagai panduan praktis dalam rangka penggunaan/demonstrasi perangkat lunak Statify untuk menjalankan dan menganalisis modul *Text Analytics* dengan algoritma *Naive Bayes*. Panduan ini secara khusus difokuskan pada alur konfigurasi pra-pemrosesan teks, pemilihan jenis likelihood teks, metode validasi, ekspor model dan penerapannya pada data baru, hingga pada tahap interpretasi metrik evaluasi dan kata-kata yang paling berpengaruh pada setiap kelas.

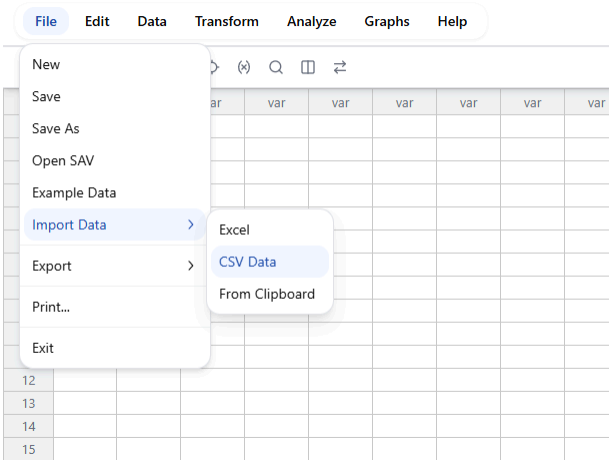
C. Material Demonstrasi

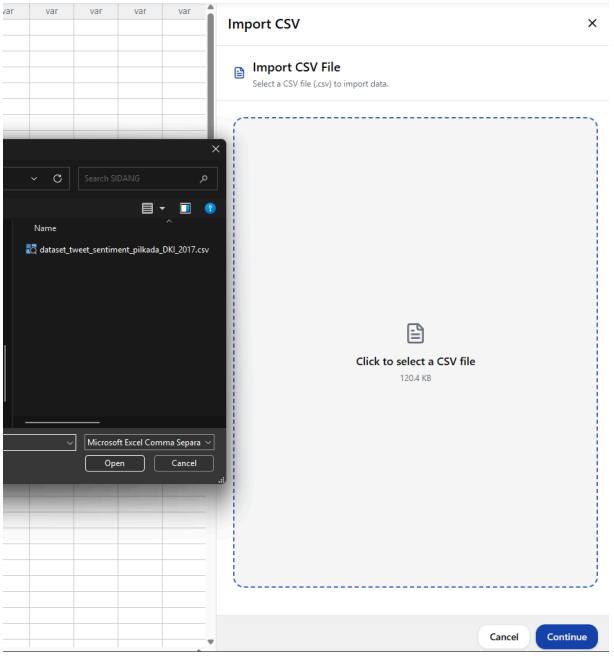
1. Dataset yang dapat diakses pada https://s.stis.ac.id/dataset_demoStatify64_ModulTA
2. Perangkat lunak Statify yang dapat diakses pada https://statify-dev.student.stis.ac.id/
3. Panduan dapat diakses pada https://s.stis.ac.id/panduan_penggunaanStatify64
4. Video kegiatan demonstrasi dapat diakses pada : …

D. Kegiatan Demonstrasi

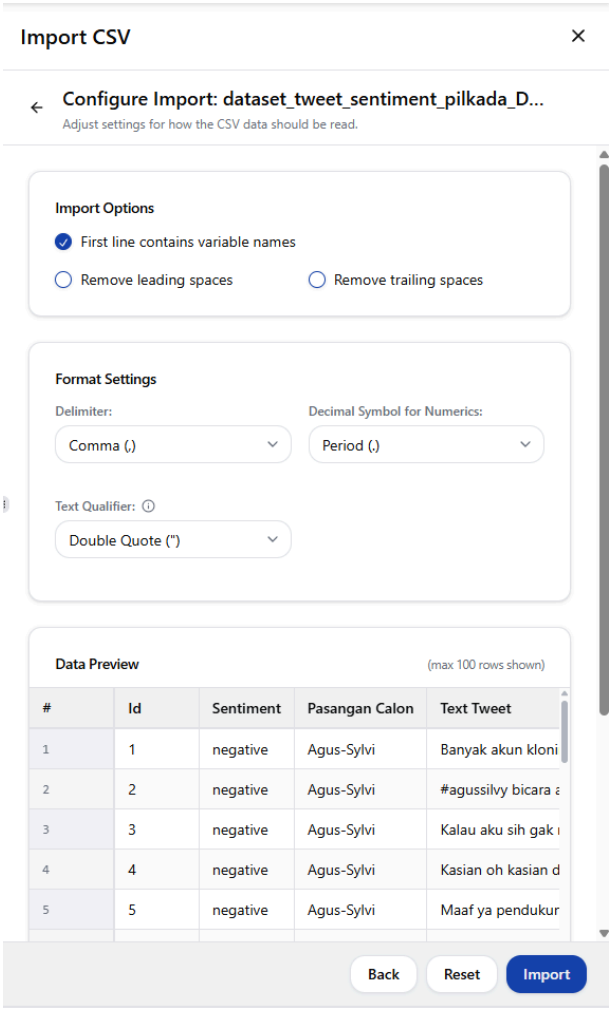
Demonstrasi menggunakan data tweet sentimen Pilkada DKI Jakarta 2017 yang terdiri atas tiga berkas, yaitu **dataset_tweet_sentiment_pilkada_DKI_2017.csv** (900 tweet), **pilkada_train.csv** (630 tweet untuk melatih model), dan **pilkada_test.csv** (270 tweet sebagai data baru). Ketiga berkas memiliki kolom yang sama, yaitu Id, Sentiment (positive/negative), Pasangan Calon, dan Text Tweet.

Tahap persiapan dilakukan dengan mengimpor dataset ke lembar kerja Statify. *File* > *Import Data* > *CSV Data*. Pilih berkas **dataset_tweet_sentiment_pilkada_DKI_2017.csv**.

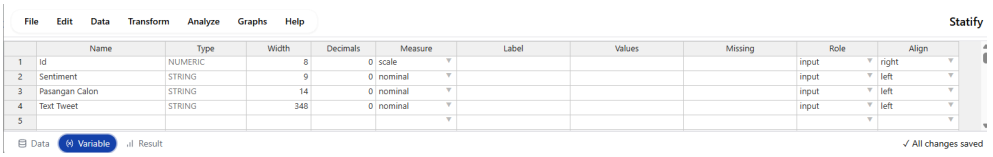




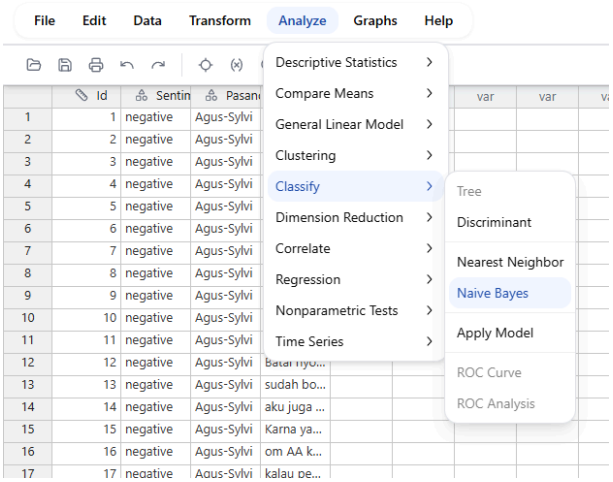
Jika tampilan/*preview* dataset berhasil muncul, maka tekan *Impor*.



Pada Variable View, pastikan Sentiment, Pasangan Calon, dan Text Tweet bertipe teks (*String*) dengan *measure* Nominal, sedangkan Id bertipe numerik dengan *measure* Scale.

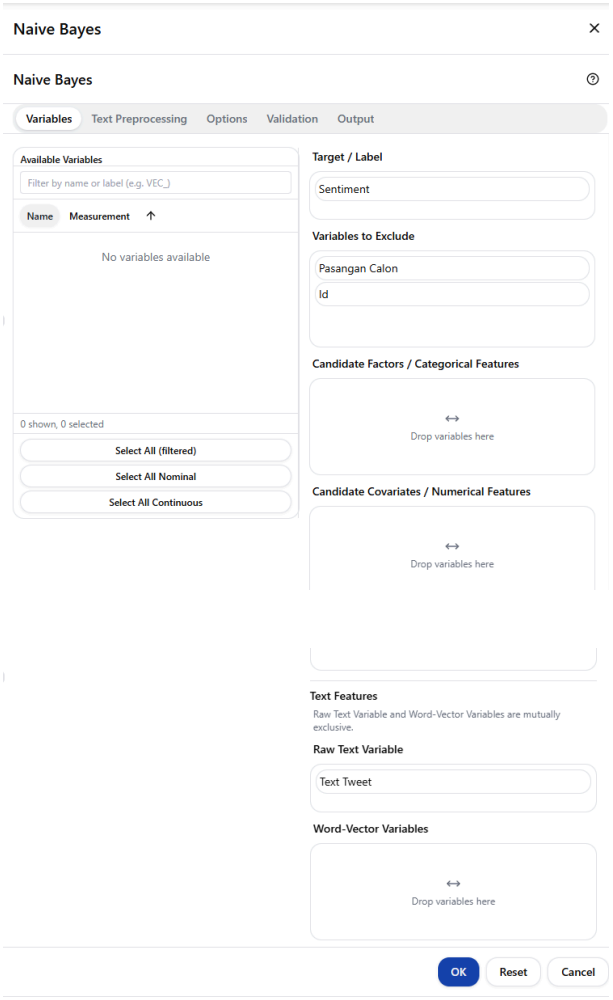


Pilih menu **Analyze > Classify > Naive Bayes**

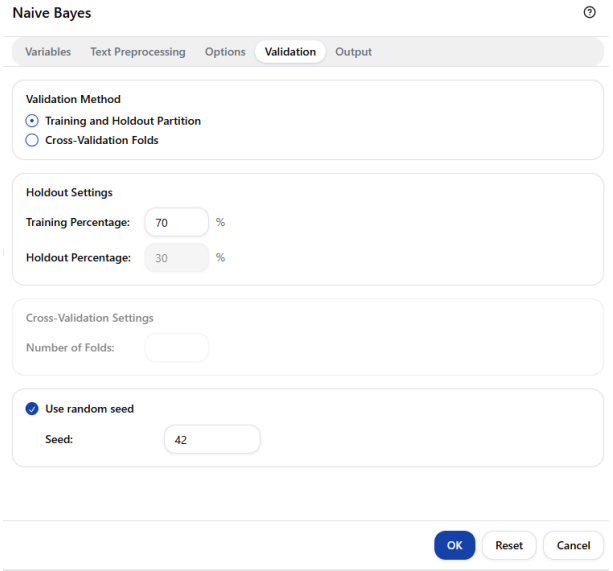


Skenario 1: Konfigurasi Default

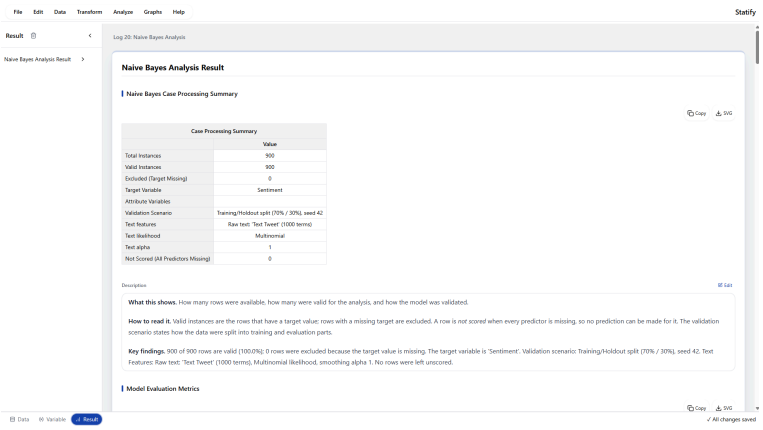
1. Pengisian **Target / Label** dapat dilakukan dengan fitur *drag-and-drop*, klik dua kali pada variabel, atau memilih variabel lalu mengklik tombol panah di samping kotak. Pada demonstrasi ini, pilih **Sentiment** sebagai variabel target (kelas yang diprediksi). Target harus bertipe Nominal atau Ordinal dan boleh memiliki lebih dari dua kelas.
2. Pada blok **Text Features**, masukkan **Text Tweet** ke kotak **Raw Text Variable**. Kotak ini hanya menerima satu variabel bertipe *String* berisi teks mentah. Setelah terisi, Tab **Text Preprocessing** menjadi aktif.
3. Masukkan **Id** dan **Pasangan Calon** ke kotak **Variables to Exclude**. Secara *default*, menu berjalan pada mode *Exclude*, yaitu semua variabel selain target, variabel teks, dan variabel yang dikeluarkan otomatis ikut menjadi prediktor. Id harus dikeluarkan karena hanya berupa nomor urut, sedangkan Pasangan Calon dikeluarkan agar model pada skenario ini murni berbasis teks.
4. Selain mode *Exclude*, tersedia mode *Candidates* yang bersifat opsional, dapat digunakan jika mahasiswa ingin memilih prediktor secara eksplisit.
    a. **Candidate Factors / Categorical Features**: hanya menerima variabel Nominal/Ordinal sebagai prediktor kategorik.
    b. **Candidate Covariates / Numerical Features**: hanya menerima variabel Scale sebagai prediktor numerik.
    c. Kedua mode bersifat saling eksklusif: mengisi salah satu akan mengosongkan yang lain.



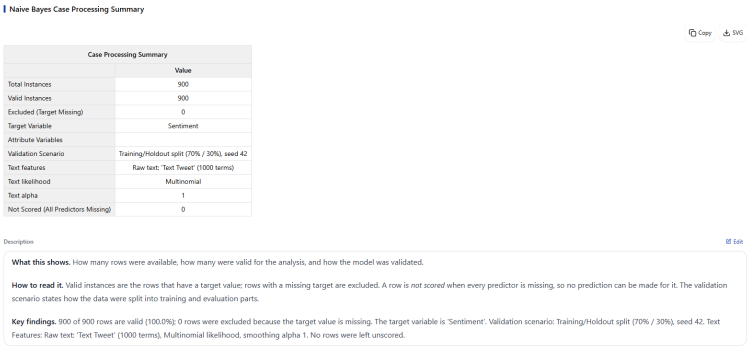
5. Biarkan tab lain pada pengaturan *default*. Agar hasil dapat diulang dan dibandingkan antarskenario, buka Tab **Validation**, centang **Use random seed**, lalu isi **Seed** dengan 42. Penjelasan lengkap tab ini ada pada Skenario 4.



6. Klik OK sehingga analisis berjalan dan memunculkan Halaman Output dengan judul **Naive Bayes Analysis Result**. Perhatikan bahwa *Output* yang muncul adalah sebagai berikut.



a. **Case Processing Summary** merangkum jumlah data (Total Instances, Valid Instances, Excluded (Target Missing)), variabel target dan atribut, skenario validasi, serta informasi teks: Text features (Raw text: 'Text Tweet' beserta jumlah kata/*terms* yang terbentuk), Text likelihood, dan Text alpha.



b. **Model Evaluation Metrics** menampilkan Accuracy, Precision, Recall, dan F1-Score untuk setiap kelas, rata-rata Macro, Weighted, dan Micro, Overall Accuracy, serta **Cohen's Kappa**, yaitu ukuran kesepakatan antara prediksi dan kelas sebenarnya setelah dikoreksi faktor kebetulan.

Model Evaluation Metrics

Copy SVG

Model Evaluation Metrics				
	Accuracy	Precision	Recall	F1-Score
negative	0.744	0.758	0.719	0.738
positive	0.744	0.732	0.77	0.751
Macro Average		0.745	0.744	0.744
Weighted Average		0.745	0.744	0.744
Micro Average		0.744	0.744	0.744
Overall Accuracy	0.744			

Description Edit

What this shows. Accuracy, precision, recall and F1-score for each class, plus macro, weighted and micro averages and the overall accuracy, all computed on the evaluation data.

How to read it. Precision is the share of rows predicted as a class that truly belong to it. Recall is the share of the rows of a class that the model found. F1 combines both. The macro average treats every class equally, while the weighted average gives larger classes more influence. Overall accuracy is the share of all rows predicted correctly.

Key findings. Overall accuracy is 0.744. The no-information rate (the share of the most frequent class 'negative') is 0.500. The model exceeds it by 0.244. Macro F1 is 0.744 and weighted F1 is 0.744. The lowest recall is 0.719 for class 'negative'.

Copy SVG

Cohen's Kappa	
	Value
Cohen's Kappa (overall)	0.489

Description Edit

What this shows. Cohen's Kappa measures how well the predicted classes agree with the actual classes after removing the agreement that would be expected by chance. A value of 1 means perfect agreement, 0 means chance-level agreement, and negative values mean agreement worse than chance.

How to read it. Following Landis & Koch (1977): below 0 is poor, 0 to 0.20 slight, 0.21 to 0.40 fair, 0.41 to 0.60 moderate, 0.61 to 0.80 substantial, and 0.81 to 1 almost perfect.

Key findings. Cohen's Kappa is 0.489, which falls in the *moderate* agreement range.

Note. Kappa is a single overall value and is not broken down per class. These ranges are conventional guidelines, not strict rules.

c. **Confusion Matrix** membandingkan kelas aktual (baris) dengan kelas hasil prediksi model (kolom) beserta jumlah dan persentasenya. Nilai pada diagonal adalah prediksi yang benar.

Confusion Matrix

Copy SVG

Confusion Matrix			
Actual \ Predicted	negative	positive	Total
negative	97 (35.9%)	38 (14.1%)	135
positive	31 (11.5%)	104 (38.5%)	135
Total	128	142	270

Description Edit

What this shows. A cross-tabulation of the actual class (rows) against the class predicted by the model (columns) on the evaluation data. Each cell shows a count and its percentage of the row total.

How to read it. Cells on the diagonal are correct predictions. Cells off the diagonal are errors: the row tells you the true class and the column tells you what the model predicted instead. A class whose row has large off-diagonal counts is often confused with the class in that column.

Key findings. 201 rows out of 270 evaluated (74.4%) lie on the diagonal, which means they were predicted correctly. The most frequent misclassification is actual 'negative' predicted as 'positive' (38 rows).

d. **Text Feature Table** menampilkan 100 kata paling berpengaruh pada setiap kelas dengan kolom Rank, Term, Score, Log weight, dan Count. Semakin besar nilai Score, semakin khas kata tersebut untuk kelas itu dibandingkan kelas lain.

Text Feature Table

Top 100 terms per class (Multinomial). Score = log weight of the class minus the mean log weight of the other classes.

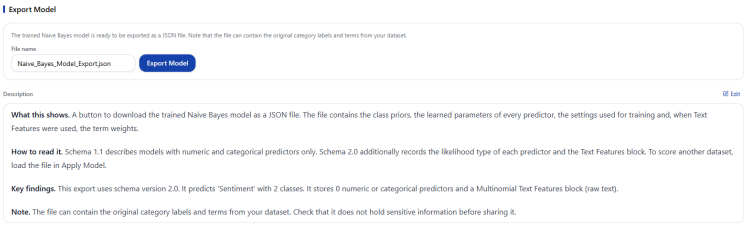
Download CSV Copy (TSV)

Class: negative

Rank	Term	Score	Log weight	Count
1	tongue	2.3774	-6.3104	10
2	face>	2.3308	-4.9706	41
3	<zipper-mouth	2.2821	-6.4057	9
4	cagub	2.1767	-6.5111	8
5	ngomong	2.1767	-6.5111	8
6	<thinking	2.0589	-6.6289	7
7	<tongue>	2.0589	-6.6289	7
8	antasari	2.0589	-6.6289	7
9	berita	2.0589	-6.6289	7
10	on	2.0589	-6.6289	7
11	sedih	2.0589	-6.6289	7
12	#debatfinalpilkadadki	1.9254	-6.7624	6
13	#fpi	1.9254	-6.7624	6
14	<grimacing	1.9254	-6.7624	6

e. **Attribute Distribution Table** hanya menjelaskan prediktor numerik dan kategorik, sehingga baru akan berisi pada Skenario 3 ketika Pasangan Calon digunakan sebagai prediktor.

f. Tombol **Export Model** untuk mengunduh model dalam bentuk berkas JSON (dibahas pada bagian Export Model dan Output).



Skenario 2: Konfigurasi pada Tab Text Preprocessing

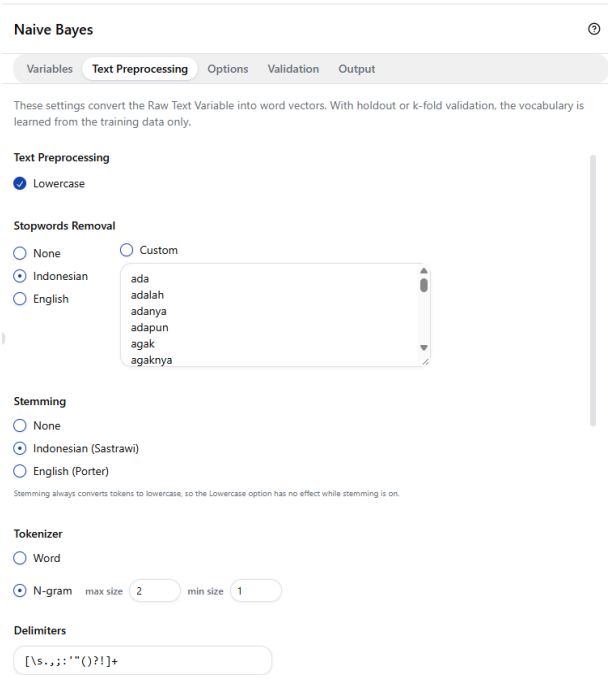
Kembali ke jendela Data, kemudian memilih *Naive Bayes* dan masuk ke Tab **Text Preprocessing**. **Tab Text Preprocessing** berfungsi untuk mengatur cara teks dibersihkan dan diubah menjadi bobot kata sebelum model dilatih. Pengaturan ini dijalankan ulang pada setiap pembagian data latih sehingga kosakata tidak dipengaruhi data uji. Panel ini sama dengan menu *String to Word Vector* (tanpa Vector Column Name).

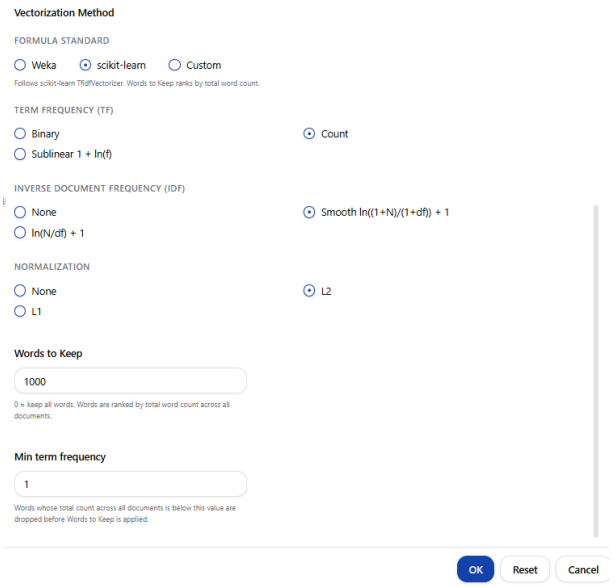
1. **Lowercase**: mengubah teks menjadi huruf kecil sehingga "Ahok" dan "ahok" dianggap kata yang sama (*default* aktif).
2. **Stopwords Removal**: membuang kata umum yang dianggap tidak informatif, dengan pilihan None (*default*), Indonesian, English, atau Custom (satu kata per baris). **Pilih Indonesian untuk skenario ini.**
3. **Stemming**: mengubah kata berimbuhan menjadi kata dasar, dengan pilihan None (*default*), Indonesian (Sastrawi) yang menggunakan algoritma Nazief–Adriani, atau English (Porter). **Pilih Indonesian (Sastrawi) untuk skenario ini.**
4. **Tokenizer**: Word memecah teks per kata (*unigram*), sedangkan N-gram menggabungkan kata berurutan dengan ukuran minimum dan maksimum 1–5. **Pilih N-gram dengan min 1 dan max 2**, sehingga frasa seperti "tidak suka" ikut menjadi fitur.
5. **Delimiters**: ekspresi reguler pemisah kata, secara *default* [\s.,;:'"()?!]+. Karakter yang tidak tercantum, seperti #, @, dan /, tetap menempel pada kata, sehingga tagar seperti #aniessandi menjadi satu token utuh.
6. **Formula standard**: menentukan kombinasi rumus pembobotan yang sah, yaitu Weka (*default*), scikit-learn, atau Custom. **Pilih scikit-learn untuk skenario ini**;

pengaturan otomatis berubah menjadi Count, Smooth IDF, dan normalisasi L2 (pembobotan TF-IDF).

a. **Term Frequency (TF)**: cara menghitung nilai kata dalam satu dokumen, misalnya jumlah kemunculan (Count/Word count) atau ada/tidaknya kata (Binary/Presence).
b. **Inverse Document Frequency (IDF)**: menurunkan bobot kata yang muncul di banyak dokumen.
c. **Normalization**: menyamakan skala vektor antardokumen (L1, L2, atau panjang dokumen ala Weka).

7. **Words to Keep**: jumlah maksimum kata yang dipertahankan (*default* 1000; 0 berarti semua kata). **Min term frequency**: kata dengan total kemunculan di bawah nilai ini dibuang (*default* 1).
8. Berikut merupakan konfigurasi saat ini:





Klik OK untuk kemudian masuk ke halaman *output*.

9. Bandingkan hasilnya dengan Skenario 1. Perhatikan perubahan jumlah *terms* pada Case Processing Summary, nilai Overall Accuracy dan Cohen's Kappa, serta kata-kata yang muncul pada Text Feature Table.
10. Catatan: daftar *stopword* bawaan memuat kata negasi seperti "tidak", "bukan", dan "belum" yang penting untuk analisis sentimen. Jika ingin mempertahankannya, gunakan pilihan Custom dengan daftar kata sendiri.

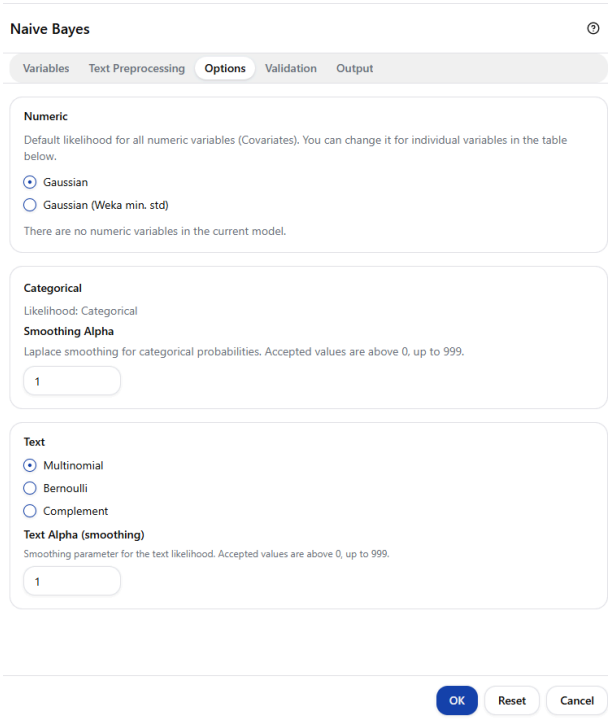
Skenario 3: Konfigurasi pada Tab Options

Tab Options berfungsi untuk memilih jenis *likelihood* (sebaran peluang) yang digunakan untuk setiap jenis prediktor beserta parameter penghalusnya (*smoothing*). Sebelum melanjutkan, kembalikan Tab **Text Preprocessing** ke pengaturan *default* dengan memilih Formula standard Weka, Stopwords Removal None, Stemming None, dan Tokenizer Word.

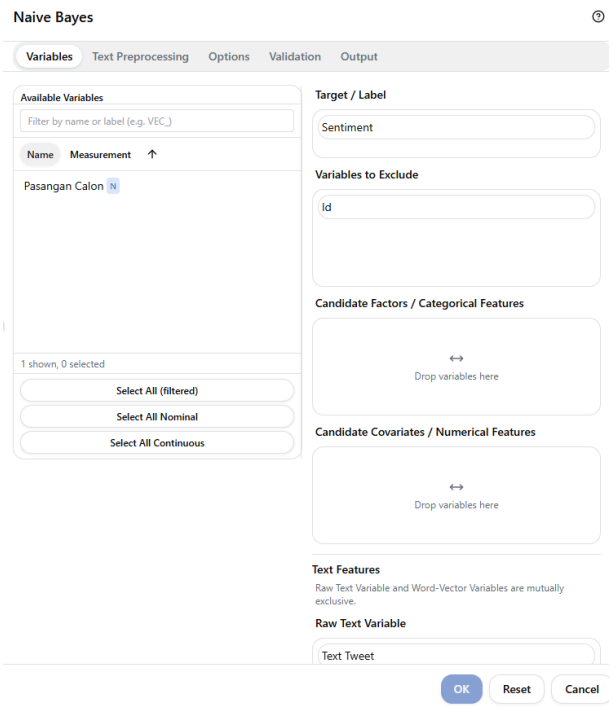
1. **Text**: aktif jika Text Features terisi, dengan pilihan:
    a. **Multinomial** (*default*): memodelkan berapa kali setiap kata muncul pada dokumen; cocok untuk sebagian besar kasus klasifikasi teks.
    b. **Bernoulli**: hanya memperhatikan ada atau tidaknya kata, termasuk kata yang tidak muncul; cocok untuk teks pendek seperti tweet.
    c. **Complement**: menghitung peluang dari dokumen di luar kelas tersebut; cocok untuk kelas yang tidak seimbang. Pilihan ini hanya dapat digunakan jika model **hanya** berisi fitur teks.

d. **Text Alpha (smoothing)**: parameter penghalus agar kata yang tidak pernah muncul pada suatu kelas tidak bernilai peluang nol (*default* 1, nilai di atas 0 sampai 999).

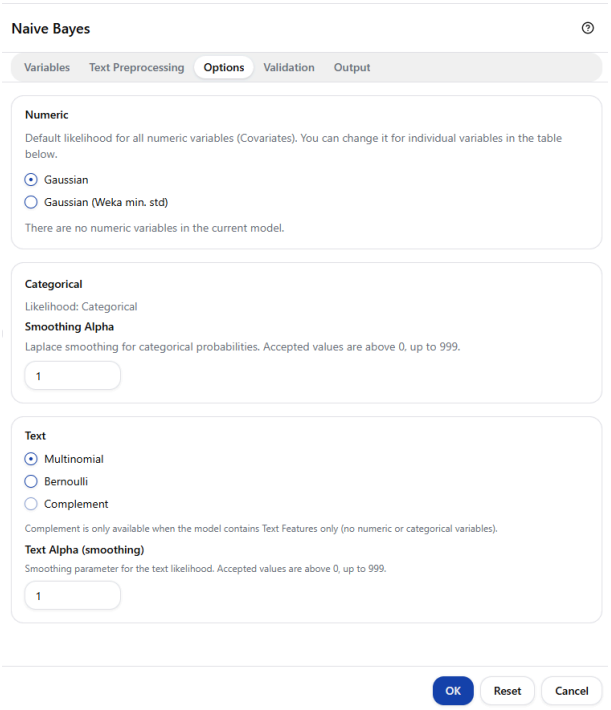
2. Jalankan analisis tiga kali dengan memilih Multinomial, Bernoulli, dan Complement secara bergantian, lalu bandingkan Overall Accuracy, Macro Average F1-Score, dan Cohen's Kappa. Pada output Complement, Case Processing Summary menampilkan catatan bahwa model tidak menggunakan *prior* kelas.



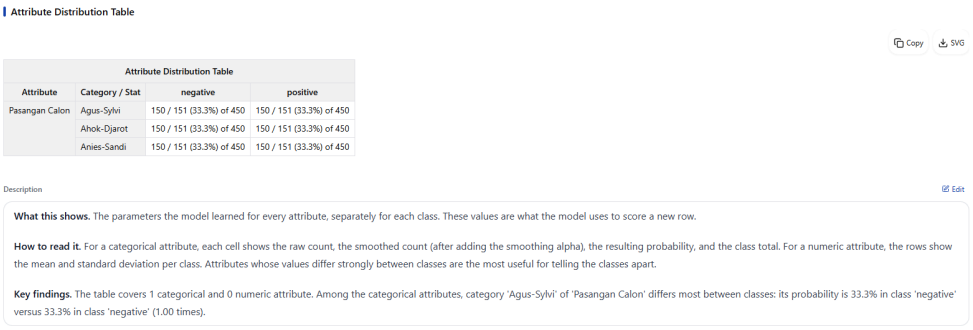
3. Selanjutnya, kembalikan pilihan Text ke **Multinomial**, lalu pada Tab **Variables** keluarkan **Pasangan Calon** dari kotak Variables to Exclude. Pada mode *Exclude*, Pasangan Calon otomatis ikut sebagai prediktor kategorik sehingga model menjadi model campuran (teks dan kategorik).



a. **Categorical**: menggunakan *likelihood* kategorik dengan **Smoothing Alpha** (Laplace smoothing, *default* 1) agar kategori yang tidak muncul pada suatu kelas tidak bernilai peluang nol.
b. **Numeric**: Gaussian (*default*) atau Gaussian (Weka min. std) yang memberi batas bawah simpangan baku agar varians yang hampir nol tidak mendominasi skor. Blok ini berlaku jika terdapat prediktor numerik (tidak digunakan pada demonstrasi ini).
c. Perhatikan bahwa pilihan Complement kini nonaktif karena model tidak lagi hanya berisi fitur teks.



4. Klik OK. Terdapat *output* tambahan, yaitu **Attribute Distribution Table** yang menampilkan, untuk setiap kategori Pasangan Calon pada setiap kelas Sentiment, jumlah data (*raw count*), jumlah setelah ditambah alpha (*smoothed count*), dan peluangnya. Pada dataset ini, setiap pasangan calon memiliki jumlah tweet positif dan negatif yang sama, sehingga peluangnya hampir sama pada kedua kelas dan variabel ini hampir tidak membantu membedakan sentimen.



Skenario 4: Konfigurasi pada Tab Validation

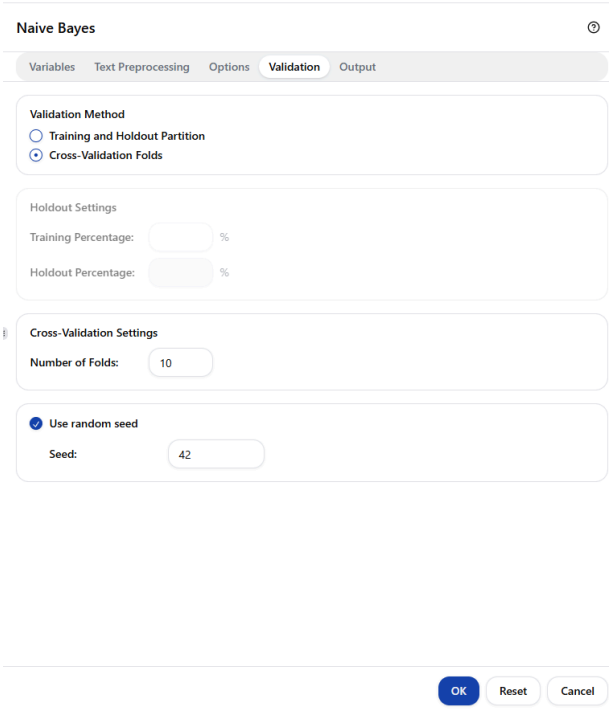
Tab Validation berfungsi untuk mengatur cara data dibagi menjadi data latih dan data uji untuk menilai performa model secara obyektif. Sebelum melanjutkan, masukkan kembali **Pasangan Calon** ke kotak Variables to Exclude agar model kembali hanya berisi fitur teks.

1. **Validation Method** terdiri atas dua pilihan yang saling eksklusif:

a. **Training and Holdout Partition** (*default*): membagi data secara acak dengan proporsi **Training Percentage** (*default* 70%) untuk melatih model dan **Holdout Percentage** (terisi otomatis 30%) untuk menguji model. Pembagian dilakukan secara *stratified*, yaitu proporsi setiap kelas pada data latih dan data uji dibuat sama.

b. **Cross-Validation Folds**: membagi data menjadi sejumlah lipatan (**Number of Folds**, *default* 10). Model dilatih dan diuji bergantian sehingga setiap baris pernah menjadi data uji tepat satu kali. Jumlah fold tidak boleh melebihi jumlah anggota kelas terkecil. **Gunakan pilihan ini dengan 10 folds untuk skenario ini.**

2. **Use random seed** dan **Seed**: mengontrol pengacakan agar hasil pembagian data dapat diulang kembali (*reproducible*). Jika nilai *seed* sama, hasilnya akan selalu sama. Nilai yang diterima adalah 0 sampai 4.294.967.295. **Tetap gunakan 42.**
3. Berikut tampilannya setelah dilakukan konfigurasi pada Tab Validation:

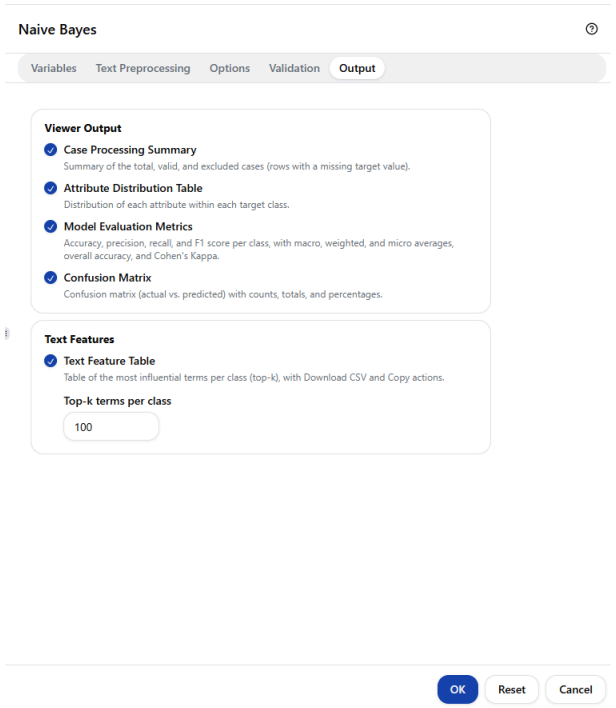


Setelah itu klik OK.

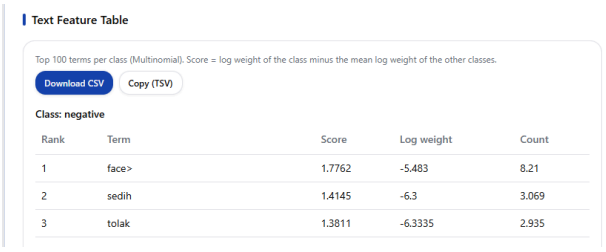
4. Pada jalur Raw Text Variable, kosakata dan bobot IDF dibentuk ulang hanya dari data latih pada setiap fold, sehingga tidak ada kebocoran informasi dari data uji. Metrik evaluasi dihitung dari gabungan prediksi semua fold, sedangkan Text Feature Table dan model yang diekspor berasal dari model akhir yang dilatih ulang menggunakan seluruh data.

Export Model dan Output

1. **Tab Output** digunakan untuk memilih tabel yang ingin ditampilkan pada panel hasil analisis (*Viewer Output*), yaitu Case Processing Summary, Attribute Distribution Table, Model Evaluation Metrics, Confusion Matrix, dan Text Feature Table. Kolom **Top-k terms per class** menentukan jumlah kata yang ditampilkan per kelas (1–1000, *default* 100).

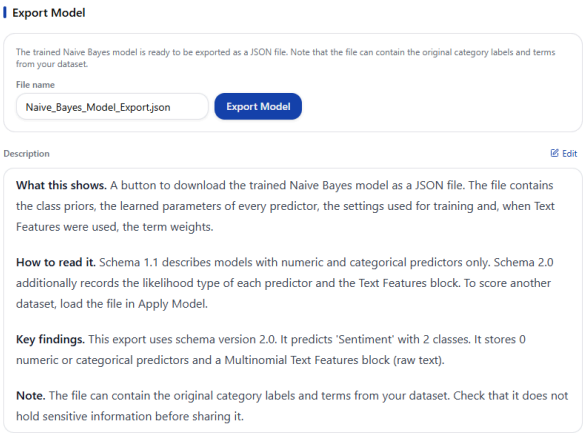


2. **Text Feature Table** dilengkapi tombol **Download CSV** untuk mengunduh seluruh kata pada setiap kelas (Naive_Bayes_Text_Features.csv) dan tombol **Copy** untuk menyalin tabel ke *clipboard*.



3. **Export Model** digunakan untuk menyimpan model yang telah dilatih ke dalam berkas JSON (nama *default* Naive_Bayes_Model_Export.json). Untuk model teks dengan Raw Text Variable, berkas ini juga menyimpan resep pra-pemrosesan (kosakata, pengaturan, dan bobot IDF), sehingga teks baru dapat diolah dengan cara

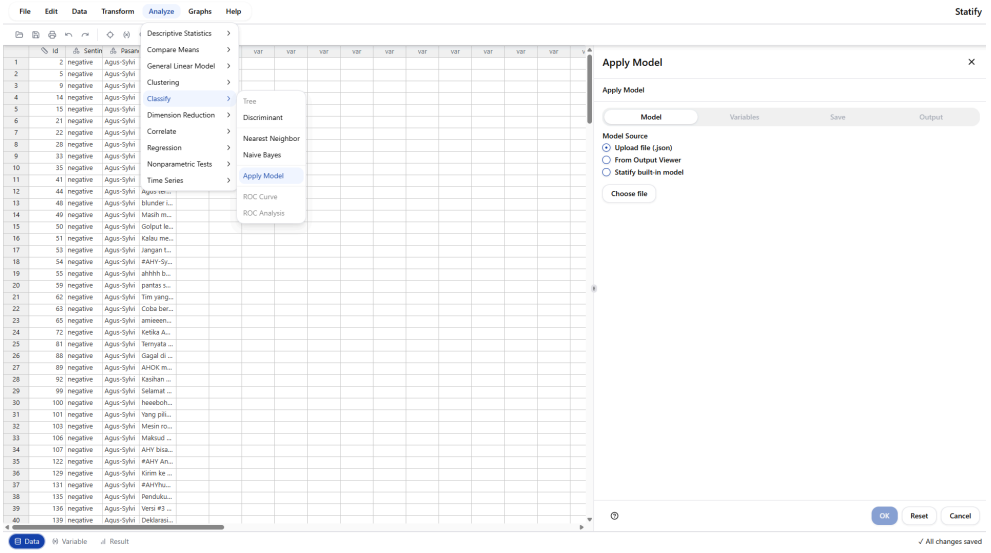
yang persis sama oleh menu Apply Model. Menu Naive Bayes sendiri tidak menulis hasil prediksi ke dataset.



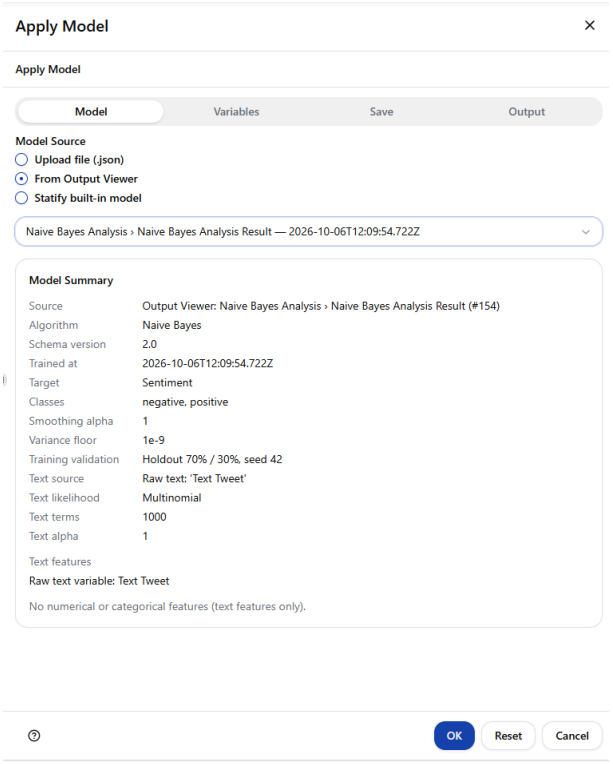
Skenario 5: Menerapkan Model ke Data Baru dengan Apply Model

Pada skenario sebelumnya, model dievaluasi menggunakan pembagian data di dalam satu dataset. Pada skenario ini, model dilatih menggunakan satu berkas, kemudian diterapkan pada berkas lain yang belum pernah dilihat model, seperti penggunaan model pada data baru di dunia nyata.

1. Impor berkas **pilkada_train.csv**, lalu jalankan *Naive Bayes* dengan konfigurasi Skenario 1 (Target Sentiment, Raw Text Variable Text Tweet, Variables to Exclude Id dan Pasangan Calon, Seed 42). Pada Output Viewer, klik **Export Model** dan simpan berkas JSON.
2. Impor berkas **pilkada_test.csv**, lalu pilih menu **Analyze > Classify > Apply Model**. Menu ini memiliki Tab Model, Variables, Save, dan Output. Tab selain Model baru aktif setelah model berhasil dimuat.

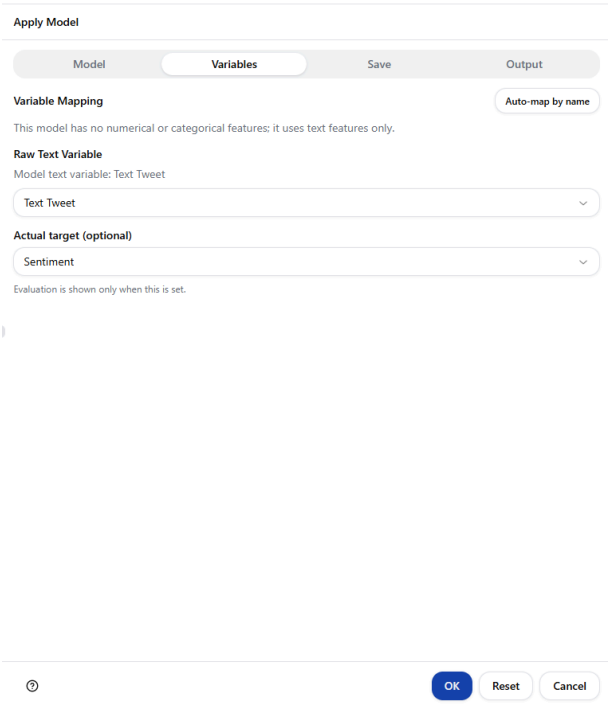


3. **Tab Model**: pada **Model Source** pilih **Upload file (.json)** lalu pilih berkas hasil Export Model, atau pilih **From Output Viewer** untuk memakai model yang dilatih pada sesi Statify yang sama. Jika model valid, muncul kartu **Model Summary** berisi algoritma, versi *schema*, target, kelas, dan informasi fitur teks.

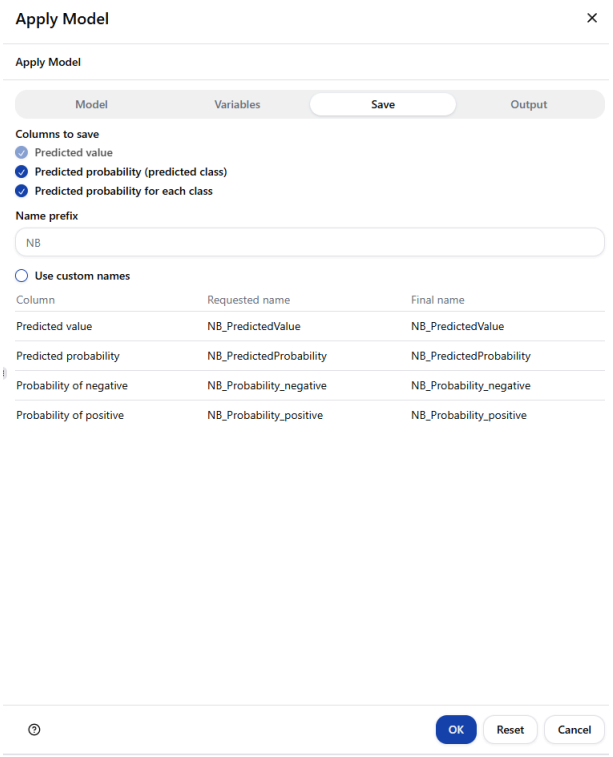


4. **Tab Variables**: **Raw Text Variable** otomatis terisi Text Tweet karena nama kolomnya sama dengan saat pelatihan. Jika model memuat prediktor numerik atau kategorik, pemetaannya diatur pada tabel **Variable Mapping** atau dengan tombol

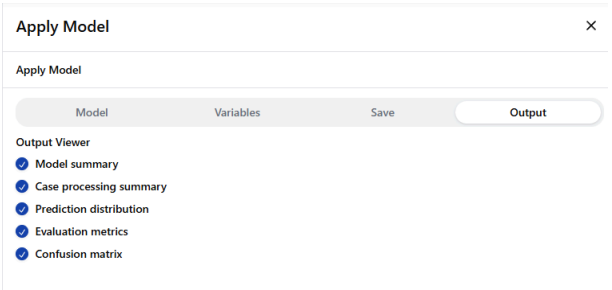
Auto-map by name. Isi **Actual target (optional)** dengan **Sentiment** agar Statify menghitung metrik evaluasi pada data baru.



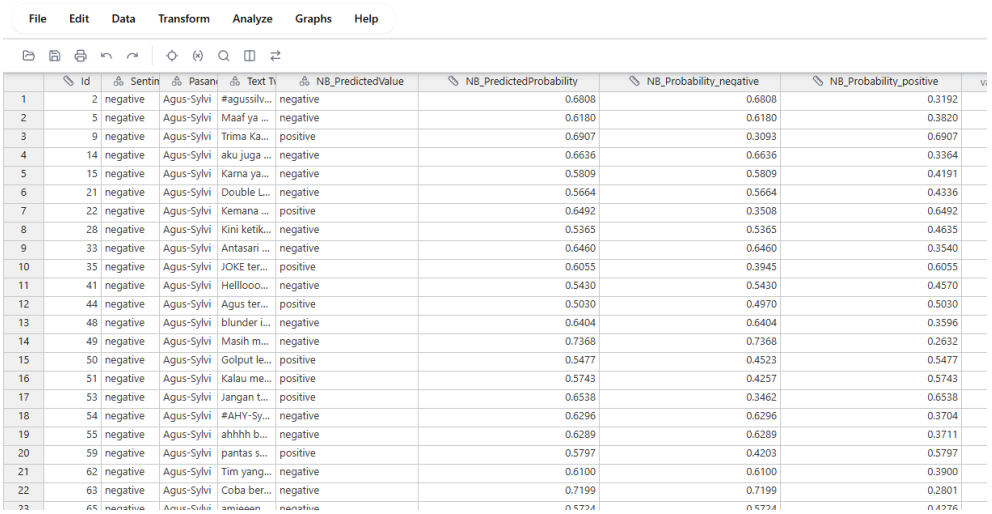
5. **Tab Save**: menentukan kolom hasil yang ditulis ke dataset. **NB_PredictedValue** (kelas prediksi) selalu ditulis, **NB_PredictedProbability** (peluang kelas terprediksi) aktif secara *default*, dan **NB_Probability_<kelas>** (peluang setiap kelas) dapat dicentang. **Centang ketiganya untuk skenario ini.** Awalan nama dapat diubah melalui **Name prefix**, dan variabel yang sudah ada tidak akan pernah ditimpa.



6. **Tab Output**: memilih tabel Model Summary, Case Processing Summary, Prediction Distribution, Evaluation metrics, dan Confusion matrix. Dua tabel terakhir hanya aktif jika Actual target diisi.



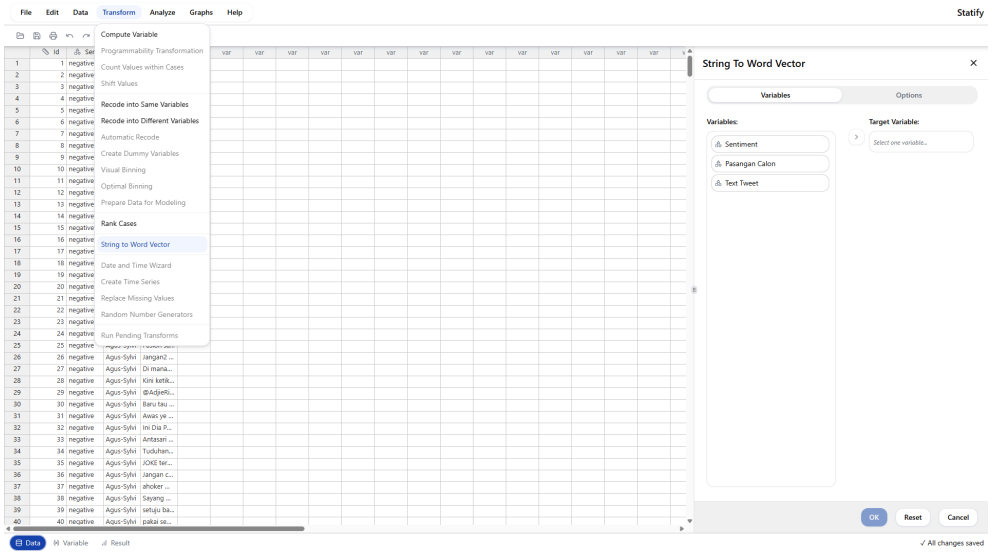
7. Klik OK sehingga masuk ke Output Viewer dengan judul **Apply Model Result**, yang memuat Model Summary, Case Processing Summary (jumlah baris yang diprediksi dan yang tidak dapat diprediksi), Prediction Distribution, Saved Variables, serta Evaluation Metrics, Cohen's Kappa, dan Confusion Matrix. Kembali ke jendela Data untuk melihat kolom hasil prediksi pada kolom paling kanan data.



	Id	Sentin	Pasan	Text Tv	NB_PredictedValue	NB_PredictedProbability	NB_Probability_negative	NB_Probability_positive
1	2	negative	Agus-Sylvi	#agussilv...	negative	0.6808	0.6808	0.3192
2	5	negative	Agus-Sylvi	Maaf ya ...	negative	0.6180	0.6180	0.3820
3	9	negative	Agus-Sylvi	Trima Ka...	positive	0.6907	0.3093	0.6907
4	14	negative	Agus-Sylvi	aku juga ...	negative	0.6636	0.6636	0.3364
5	15	negative	Agus-Sylvi	Karna ya...	negative	0.5809	0.5809	0.4191
6	21	negative	Agus-Sylvi	Double L...	negative	0.5664	0.5664	0.4336
7	22	negative	Agus-Sylvi	Kemana ...	positive	0.6492	0.3508	0.6492
8	28	negative	Agus-Sylvi	Kini ketik...	negative	0.5365	0.5365	0.4635
9	33	negative	Agus-Sylvi	Antasari ...	negative	0.6460	0.6460	0.3540
10	35	negative	Agus-Sylvi	JOKE ter...	positive	0.6055	0.3945	0.6055
11	41	negative	Agus-Sylvi	Helllooo...	negative	0.5430	0.5430	0.4570
12	44	negative	Agus-Sylvi	Agus ter...	positive	0.5030	0.4970	0.5030
13	48	negative	Agus-Sylvi	blunder i...	negative	0.6404	0.6404	0.3596
14	49	negative	Agus-Sylvi	Masih m...	negative	0.7368	0.7368	0.2632
15	50	negative	Agus-Sylvi	Golput le...	positive	0.5477	0.4523	0.5477
16	51	negative	Agus-Sylvi	Kalau me...	positive	0.5743	0.4257	0.5743
17	53	negative	Agus-Sylvi	Jangan t...	positive	0.6538	0.3462	0.6538
18	54	negative	Agus-Sylvi	#AHY-Sy...	negative	0.6296	0.6296	0.3704
19	55	negative	Agus-Sylvi	ahhhh b...	negative	0.6289	0.6289	0.3711
20	59	negative	Agus-Sylvi	pantas s...	positive	0.5797	0.4203	0.5797
21	62	negative	Agus-Sylvi	Tim yang...	negative	0.6100	0.6100	0.3900
22	63	negative	Agus-Sylvi	Coba ber...	negative	0.7199	0.7199	0.2801
23	65	negative	Agus-Sylvi	amieeen	negative	0.5724	0.5724	0.4276

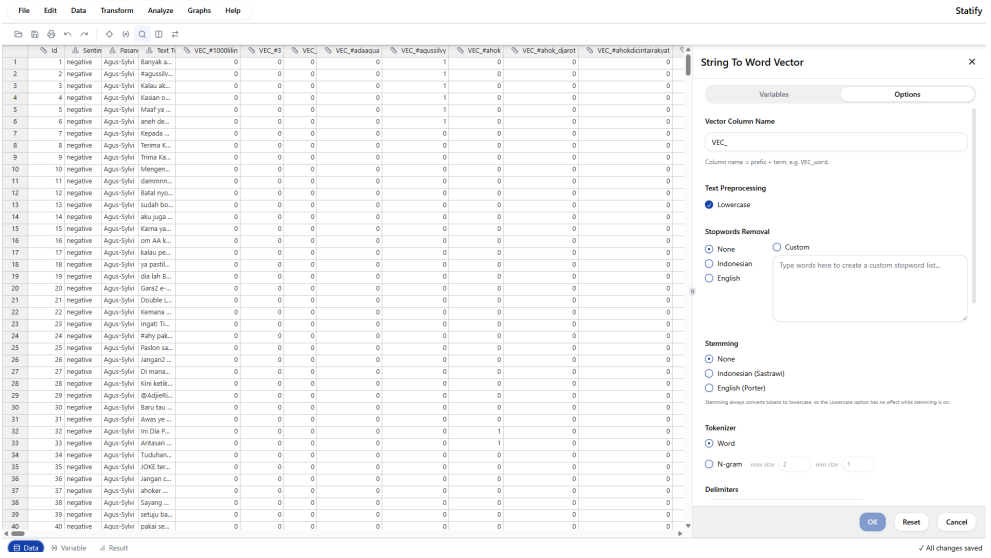
Skenario 6: String to Word Vector dan Word-Vector Variables

Menu *String to Word Vector* digunakan jika pengguna ingin melihat atau menyimpan bobot kata sebagai kolom di dataset, misalnya untuk dianalisis dengan menu lain. Impor kembali berkas **dataset_tweet_sentiment_pilkada_DKI_2017.csv**, lalu pilih menu **Transform > String to Word Vector**.

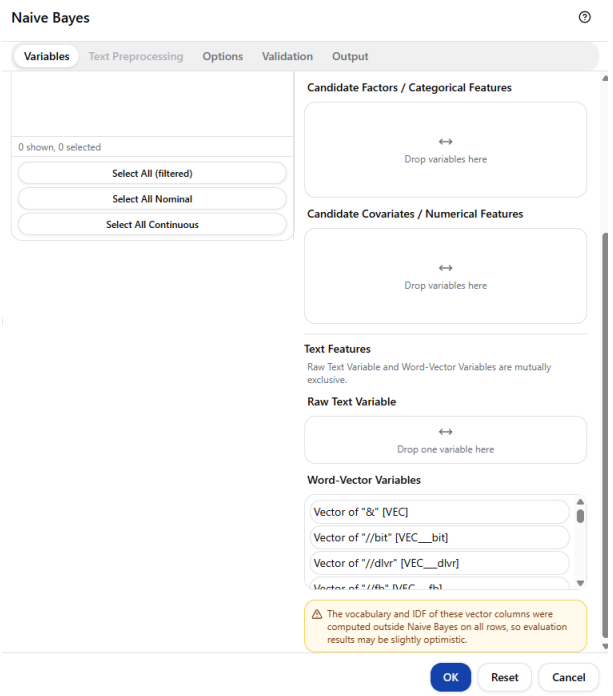


1. **Tab Variables**: pindahkan **Text Tweet** ke kotak **Target Variable**. Daftar variabel hanya menampilkan variabel bertipe *String* atau ber-*measure* Nominal.
2. **Tab Options**: berisi pengaturan yang sama dengan Tab Text Preprocessing pada Skenario 2, ditambah **Vector Column Name** untuk awalan nama kolom hasil (*default* VEC_, maksimal 32 karakter). Gunakan pengaturan *default* untuk skenario ini.
3. Klik OK. Kolom baru seperti VEC_ahok dan VEC_anies ditambahkan di akhir dataset, dengan satu kolom untuk setiap kata. Output Viewer dengan judul **String to**

Word Vector menampilkan **Processing Summary** (jumlah dokumen, ukuran kosakata, dan jumlah kolom yang ditambahkan), **Settings** (konfigurasi yang dipakai), dan **Vocabulary** (daftar kata dan kolomnya, maksimal 200 baris ditampilkan).



4. Buka kembali menu **Naive Bayes**. Isi Target dengan Sentiment, lalu masukkan Id, Pasangan Calon, dan Text Tweet ke kotak Variables to Exclude. Text Tweet perlu dikeluarkan karena pada mode *Exclude* variabel teks lain akan ikut sebagai prediktor kategorik.
5. Ketik **VEC_** pada kotak **Filter**, klik **Select All (filtered)**, lalu pindahkan seluruh kolom tersebut ke kotak **Word-Vector Variables**. Akan muncul peringatan bahwa kosakata dan IDF kolom vektor dihitung di luar Naive Bayes sehingga hasil evaluasi dapat sedikit optimis.



Klik OK.

6. Bandingkan hasilnya dengan Skenario 1. Pada jalur ini, kosakata dibentuk dari seluruh data, termasuk data uji, sehingga terjadi kebocoran data. Selain itu, model Word-Vector tidak menyimpan resep pra-pemrosesan, sehingga untuk klasifikasi teks dan penerapan model pada data baru disarankan menggunakan jalur **Raw Text Variable**.